

考试大题结构猜测与分析

第一章 概率论

练习题 1：乘积规则与贝叶斯推断（离散先验与连续似然）

【考点涵盖】乘积规则、全概率公式、贝叶斯计算后验

【题目】

已知参数 θ 的先验分布为两点分布，其取值为 1 和 -1 的概率均为 0.5。系统的观测模型为 $y = \theta + \omega$ ，其中噪声项 ω 服从零均值、方差为 σ^2 的正态分布，即 $\omega \sim \mathcal{N}(0, \sigma^2)$ ，且 θ 与 ω 相互独立。

- (1) 写出给定 θ 时，观测值 y 的似然函数 $p(y|\theta)$ 。
- (2) 利用乘积规则 and 全概率法则，推导观测变量 y 的边缘概率密度函数 $p(y)$ 。
- (3) 当观测到一个具体的 y 值时，求参数 $\theta = 1$ 的后验概率 $P(\theta = 1|y)$ 。

【解题过程】

(1) **似然函数**：由于 $y = \theta + \omega$ 且 $\omega \sim \mathcal{N}(0, \sigma^2)$ ，当给定 θ 时， y 服从均值为 θ 、方差为 σ^2 的正态分布。

因此，似然函数为：
$$p(y|\theta) = \mathcal{N}(y|\theta, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y-\theta)^2}{2\sigma^2}\right)。$$

(2) **边缘分布**：根据**乘积规则**，联合分布 $p(y, \theta) = p(y|\theta)P(\theta)$ 。根据全概率法则，边缘分布 $p(y)$ 是联合分布对所有可能的 θ 求和：

$$p(y) = p(y|\theta = 1)P(\theta = 1) + p(y|\theta = -1)P(\theta = -1)$$
$$p(y) = 0.5 \cdot \mathcal{N}(y|1, \sigma^2) + 0.5 \cdot \mathcal{N}(y|-1, \sigma^2)$$

(3) **后验分布**：根据**贝叶斯定理**，后验概率等于似然乘以先验，再除以边缘似然：

$$P(\theta = 1|y) = \frac{p(y|\theta=1)P(\theta=1)}{p(y)} = \frac{0.5 \cdot \mathcal{N}(y|1, \sigma^2)}{0.5 \cdot \mathcal{N}(y|1, \sigma^2) + 0.5 \cdot \mathcal{N}(y|-1, \sigma^2)}$$
$$化简得：P(\theta = 1|y) = \frac{\exp\left(-\frac{(y-1)^2}{2\sigma^2}\right)}{\exp\left(-\frac{(y-1)^2}{2\sigma^2}\right) + \exp\left(-\frac{(y+1)^2}{2\sigma^2}\right)}$$

练习题 2：二维联合高斯分布推算边缘与条件分布

【考点涵盖】二维联合高斯分布、边缘分布、条件分布

【题目】

考虑一个二维随机向量 $x = (x_1, x_2)^T$ ，其服从联合高斯分布 $p(x_1, x_2) = \mathcal{N}(x|\mu, \Sigma)$ 。其中，均值向量 $\mu = (\mu_1, \mu_2)^T$ ，协方差矩阵为 $\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$ ， ρ 为相关系数。

- (1) 试写出 x_2 的边缘概率分布 $p(x_2)$ 。
- (2) 推导给定 x_1 的条件下， x_2 的条件概率分布 $p(x_2|x_1)$ 的均值和方差，并解释当 $\rho = 0$ 时条件分布的变化。

【解题过程】

(1) **边缘分布**：在多元高斯分布中，任意子向量的边缘分布依然是高斯分布，只需从联合均值和联合协方差矩阵中提取对应的分块即可。因此， x_2 的边缘分布为：

$$p(x_2) = \mathcal{N}(x_2|\mu_2, \sigma_2^2)。$$

(2) **条件分布**：根据多元高斯分布的条件概率公式，条件分布 $p(x_2|x_1)$ 也是高斯分布，其均值和方差公式为：

- **条件均值**： $\mu_{2|1} = \mu_2 + \Sigma_{21}\Sigma_{11}^{-1}(x_1 - \mu_1) = \mu_2 + \frac{\rho\sigma_1\sigma_2}{\sigma_1^2}(x_1 - \mu_1) = \mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)。$
- **条件方差**： $\Sigma_{2|1} = \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12} = \sigma_2^2 - \frac{(\rho\sigma_1\sigma_2)^2}{\sigma_1^2} = \sigma_2^2(1 - \rho^2)。$
- **解释**：当 $\rho = 0$ （即 x_1 与 x_2 不相关时），条件均值退化为 μ_2 ，条件方差退化为 σ_2^2 。此时 $p(x_2|x_1) = p(x_2)$ ，表明在联合高斯分布中，不相关等价于独立。

条件均值和条件方差公式推导：基于协方差矩阵分块直接配方推导

假设随机变量向量分为 x_1 和 x_2 两部分，其联合概率分布 $p(x_1, x_2)$ 满足多元高斯分布：

$$p(x_1, x_2) \propto \exp\left\{-\frac{1}{2}\begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix}^T \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}^{-1} \begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix}\right\}$$

为了解条件分布 $p(x_1|x_2)$ ，可以利用分块矩阵求逆公式，将指数部分进行配方分解。经过配方分解后，联合分布可以拆解为两部分相乘的形式：

$$p(x_1, x_2) \propto \exp\left\{-\frac{1}{2}(x_1 - \mu_1 - \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2))^T(\Sigma/\Sigma_{22})^{-1}(x_1 - \mu_1 - \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2))\right\} \times \exp\left\{-\frac{1}{2}(x_2 - \mu_2)^T\Sigma_{22}^{-1}(x_2 - \mu_2)\right\}$$

根据条件概率公式 $p(x_1, x_2) = p(x_1|x_2)p(x_2)$ ，前一个 exp 项正是对应于 $p(x_1|x_2)$ 的分布形式，后一个 exp 项对应于边缘分布 $p(x_2)$ 。

由此，可以直接从 $p(x_1|x_2)$ 的 exp 表达式中提取出**条件均值和条件方差**的结论：

- **条件均值**： $\mu_{1|2} = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2)$
- **条件方差**： $\Sigma_{1|2} = \Sigma/\Sigma_{22} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$
(注：这与前面的练习题中求 $p(x_2|x_1)$ 时只是索引 1 和 2 对调了一下)

练习题 3：线性高斯系统与贝叶斯后验计算（对标2025样卷第1题）

【考点涵盖】线性高斯系统、贝叶斯计算后验、后验均值与方差

【题目】

设随机变量 x 代表某目标的真实位置，其先验分布为 $p(x) = \mathcal{N}(x|\mu_0, \sigma_0^2)$ 。雷达对 x 进行观测得到测量值 $y = x + v$ ，其中测量噪声 $v \sim \mathcal{N}(0, \sigma_v^2)$ ，且 x 与 v 独立。

- (1) 写出似然函数表达式 $p(y|x)$ ，以及观测变量 y 的边缘分布 $p(y)$ 。
- (2) 计算后验分布 $p(x|y)$ ，并写出后验均值 μ_{post} 和后验方差 σ_{post}^2 。
- (3) 比较后验方差 σ_{post}^2 与先验方差 σ_0^2 、噪声方差 σ_v^2 的大小关系，说明贝叶斯估计的意义。

【解题过程】

(1) 似然与边缘分布：

因为 $y = x + v$ 且 x 固定，故似然函数 $p(y|x) = \mathcal{N}(y|x, \sigma_v^2)$ 。

对于边缘分布，利用线性高斯系统的性质： $E[y] = E[x] + E[v] = \mu_0$ ，由于独立性 $Var(y) = Var(x) + Var(v) = \sigma_0^2 + \sigma_v^2$ 。故 $p(y) = \mathcal{N}(y|\mu_0, \sigma_0^2 + \sigma_v^2)$ 。

(2) 后验分布计算：

这是典型的线性高斯系统求后验。根据教材公式，若 $p(z) = \mathcal{N}(z|\check{\mu}, \check{\Sigma})$ 且 $p(y|z) = \mathcal{N}(y|Wz + b, \Omega)$ ，后验 $p(z|y)$ 的参数为：

均值 $\hat{\mu} = \check{\mu} + \check{\Sigma}W^T(\Omega + W\check{\Sigma}W^T)^{-1}(y - (W\check{\mu} + b))$

方差 $\hat{\Sigma} = \check{\Sigma} - \check{\Sigma}W^T(\Omega + W\check{\Sigma}W^T)^{-1}W\check{\Sigma}$

对应本题参数映射： $z = x, W = 1, b = 0, \check{\mu} = \mu_0, \check{\Sigma} = \sigma_0^2, \Omega = \sigma_v^2$ 。代入得：

- 后验均值： $\mu_{post} = \mu_0 + \frac{\sigma_0^2}{\sigma_0^2 + \sigma_v^2}(y - \mu_0)$ 。
 - 后验方差： $\sigma_{post}^2 = \sigma_0^2 - \frac{\sigma_0^4}{\sigma_0^2 + \sigma_v^2} = \frac{\sigma_0^2 \sigma_v^2}{\sigma_0^2 + \sigma_v^2}$ 。
- 因此，后验分布 $p(x|y) = \mathcal{N}(x|\mu_{post}, \sigma_{post}^2)$ 。

(3) 方差大小比较与意义：

将后验方差改写为倒数形式： $\frac{1}{\sigma_{post}^2} = \frac{1}{\sigma_0^2} + \frac{1}{\sigma_v^2}$ 。

这表明后验精度（方差的倒数）等于先验精度与测量精度之和。由于各项均为正，因此 $\sigma_{post}^2 < \sigma_0^2$ 且 $\sigma_{post}^2 < \sigma_v^2$ 。

结论：后验方差代表了以均值作为估计器的平均均方误差。该关系说明，综合利用先验信息和测量信息进行贝叶斯估计，其不确定性（误差）一定会小于仅仅依赖先验预测，或者仅仅依赖单次雷达测量的误差。

第二章 逻辑与推理

样卷小问 解题过程

题目：已知 $(\forall x)(F(x) \rightarrow (G(x) \vee H(x)))$, $\neg(\forall x)(F(x) \rightarrow G(x))$ 。试证明 $(\exists x)(F(x) \wedge H(x))$ 。

证明过程：

1. $\neg(\forall x)(F(x) \rightarrow G(x)) \equiv (\exists x)\neg(F(x) \rightarrow G(x))$ （全称量词与存在量词的逻辑等价）
2. $\neg(F(x) \rightarrow G(x)) \equiv \neg(\neg F(x) \vee G(x)) \equiv F(x) \wedge \neg G(x)$ （蕴含消除与德摩根定律）
3. 由 1 和 2 可得前提2等价于： $(\exists x)(F(x) \wedge \neg G(x))$
4. $(\exists x)(F(x) \wedge \neg G(x)) \Rightarrow F(a) \wedge \neg G(a)$ （存在量词消去 EI）
5. $F(a) \wedge \neg G(a) \Rightarrow F(a), \neg G(a)$ （与消解）
6. $(\forall x)(F(x) \rightarrow (G(x) \vee H(x))) \Rightarrow F(a) \rightarrow (G(a) \vee H(a))$ （对前提1使用全称量词消去 UI）
7. $F(a) \rightarrow (G(a) \vee H(a)) \equiv \neg F(a) \vee G(a) \vee H(a)$ （蕴含消除）
8. $F(a), \neg F(a) \vee G(a) \vee H(a) \Rightarrow G(a) \vee H(a)$ （单项消解或归结）
9. $\neg G(a), G(a) \vee H(a) \Rightarrow H(a)$ （单项消解或归结）
10. $F(a), H(a) \Rightarrow F(a) \wedge H(a)$ （与导入）
11. $F(a) \wedge H(a) \Rightarrow (\exists x)(F(x) \wedge H(x))$ （存在量词引入 EG）

针对性模拟练习题

练习题 1：命题逻辑（范式转换与归结法）

题目：

- (1) 求命题公式 $\neg(\alpha \rightarrow \beta) \vee \neg\gamma$ 的合取范式。
- (2) 已知前提 $\alpha \rightarrow \beta, \beta \rightarrow \gamma, \neg\gamma$ ，试用归结法证明 $\neg\alpha$ 。

解题过程：

(1) 求合取范式：

$\neg(\alpha \rightarrow \beta) \vee \neg\gamma$
 $\equiv \neg(\neg\alpha \vee \beta) \vee \neg\gamma$ (蕴含消除)
 $\equiv (\alpha \wedge \neg\beta) \vee \neg\gamma$ (德摩根定律)
 $\equiv (\alpha \vee \neg\gamma) \wedge (\neg\beta \vee \neg\gamma)$ (分配律, 得到合取范式)

(2) 归结法证明：

- $\alpha \rightarrow \beta \equiv \neg\alpha \vee \beta$ (蕴含消除)
- $\beta \rightarrow \gamma \equiv \neg\beta \vee \gamma$ (蕴含消除)
- $\neg\alpha \vee \beta, \neg\beta \vee \gamma \Rightarrow \neg\alpha \vee \gamma$ (消解或归结)
- $\neg\alpha \vee \gamma, \neg\gamma \Rightarrow \neg\alpha$ (单项消解或归结)

练习题 2：谓词逻辑推理（与样题类似）

题目：已知前提 $(\forall x)(P(x) \rightarrow Q(x))$ 和 $(\exists x)(P(x) \wedge R(x))$ ，试证明 $(\exists x)(Q(x) \wedge R(x))$ 。

解题过程：

- $(\exists x)(P(x) \wedge R(x)) \Rightarrow P(a) \wedge R(a)$ (存在量词消去 EI)
- $P(a) \wedge R(a) \Rightarrow P(a), R(a)$ (与消解)
- $(\forall x)(P(x) \rightarrow Q(x)) \Rightarrow P(a) \rightarrow Q(a)$ (全称量词消去 UI)
- $P(a) \rightarrow Q(a) \equiv \neg P(a) \vee Q(a)$ (蕴含消除)
- $P(a), \neg P(a) \vee Q(a) \Rightarrow Q(a)$ (单项消解或归结)
- $Q(a), R(a) \Rightarrow Q(a) \wedge R(a)$ (与导入)
- $Q(a) \wedge R(a) \Rightarrow (\exists x)(Q(x) \wedge R(x))$ (存在量词引入 EG)

练习题 3：自然语言形式化与证明

题目：将以下自然语言形式化，并进行证明。

前提：所有参加人工智能考试的学生都复习了教材。有些学生没有复习教材。

结论：有些学生没有参加人工智能考试。

解题过程：

形式化：

设 $Student(x)$: x 是学生; $Exam(x)$: x 参加人工智能考试; $Review(x)$: x 复习了教材。

前提 1: $(\forall x)((Student(x) \wedge Exam(x)) \rightarrow Review(x))$

前提 2: $(\exists x)(Student(x) \wedge \neg Review(x))$

结论: $(\exists x)(Student(x) \wedge \neg Exam(x))$

证明：

- $(\exists x)(Student(x) \wedge \neg Review(x)) \Rightarrow Student(a) \wedge \neg Review(a)$ (存在量词消去)
- $Student(a) \wedge \neg Review(a) \Rightarrow Student(a), \neg Review(a)$ (与消解)
- $(\forall x)((Student(x) \wedge Exam(x)) \rightarrow Review(x)) \Rightarrow (Student(a) \wedge Exam(a)) \rightarrow Review(a)$ (全称量词消去)
- $(Student(a) \wedge Exam(a)) \rightarrow Review(a) \equiv \neg(Student(a) \wedge Exam(a)) \vee Review(a)$ (蕴含消除)
- $\neg(Student(a) \wedge Exam(a)) \vee Review(a) \equiv \neg Student(a) \vee \neg Exam(a) \vee Review(a)$ (德摩根定律)
- $\neg Review(a), \neg Student(a) \vee \neg Exam(a) \vee Review(a) \Rightarrow \neg Student(a) \vee \neg Exam(a)$ (单项消解与归纳)
- $Student(a), \neg Student(a) \vee \neg Exam(a) \Rightarrow \neg Exam(a)$ (单项消解与归纳)
- $Student(a), \neg Exam(a) \Rightarrow Student(a) \wedge \neg Exam(a)$ (与导入)
- $Student(a) \wedge \neg Exam(a) \Rightarrow (\exists x)(Student(x) \wedge \neg Exam(x))$ (存在量词引入)

第三章 搜索

综合大题：智能探险者的寻宝之旅

【题目背景】

人工智能探险者 (Alpha) 进入了一个地下城寻找终极宝藏。它需要先通过迷宫地图 (单智能体寻路搜索)，到达宝藏室后，还必须与守卫进行一场零和博弈 (对抗搜索) 才能拿走宝藏。

第一阶段：迷宫寻路（考察：贪婪最佳优先、A*搜索）

Alpha 目前位于起点 S ，宝藏室位于终点 G 。迷宫节点及真实的移动代价 $g(n)$ （两点之间的距离）如下：

- $S \rightarrow A$ (代价: 1)
- $S \rightarrow B$ (代价: 4)
- $A \rightarrow C$ (代价: 2)
- $A \rightarrow G$ (代价: 12)
- $B \rightarrow D$ (代价: 2)
- $C \rightarrow G$ (代价: 3)
- $D \rightarrow G$ (代价: 3)

同时，Alpha 拥有一张古代藏宝图，提供了各个节点到终点 G 的**直线估计距离（启发式函数 $h(n)$ ）**：

$$h(S) = 7, h(A) = 4, h(B) = 2, h(C) = 2, h(D) = 1, h(G) = 0$$

问题 1:

- (a) 如果 Alpha 使用**贪婪最佳优先搜索（Greedy Best-First Search）**，请写出它选择扩展的节点序列和最终路径，并计算该路径的实际总代价。
- (b) 如果 Alpha 使用**A* 搜索算法**，请写出搜索扩展过程中的 $f(n)$ 计算、最终找到的路径及其总代价。贪婪算法和 A* 算法谁找到了最优解？这体现了它们在基本概念上的什么区别？

第二阶段：与守卫博弈（考察：Minimax、Alpha-Beta剪枝）

Alpha 成功抵达终点 G 后，守卫要求与它玩一个回合制桌游。Alpha 是先手（Max层），守卫是后手（Min层）。游戏树深度有限，叶子节点是 Alpha 的收益值。

博弈树结构如下（从左到右）：

- 根节点 A (Max) 有两个动作选项，分别通向节点 B (Min) 和 C (Min)。
- 节点 B 有两个动作选项，通向 D (Max) 和 E (Max)。
- 节点 C 有两个动作选项，通向 F (Max) 和 G (Max)。
- 终端叶子节点的收益值为： D 分支向下有两个叶子 (3, 5)； E 分支有两个叶子 (6, 9)； F 分支有两个叶子 (1, 2)； G 分支有两个叶子 (0, -1)。

问题 2:

- (a) 使用 **Minimax 搜索** 计算中间节点 D, E, F, G 以及 B, C, A 的评估值。Alpha 初始应该选择哪条分支（B还是C）？
- (b) 为了加速计算，Alpha 决定使用 **Alpha-Beta 剪枝算法**。假设算法从左到右遍历博弈树，请详细写出发生剪枝的位置，并说明为什么可以剪枝？

第三阶段：无尽的博弈规则（考察：蒙特卡洛树搜索 MCTS）

守卫见自己快输了，突然将游戏改成了“围棋”。围棋的分支因子极大，深度极深，利用有限的算力根本无法构建完整的 Minimax 树或使用 Alpha-Beta 遍历。

问题 3:

Alpha 决定切换为 **蒙特卡洛树搜索 (Monte Carlo Tree Search, MCTS)** 来决定下一步动作。请你简述 MCTS 每次迭代的核心的**四个步骤**是什么？为什么 MCTS 比 Minimax/Alpha-Beta 更适合这种复杂度极高且难以设计启发式评估函数的游戏？

💡 参考答案与解题过程

解答 1：迷宫寻路 (贪婪算法 vs A* 算法)

(a) **贪婪最佳优先搜索**的核心是**只看前方**，即评价函数 $f(n) = h(n)$ ，永远挑选启发值最小的节点扩展。

- **当前在 S**：可去 A ($h = 4$) 或 B ($h = 2$)。因为 $h(B) < h(A)$ ，选择扩展 **B**。
- **当前在 B**：可去 D ($h = 1$)。选择扩展 **D**。
- **当前在 D**：可去 G ($h = 0$)。选择扩展 **G**，到达终点。
- **路径**： $S \rightarrow B \rightarrow D \rightarrow G$
- **总代价**： $4 + 2 + 3 = 9$ 。

(b) **A* 搜索**的核心是**兼顾历史与前方**，评价函数 $f(n) = g(n) + h(n)$ ，挑选总估计代价最小的节点。

- **扩展 S** ($f = 0 + 7 = 7$)：生成 A ($f = 1 + 4 = 5$)， B ($f = 4 + 2 = 6$)。最小是 **A**。
- **扩展 A** ($f = 5$)：生成 C ($f = (1 + 2) + 2 = 5$)， G ($f = (1 + 12) + 0 = 13$)。这时候选节点有 $C(5)$, $B(6)$, $G(13)$ 。最小是 **C**。
- **扩展 C** ($f = 5$)：生成 G ($f = (1 + 2 + 3) + 0 = 6$)。这时候选节点有 $B(6)$, $G(6)$, $G(13)$ 。最小是 **G(代价值为6)**，到达终点。
- **路径**： $S \rightarrow A \rightarrow C \rightarrow G$
- **总代价**： $1 + 2 + 3 = 6$ 。

- **区别**：**A*搜索找到了最优解（代价6）**，而贪婪算法陷入了次优解（代价9）。在搜索基本概念中，贪婪搜索是不完备且不能保证最优的（它容易被眼前的“假象”诱导）；而 A* 搜索只要启发式函数是可采纳的（ $h(n) \leq$ 实际代价，这里全部满足），就**保证能找到最优解**。

解答 2：对抗搜索 (Minimax 与 Alpha-Beta 剪枝)

(a) **Minimax 搜索计算** (自底向上，Max取最大，Min取最小)：

1. **D层(Max)**: $D = \max(3, 5) = 5$; $E = \max(6, 9) = 9$; $F = \max(1, 2) = 2$; $G = \max(0, -1) = 0$ 。
2. **Min层**: $B = \min(D, E) = \min(5, 9) = 5$; $C = \min(F, G) = \min(2, 0) = 0$ 。
3. **Root A(Max)**: $A = \max(B, C) = \max(5, 0) = 5$ 。

- **结论**：Alpha 应该选择走到节点 **B** 分支，保证自己能拿到底线收益 5。

(b) **Alpha-Beta 剪枝过程** (自顶向下，从左到右， α 是Max的最好底线， β 是Min的最好底线)：

1. 首先到达 A，向左走遍历 B，再遍历 D。D 拿到叶子 3, 5，所以 $D = 5$ 。
2. 退回 B，此时 B(Min节点) 有了一个可选项 5，因此更新 $\beta = 5$ （意思是B最多给A留下5的收益）。
3. 从 B 去遍历 E。E(Max节点) 看到了第一个叶子节点 **6**。
4. **【第一次剪枝发生】** 此时 E 作为 Max 节点，它的值**至少是 6**。但是 B 作为 Min 节点，手里已经攥着一个较小的值 5 ($\beta = 5$)。B 绝对不会对去选 E 分支（因为 $6 > 5$ ）。所以 E 剩下的叶子节点（如9）**被剪枝，无需遍历**。
5. B 节点评估结束，返回 5 给根节点 A。A 更新自己的 $\alpha = 5$ (A 保证自己至少能拿到 5)。
6. A 向右去遍历 C。C 再遍历 F。F 拿到叶子 1, 2，所以 $F = 2$ 。
7. 退回 C，此时 C(Min节点) 有了一个可选项 2，因此更新其 $\beta = 2$ 。
8. **【第二次剪枝发生】** 此时 C 是 Min 节点，它的值**至多是 2**（甚至更小）。但是根节点 A(Max) 的底线 $\alpha = 5$ 。既然 C 提供的收益绝对不可能大于 A 当前手中已有的 5（即 $\beta(2) \leq \alpha(5)$ ），A 就绝对不会走 C 这一步。所以，**C 下方的 G 节点（及其所有子节点）被整枝剪掉**。
9. 搜索结束，最优动作仍然是走向 B。

解答 3：蒙特卡洛树搜索 (MCTS)

四个核心步骤：

1. **选择 (Selection)**：从根节点出发，使用 UCB1（上限置信区间）公式在探索（尝试没去过的分支）和利用（选择胜率高的分支）之间寻找平衡，一直走到一个未完全展开的节点。
2. **扩展 (Expansion)**：如果该节点不是终止状态，则将它的一个（或多个）合法动作作为新的子节点加入到搜索树中。
3. **模拟 (Simulation / Rollout)**：从这个新扩展的子节点开始，随机（或基于简单策略）快速走子，直到游戏结束，得到最终的胜负结果。
4. **回溯 (Backpropagation)**：将模拟得到的胜负结果，沿着路径反向传播回去，更新路径上所有节点的访问次数（N）和胜利次数（W）。

为什么比 Minimax/Alpha-Beta 更好？

- **无需完全遍历**：围棋的分支因子极大（平均250），Minimax 树呈指数级爆炸，Alpha-Beta也剪不完；MCTS 采用随机抽样，算力允许时随时可以停止（Anytime Algorithm）并输出当前的最优解。
- **无需复杂的评估函数**：Minimax 必须依赖精确的启发式函数来评估非终端节点（而围棋的盘面价值极难用公式准确量化）；MCTS 通过大量的随机模拟（Rollout）走到终局来直接获知胜率，以真实的统计结果替代了人工设计的评价函数。

第四章 监督学习

练习题 1：监督学习基础与生成/判别方法（概念与辨析）

题目：

- (1) 简述机器学习中“监督学习”的基本目标是什么？在模型学习过程中，如何衡量预测结果的好坏？
- (2) 判别式学习（Discriminative learning）与生成学习（Generative learning）的核心区别是什么？请写出生成学习中，计算输入数据 x 属于类别 c_i 的后验概率 $P(c_i|x)$ 的基本公式，并说明公式中各项的物理意义。

解题过程与考点解析：

- (1) **监督学习的基本概念**：监督学习的目标是给定带有标签信息的训练集合，学习一个从输入（特征向量）到输出（标签空间）的映射函数 f 。为了学习此映射函数 f ，需要定义**损失函数**（Loss function）来衡量预测值 $\hat{y}_i$ 与真实标签 y_i 之间的差异。

(2) **生成方法与判别方法的区别**：

- **判别式学习**：由数据直接学习决策函数 f_θ 或者条件概率分布 $P(c_i|x)$ 来作为预测的模型。它不涉及与样本数据有关的底层概率计算，而是直接从底层特征出发得到类别输出。
- **生成学习**：先从数据中学习输入和类别的**联合概率分布** $P(X, C)$ ，然后再通过计算条件概率分布 $P(C|X)$ 作为预测模型。

- **公式与意义**：生成学习通过贝叶斯公式计算后验概率：

$$P(c_i|x) = \frac{P(x|c_i)P(c_i)}{P(x)}$$

在分类决策时，因为对于每个类别，输入数据 x 的概率 $P(x)$ 是一样的，通常简化为： $P(c_i|x) = P(x|c_i) \times P(c_i)$ 。其中， $P(x|c_i)$ 是**似然概率**（从类别 c_i 模型中产生 x 的概率）， $P(c_i)$ 是**先验概率**（类别 c_i 出现的概率）， $P(c_i|x)$ 即为所求的**后验概率**。

练习题 2：回归分析（线性回归与逻辑斯蒂回归）

题目：

- (1) 在多元线性回归中，若将所有训练数据特征表示为矩阵 $X = [x_1, \dots, x_m]$ ，标签为 $y = [y_1, \dots, y_m]^T$ ，请写出其均方误差函数 $J_m(a)$ 的矩阵表示形式。通过令其导数为 0，求解出的参数矩阵 a 的闭式解（closed form solution）是什么？
- (2) 在分类场景下，一元或多元线性回归存在什么明显的问题？逻辑斯蒂回归（Logistic Regression）是如何解决这个问题？
- (3) 逻辑斯蒂回归的损失函数（交叉熵损失）是如何通过最大似然估计推导出来的？简述推导过程。

解题过程与考点解析：

- (1) **多元线性回归矩阵形式与闭式解**：

均方误差函数可以表示为 $J_m(a) = (y - X^T a)^T (y - X^T a)$ 。

对参数 a 求导得到 $\nabla J(a) = -2X(y - X^T a)$ ，令梯度为 0，解得闭式解为： $a = (X X^T)^{-1} X y$ 。

- (2) **逻辑斯蒂回归的引入动机**：

线性回归的一个明显问题是**对离群点（outlier）非常敏感**，会导致模型建模不稳定且使结果有偏。逻辑斯蒂回归在回归模型中引入了 sigmoid 函数 $y = \frac{1}{1+e^{-z}}$ ，将连续的线性输出映射到了 $(0, 1)$ 之间。这不仅限制了离群点输出的量级，而且赋予了输出值以概率意义（如输入数据属于正例的概率），从而完美契合了分类任务的需求。

- (3) **交叉熵损失的推导**：

假设每个样本数据是独立同分布的，逻辑斯蒂回归的最大似然函数（Likelihood）可以表示为所有样本预测概率的乘积：

$$L(\theta|D) = \prod_{i=1}^n (h_{\theta}(x_i))^{y_i} (1 - h_{\theta}(x_i))^{1-y_i}。$$

对该似然函数取对数，得到对数似然函数 $l(\theta) = \sum_{i=1}^n [y_i \log(h_{\theta}(x_i)) + (1 - y_i) \log(1 - h_{\theta}(x_i))]$ 。

为了将求最大值问题转化为最小化损失函数的问题，在对数似然函数前加一个负号，即得到了交叉熵损失函数 $T(\theta) = -l(\theta)$ 。

练习题 3：支持向量机（SVM 综合推导）

题目：

- (1) 支持向量机（SVM）通过什么原则来解决过拟合（过学习）问题？请简述经验风险、置信风险与 VC 维之间的关系。
- (2) 针对线性可分问题，支持向量机寻找“最大间隔”的优化目标函数（引入了 $\|w\|^2$ ）是什么？
- (3) 针对存在少数离群点导致线性不可分的“软间隔”（Soft margin）情况，支持向量机如何修改其目标函数？请写出引入松弛变量 ξ_i 后的原问题（primal problem）目标函数和约束条件。
- (4) 对于完全线性不可分的数据，支持向量机采用什么技术处理？

解题过程与考点解析：

- (1) **结构风险最小化与 VC 维**：

SVM 通过**结构风险最小化（structural risk minimization）**来解决过学习问题。

分类器的期望风险（真实风险）由两部分组成：从训练集得到的**经验风险**，以及与分类器 VC 维相关的**置信风险**。模型复杂度越高（VC 维越大），虽然可能经验风险很小，但置信风险会显著变大，导致期望风险变大（即过拟合）。结构风险最小化要求在保证经验风险小的同时，降低算法模型的 VC 维，以取得较好的泛化性能。

- (2) **硬间隔优化目标**：

在满足使所有正负样本被正确分类（ $y_i(w^T x_i + b) \geq 1$ ）的约束下，SVM 最大化分类间隔 $\frac{2}{\|w\|_2}$ ，等价于最小化优化目标：

$$\min_{w,b} \frac{1}{2} w^T w。$$

- (3) **软间隔与松弛变量**：

软间隔允许部分样本错分，因此引入了松弛变量 $\xi_i \geq 0$ 来表示样本被错分产生的损失（Hinge 损失）。优化目标函数变为最小化权重以及松弛变量的惩罚和：

$$\min_{w,b} \frac{1}{2} w^T w + c \times \sum_{i=1}^n \xi_i。$$

其约束条件变为： $y_i(w^T x_i + b) \geq 1 - \xi_i$ ，且 $\xi_i \geq 0 (i = 1, 2, \dots, n)$ 。

- (4) **核函数（Kernel Function）**：

对于原始样本空间线性不可分的问题，SVM 可以将样本映射到一个更加高维的特征空间使其线性可分。为了避免直接在高维特征空间中进行复杂的内积运算，SVM 引入了**核函数** $\kappa(x_i, x_j)$ 。通过核函数，可以直接在原始样本空间中计算得出两个样本映射到高维空间后的内积（即 $\kappa(x_i, x_j) = \phi(x_i)^T \phi(x_j)$ ），大大简化了运算。常见的核函数有多项式核函数、高斯径向基核函数（RBF）等。

第五章 无监督学习

练习题 1：无监督学习基础与 K 均值聚类（结合 2025 卷第 5 题）

题目：

- (1) 简述无监督学习的基本概念及其常见任务。
- (2) **(2025 卷真题演练)** 计算如下一维无监督分类问题：已知数据点为 1, 2, 3, 6, 7, 9，假设初始质心为 1 和 6，利用欧式距离作为距离函数使用 K-means 算法将数据点分为两类，请写出演算过程，计算最终中心点并分类数据点。

解答与考点解析：

(1) **无监督学习概念**：无监督学习是一种不依赖标签信息的机器学习方法。它的目标是从无标签数据中发现数据的内在结构和模式，让算法去洞悉客观事物的内在秉性。常见的无监督学习任务包括**聚类**（将数据划分为若干簇，使簇内相似度高，簇间相似度低）和**降维**（将高维数据映射到低维空间并保留主要信息）。

(2) **K-means 聚类计算**：

- **初始状态**：质心 $c_1 = 1, c_2 = 6$ 。
- **第一次迭代（分配数据点）**：计算各点到两个质心的距离。
 - 点 1：到 c_1 距离为 0，到 c_2 距离为 5 $\rightarrow$ 属于类别 1。
 - 点 2：到 c_1 距离为 1，到 c_2 距离为 4 $\rightarrow$ 属于类别 1。
 - 点 3：到 c_1 距离为 2，到 c_2 距离为 3 $\rightarrow$ 属于类别 1。
 - 点 6：到 c_1 距离为 5，到 c_2 距离为 0 $\rightarrow$ 属于类别 2。
 - 点 7：到 c_1 距离为 6，到 c_2 距离为 1 $\rightarrow$ 属于类别 2。
 - 点 9：到 c_1 距离为 8，到 c_2 距离为 3 $\rightarrow$ 属于类别 2。
 - **当前分类**：簇1 $G_1 = \{1, 2, 3\}$ ，簇2 $G_2 = \{6, 7, 9\}$ 。
- **第二次迭代（更新质心）**：
 - 新质心 $c_1 = (1 + 2 + 3)/3 = 2$ 。
 - 新质心 $c_2 = (6 + 7 + 9)/3 = 7.33$ （或 $22/3$ ）。
- **第三次迭代（重新分配）**：计算各点到新质心 2 和 7.33 的距离。
 - 点 1, 2, 3 距离 2 更近 $\rightarrow$ 属于类别 1。
 - 点 6, 7, 9 距离 7.33 更近 $\rightarrow$ 属于类别 2。
- **结论**：分类结果未发生改变，算法收敛。**最终中心点为 2 和 7.33**，分类结果为：**一类是 {1, 2, 3}，另一类是 {6, 7, 9}。**

练习题 2：主成分分析（PCA）与特征人脸方法

题目：

(1) 主成分分析（PCA）降维的优化目标是什么？

(2) 在特征人脸方法中，假设有 n 张分辨率为 $d \times d$ 的图像，直接计算其特征协方差矩阵的特征向量十分耗时。请简述该方法是如何巧妙利用矩阵代数技巧来高效求解特征人脸的？

解答与考点解析：

(1) **PCA 优化目标**：PCA 的目标是将原始数据向方差最大的方向进行投影，以**最大程度保持原始高维数据总体方差结构**（使得数据每一维的方差都尽可能大），从而减少信息丢失。在数学上，其优化目标是求解映射矩阵 W ，使得 $\max_W \text{tr}(W^T \Sigma W)$ ，其中 Σ 是原始数据的协方差矩阵。

(2) **特征人脸的 SVD 加速技巧**：对于分辨率为 $d \times d$ 的图像，将其展平后维度为 d^2 （通常 $d^2 \gg n$ ）。直接计算 $d^2 \times d^2$ 的协方差矩阵 $\Phi^T \Phi$ 的特征向量极其耗时。

特征人脸方法巧妙地先求取较小的 $n \times n$ 矩阵 $\Phi \Phi^T$ 的特征向量 u_i 。根据公式 $(\Phi \Phi^T)u_i = \lambda_i u_i$ ，两边左乘 Φ^T 得到 $\Phi^T \Phi (\Phi^T u_i) = \lambda_i (\Phi^T u_i)$ 。由此可知， $\Phi^T u_i$ **即为我们真正需要的原矩阵 $\Phi^T \Phi$ 的特征向量**（即特征人脸），从而大幅降低了计算复杂度。

练习题 3：潜在语义分析（LSA）

题目：

(1) 传统的“单词-文档”矩阵存在什么缺陷？潜在语义分析（LSA）是如何解决这一缺陷的？

(2) 对单词-文档矩阵 A 进行奇异值分解 $A \approx U D V^T$ 时，提取出的矩阵 U 和 V^T 分别代表什么物理意义？

解答与考点解析：

(1) **缺陷与解决**：传统的“单词-文档”矩阵只能单纯刻画单词是否在文档中出现，**无法对单词-单词、单词-文档之间的语义关系进行建模**，因此难以应对“一词多义”和“异词同义”的挑战。LSA 通过对大规模文本构建的“单词-文档”矩阵进行**奇异值分解（SVD）得到低秩逼近**，能够将原始文档和单词内嵌到一个隐性空间中，从而挖掘出隐藏在海量文本中的上下文关联和语义关系。

(2) **矩阵的物理意义**：

- **矩阵 U** ：其中的每一个行向量被称为 **LSI 单词向量**（term vectors），包含了单词的隐性语义特征。
- **矩阵 V^T** ：其中的每一个列向量（即矩阵 V 的行向量）被称为 **LSI 文档向量**（document vectors），包含了文档的隐性语义特征。

练习题 4：期望最大化算法（EM）及其应用

题目：

(1) 在包含隐变量的模型中，直接使用最大似然估计会遇到什么困难？EM 算法的核心思想是什么？

(2) 在教材提到的“三硬币投掷”例子中（先抛掷硬币0，若为正面则抛硬币1，若为反面则抛硬币2，只记录硬币1/2的结果），什么是“观测数据”，什么是“隐变量”，什么是“模型参数”？

解答与考点解析：

(1) **困难与 EM 核心思想**：由于隐变量（未观测到的数据）未知，含有隐变量的对数似然函数极其复杂，难以直接对参数求导并令其为0来求解。

EM算法的核心思想是利用迭代逼近：

- **E步骤（求取期望）**：利用 Jensen 不等式构造对数似然函数的一个**下界**。即在固定当前模型参数的情况下，计算隐变量的后验概率分布。
- **M步骤（期望最大化）**：固定隐变量的分布，通过调整模型参数来**最大化这个下界**（即最大化对数似然期望），从而使得更新后的参数能够更好地拟合观测数据。如此交替迭代，直到参数收敛。

(2) **三硬币模型中的要素**：

- **观测数据**：硬币1和硬币2最终投掷出正面或反面的序列结果（如“反正反”即 THT 等）。
- **隐变量**：硬币0的投掷结果（因为决定了后续选哪个硬币，但其本身的结果未被记录）。
- **模型参数**：三枚硬币各自掷出正面的概率，记为 $\Theta = \{\lambda, p_1, p_2\}$ 。