

习题4

1. 请判断下面说法是否正确：线性区别分析是在最大化类间方差和类内方差的比值（ ）。
 - A. 正确
 - B. 错误
2. 在决策树建立过程中，使用一个属性对某个结点对应的数据集进行划分后，结果具有高信息熵（high entropy），对于结果的描述，最贴切的是（ ）。
 - A. 纯度高
 - B. 纯度低
 - C. 有用
 - D. 无用
 - E. 以上描述都不贴切
3. 在一个监督学习任务中，每个数据样本有4个属性和一个类别标签，每种属性分别有3、2、2和2种可能的取值，类别标签有3种不同的取值。请问可能有多少种不同的样本？（注意，并不是在某个数据集中最多有多少种不同的样本，而是考虑所有可能的样本）（ ）。
 - A. 3
 - B. 6
 - C. 12
 - D. 24
 - E. 48
 - F. 72
4. 关于支持向量机，哪一种选择能正确填充下面的说法？（ ）

支持向量机是一种_____模型，其目标是_____分类间隔。

 - A. 生成，最大化
 - B. 生成，最小化
 - C. 判别，最大化
 - D. 判别，最小化
5. 以下哪种方法不属于监督学习方法？（ ）
 - A. 聚类
 - B. 决策树
 - C. 线性回归
 - D. 朴素贝叶斯
 - E. 支持向量机
 - F. 以上都不属于监督学习方法
6. 在Adaboosting的迭代中，从第 t 轮到第 $t+1$ 轮，某个被错误分类样本的惩罚增加了，可能因为该样本（ ）。
 - A. 被第 t 轮训练的弱分类器错误分类
 - B. 被第 t 轮后的集成分类器（强分类器）错误分类
 - C. 被到第 t 轮为止训练的大多数弱分类器错误分类
 - D. B和C都正确
 - E. A、B和C都正确
7. 假设有两批从同样的真实数据分布中采样得到去完成同一任务的数据集A和B。A包含100KB数据，B包含10KB数据。按照9:1这一同样比例随机将A和B分别划分为训练集和测试集。图4.13给出了数据集A和数据集B随着模型复杂度增加所对应的训练误差（A, Train以及B, Train）和测试误差（A, Test以及B, Test）曲线图。请指出哪个图正确表示了随着模型复杂度增加所对应训练误差和测试误差的变化曲线图。（ ）
8. 考虑一个在二维特征空间中的二分类问题。训练集包含8个样本，其在二维空间中的分布如图4.14所示。图4.14中不同




图4.13 数据集A和数据集B随模型复杂度增加所对应的训练误差和测试误差变化示意图




图4.14 两类分类问题中8个样本的分布图

- 类别的样本用不同的形状表示，根据图4.14回答如下问题。
- (1) 使用实线画出使用SVM分类器可得到的分类边界，并用圆圈标出支持向量。
 - (2) 在该分类边界下所得训练错误率为多少？
 - (3) 移除哪些样本可以让分类边界发生变化？

9. 加入L2标准化 (normalization) 后，线性回归的损失函数的标准形式为：

$$L = (Y - Xw)^T (Y - Xw) + \lambda w^T w \quad \text{其中 } \lambda > 0$$

(1) 假设L2标准化项被误写为 $\lambda Y^T Y$ ，请解释为什么该项起不到标准化的作用。

(2) 假设L2标准化项正确，但 λ 小于0，请解释为什么该项起不到标准化的作用。

10. 考虑下面一个数据集，它记录了某学生多次考试的情况，请根据提供的数据按要求构建决策树。

是否通过考试	是否认真复习	是否超常发挥
是	是	否
是	是	是
是	是	否
是	是	是
是	是	否
是	否	是
否	否	否
否	否	是

(1) 根据信息增益率选择第一个属性，构建一个深度为1的决策树（根结点的深度为1）。

(2) 根据信息增益率构建完整的决策树。请回答，这两个决策树的决策结果是否和训练数据一致，并解释说明。

11. 考虑下面一个数据集：

序号	出去玩	天气状况	有同伴	零花钱	特殊节日	心情指数 (1差~5好)
1	是	好	无	多	是	5
2	是	一般	有	多	是	5
3	是	一般	有	少	否	1
4	是	一般	有	少	否	3
5	是	一般	有	少	否	5
6	是	好	无	多	是	5
7	是	好	无	多	是	5
8	否	一般	无	多	是	1
9	否	一般	有	少	否	1
10	否	一般	无	少	否	5

对于如上数据，考虑使用Ada boosting方法来训练“是否出去玩”强分类器。每个弱分类器可考虑对单个属性的分类，比如对于“心情指数”这一属性，可考虑心情指数 >2 和心情指数 <4 两个方面。请回答下列问题。

- (1) Ada boosting在第一轮迭代中将会选择哪一个弱分类器?
- (2) 第一轮迭代前与迭代后每个样本的权重是多少?
- (3) 第二轮迭代选择的弱分类器是哪一个?, 分类器权重是多少?
- (4) 写出三轮迭代后的强分类器的表达式(每个弱分类器可用字母替代)

*12/ 线性判别分析模型由如下的假设所定义:

$$P(x|y=k) = \frac{e^{\frac{1}{2}(x-\mu_k)^T \Sigma^{-1}(x-\mu_k)}}{\sqrt{2\pi} |\Sigma|^{\frac{1}{2}}}$$

其决策边界由如下的对数几率比值确定:

$$\log \frac{P(y=1|x)}{P(y=0|x)} = \log \frac{P(x|y=1)P(y=1)}{P(x|y=0)P(y=0)}$$

请简要证明线性判别分析的决策边界是线性的。

参考文献

- [1] NG A Y, JORDAN M I. On Discriminative vs. Generative classifiers: A comparison of logistic regression and naive Bayes [J]. NIPS, 2001.
- [2] BAUM L E, PETRIE T. Statistical Inference for Probabilistic Functions of Finite State Markov Chains [J]. The Annals of Mathematical Statistics, 37 (6): 1554–1563, 1966.
- [3] BISHOP C M. Pattern Recognition and Machine Learning [M]. New York: Springer-Verlag inc., 2006.
- [4] BLEI D M, NG A Y, JORDAN M I. Latent dirichlet allocation [J]. Journal of machine Learning research, 3 (4–5): 993–1022, 2003.
- [5] BOYD S, VANDENBERGHE L. Convex optimization [M]. Cambridge: Cambridge University Press, 2004.
- [6] LEO B. Bagging predictors [J]. Machine learning, 24(2): 123–140, 1996.
- [7] CORTEZ P, MORAIS A. A Data Mining Approach to Predict Forest Fires using Meteorological Data [C] // Proceedings of the 13th EPIA 2007– Portuguese Conference on Artificial Intelligence. Associação Portuguesa Para A Inteligência Artificial, 512–523, 2007.
- [8] CORTES, CORINNA, VAPNIK V. Support-vector networks [J]. Machine learning, 20(3): 273–297, 1995.
- [9] COX, DAVID R. The regression analysis of binary sequences [J]. Journal of the Royal Statistical Society: Series B (Methodological), 20(2): 215–232, 1958.
- [10] DAVID B S, et al. Learnability can be undecidable [J]. Nature Machine Intelligence, 1(1): 44–48, 2019.
- [11] DENG, HOUTAO, RUNGER G, et al. Bias of importance measures for multi-valued attributes and solutions [C] // Proceedings of the International Conference on Artificial Neural Networks. Berlin: Springer, 2011.
- [12] FISHER R. The Use of Multiple Measurements in Taxonomic Problems [J]. Annals of Eugenics, 7 (2): 179–188, 1936.
- [13] FREUND, YOAV, ROBERT E. Schapire. Experiments with a new boosting algorithm [J]. International Conference of Machine Learning (ICML), 1996.
- [14] GALTON F. Regression Towards Mediocrity in Hereditary Stature [J]. The Journal of the Anthropological Institute of Great Britain and Ireland, 15: 246–263, 1886.