

习题5

1. 可以从最小化每个类簇的方差这一视角来解释 K -均值聚类の結果,下面对这一视角描述不正确的是()。
 - A. 最终聚类结果中每个聚类集中所包含数据呈现出来的差异性最小
 - B. 每个样本数据分别归属于与其距离最近的聚类质心所在聚类集合
 - C. 每个簇类的方差累加起来最小
 - D. 每个簇类的质心累加起来最小
2. 下面对相关性 (correlation) 和独立性 (independence) 描述不正确的是()。
 - A. 如果两维变量线性不相关,则皮尔逊相关系数等于0
 - B. 如果两维变量彼此独立,则皮尔逊相关系数等于0
 - C. “不相关”是一个比“独立”要强的概念,即不相关一定相互独立
 - D. 独立指两个变量彼此之间不相互影响
3. 下面对主成分分析的描述不正确的是()。
 - A. 主成分分析是一种特征降维方法
 - B. 主成分分析可保证原始高维样本数据被投影映射后,其方差保持最大
 - C. 在主成分分析中,将数据向方差最大方向进行投影,可使得数据蕴含信息没有丢失,以便在后续处理过程中“彰显个性”
 - D. 在主成分分析中,所得低维数据中每一维度之间具有极大相关度
4. 下面对特征人脸算法描述不正确的是()。
 - A. 特征人脸方法是一种应用主成分分析来实现人脸图像降维的方法
 - B. 特征人脸方法是用一种称为“特征人脸 (eigenface)”的特征向量按照线性组合形式来表达每一张原始人脸图像
 - C. 每一个特征人脸的维数与原始人脸图像的维数一样大
 - D. 特征人脸之间的相关度要尽可能大
5. 在潜在语义分析中,给定 M 个单词和 N 个文档所构成的单词-文档矩阵 (term-document) 矩阵,对其进行分解,将单词或文档映射到一个 R 维的隐性空间。下面描述不正确的是()。
 - A. 单词和文档映射到隐性空间后具有相同的维度
 - B. 通过矩阵分解可重建原始单词-文档矩阵,所得到的重建矩阵结果比原始单词-文档矩阵更好捕获了单词-单词、单词-文档、文档-文档之间的隐性关系
 - C. 这一映射过程中需要利用文档的类别信息
 - D. 隐性空间维度的大小由分解过程中所得对角矩阵中对角线上不为零的系数个数所决定
6. 图5.9给出了 K -均值聚类算法的初始状态和后续迭代结果。在图5.9左图给出的初始状态中,圆形代表被聚类数据点、





图5.9 K -均值聚类初始状态及后续迭代聚类结果示意图



方形代表聚类质心。给出后续迭代中聚类质心在对应图中的结果。

7. 说明在 K -均值聚类算法执行的过程中，其目标函数 $\sum_{i=1}^K \sum_{x \in G_i} \|x - c_i\|^2$ 是严格递减的，并解释为什么 K -均值聚类算法可以确保在有限步内收敛。
8. 结合本章5.5.1小节的例子，根据如下5轮（每轮投掷10次硬币）观测的结果，使用EM算法分别估计硬币A和硬币B被投掷为正面的概率。

1	H	H	T	T	T	T	T	H	T	H
2	T	T	H	T	H	H	H	H	T	H
3	T	T	T	T	T	T	T	T	T	T
4	H	T	H	H	H	H	H	H	H	H
5	H	T	T	T	H	H	T	H	H	T

9. EM算法和 K -均值聚类算法有着非常相似的迭代结构，可以说 K -均值聚类算法是EM算法的一种特殊实现。如果将 K -均值聚类中的聚类质心作为隐变量，试从EM算法角度来解释 K -均值聚类算法，即描述 K -均值聚类算法的E步骤和M步骤。
10. 在机器学习中，总体是特定研究任务中所定义的全部个体集合，样本是从总体中选择出来的个体子集。一般使用从包含有限个体数目的样本中所得到的信息来作出描述总体的一般结论。样本方差（sample variance）和总体方差是两个不一样的概念。使用样本均值来估计总体均值是无偏的（unbiased），但使用样本方差 s^2 来估计总体方差 σ^2 却是有偏的（biased）。总体方差 $\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$ ，其中 N 和 μ 分别是总体样本数量和总体均值。假设样本 x 包含了 n 个数据 $\{x_1, x_2, x_3, \dots, x_n\}$ ，在了解下面样本均值是总体均值的无偏估

计以及 $E\left[\frac{1}{n}\sum_{i=1}^n(\bar{x}-x_i)^2\right]=\frac{n-1}{n}\sigma^2$ 的基础上, 证明如果样本方

差定义为 $s^2=\frac{1}{n-1}\sum_{i=1}^n(x_i-\mu)^2$, 则 $E(s^2)=\sigma^2$ 。

a) 样本均值是对总体均值无偏估计的证明过程

证明:

$$\begin{aligned} E[\bar{x}] &= E\left[\frac{x_1+x_2+\cdots+x_n}{n}\right] \\ &= \frac{1}{n}E[x_1+x_2+\cdots+x_n] \\ &= \frac{1}{n}(E[x_1]+E[x_2]+\cdots+E[x_n]) \\ &= \frac{1}{n}(\mu+\mu+\cdots+\mu) \\ &= \frac{n\mu}{n} \\ &= \mu \end{aligned}$$

可见, 样本均值是对总体均值的无偏估计。

$$\text{b) } E\left[\frac{1}{n}\sum_{i=1}^n(\bar{x}-x_i)^2\right]=\frac{n-1}{n}\sigma^2$$

证明:

$$\begin{aligned} E\left[\frac{1}{n}\sum_{i=1}^n(\bar{x}-x_i)^2\right] &= E\left[\frac{1}{n}\sum_{i=1}^n((\bar{x}-\mu)-(x_i-\mu))^2\right] \\ &= E\left[\frac{1}{n}\sum_{i=1}^n((\bar{x}-\mu)^2-2(\bar{x}-\mu)(x_i-\mu)+(x_i-\mu)^2)\right] \\ &= E\left[(\bar{x}-\mu)^2-\frac{2(\bar{x}-\mu)}{n}\sum_{i=1}^n(x_i-\mu)+\frac{1}{n}\sum_{i=1}^n(x_i-\mu)^2\right] \\ &= E\left[(\bar{x}-\mu)^2-2(\bar{x}-\mu)^2+\frac{1}{n}\sum_{i=1}^n(x_i-\mu)^2\right] \\ &= E\left[\frac{1}{n}\sum_{i=1}^n(x_i-\mu)^2\right]-E[(\bar{x}-\mu)^2] \\ &= \sigma^2-\frac{\sigma^2}{n} \\ &= \frac{n-1}{n}\sigma^2 \end{aligned}$$

在上面的证明过程中, 利用了如下的结果:

由于 $E(X^2)=[E(X)]^2+\text{Var}(X)$, $\text{Var}(a+X)=\text{Var}(X)$, $\text{Var}(aX)=a^2\text{Var}(X)$

因此

$$\begin{aligned} E[(\bar{x}-\mu)^2] &= [E(\bar{x}-\mu)]^2+\text{Var}(\bar{x}-\mu)=\text{Var}(\bar{x})=\text{Var}\left(\frac{x_1+x_2+\cdots+x_n}{n}\right) \\ &= \frac{n\sigma^2}{n^2}=\frac{\sigma^2}{n} \end{aligned}$$

从 $E\left[\frac{1}{n}\sum_{i=1}^n(\bar{x}-x_i)^2\right]=\frac{n-1}{n}\sigma^2$ 可知, $\frac{1}{n}\sum_{i=1}^n(\bar{x}-x_i)^2$ 是对总体方差

的一个低估, 因此在用样本方差来代替总体方差时, 需要将

样本方差定义为 $\frac{1}{n-1}\sum_{i=1}^n(x_i-\mu)^2$, 这才能从样本方差出发, 得到总体方差 σ^2 , 这是一个无偏估计。