

作业集 1 参考答案：深度学习基础、模型训练与卷积神经网络

1. 数学神经元与万能逼近定理 (Mathematical Neuron and Universal Approximation Theorem)

1.1 人工神经元基本原理

人工神经元 (Artificial Neuron) 是深度学习构建复杂网络的核心单元。其计算逻辑模拟了生物神经元的信号处理过程，公式化表达为：

$$y = f(\mathbf{w}^T \mathbf{x} + b)$$

其中， $\mathbf{x}$ 为输入向量， $\mathbf{w}$ 为权重向量 (Weights)， b 为偏置项 (Bias)， f 为非线性激活函数 (Activation Function)。

1.2 生物神经元与人工神经元的映射关系

人工神经元的数学步骤与生物组件的对应关系如下表所示：

生物神经元组件	计算步骤对应关系	学术说明
树突 (Dendrites)	输入信号 (Input)	接收来自其他神经元的原始电信号 x_i 。
细胞体 (Soma)	加权求和与处理 (Summation & Processing)	整合输入信号 $\sum w_i x_i + b$ 并通过激活函数判断是否兴奋。
轴突 (Axon)	输出信号 (Output Signal)	将计算后的脉冲信号 y 传递至后续突触。

1.3 万能逼近定理 (Universal Approximation Theorem)

核心定义：万能逼近定理指出，一个包含单层隐藏层和有限数量神经元的前馈网络，只要配备合适的非线性激活函数，理论上可以在任意精度 $\epsilon > 0$ 下逼近定义在实数空间紧集 (Compact Set) 上的任何连续函数。

专家级洞察：

- 非构造性 (Non-constructive)**：该定理仅证明了满足条件的网络存在，但未给出如何寻找最优权重的方法。
- 指数级宽度风险**：对于某些复杂函数，单层网络所需的隐藏层宽度（神经元数量）可能会随输入维度的增加而呈指数级增长。

1.4 增加网络深度的理论动力

在实际工程中，深层架构 (Deep Architectures) 相比浅层宽网络更受青睐，原因如下：

- 参数利用效率**：深层网络能以显著更少的参数量表达相同的复杂映射。研究表明，深度网络在表示某些函数时具有指数级的效率优势。

- 层次化特征学习 (Hierarchical Feature Learning)：网络深度允许模型提取递进式特征。底层学习边缘 (Edges)，中层学习纹理 (Textures)，高层逐步抽象为具体的物体形状 (Objects)，这种结构更符合自然数据的内在规律。

2. 数值反向传播追踪计算 (Numerical Backpropagation Trace)

本节演示如何手动追踪反向传播。设定输入 $x_1 = 2, x_2 = 3$ ，初始权重 $w_1 = 0.11, w_2 = 0.12, w_3 = 0.21, w_4 = 0.08$ （输入层至隐藏层）， $w_5 = 0.14, w_6 = 0.15$ （隐藏层至输出层），目标值 $target = 1$ 。

2.1 前向传播 (Forward Pass)

1. 计算隐藏节点 h_1 ：

$$h_1 = x_1 w_1 + x_2 w_2 = 2(0.11) + 3(0.12) = 0.58$$

2. 计算隐藏节点 h_2 ：

$$h_2 = x_1 w_3 + x_2 w_4 = 2(0.21) + 3(0.08) = 0.66$$

3. 预测值 $pred$ 推导：

$$pred = h_1 w_5 + h_2 w_6 = (0.58 \times 0.14) + (0.66 \times 0.15) = \mathbf{0.1802}$$

2.2 误差计算 (Error Calculation)

采用均方误差公式 (Mean Squared Error)：

$$L = \frac{1}{2}(target - pred)^2 = \frac{1}{2}(1 - 0.1802)^2 \approx \mathbf{0.336}$$

2.3 w_6 的反向传播 (链式法则应用)

计算损失函数 L 对权重 w_6 的偏导数：

- 步骤 1 (误差对预测值的梯度)： $\frac{\partial L}{\partial pred} = -(target - pred) = -(1 - 0.1802) = -0.8198$
- 步骤 2 (预测值对 w_6 的梯度)： $\frac{\partial pred}{\partial w_6} = h_2 = 0.66$
- 步骤 3 (应用链式法则求总梯度)：

$$\frac{\partial L}{\partial w_6} = \frac{\partial L}{\partial pred} \cdot \frac{\partial pred}{\partial w_6} = -0.8198 \times 0.66 = -0.541068$$

2.4 权重更新

在学习率 $lr = 0.5$ 下更新 w_6 ：

1. 计算梯度步长： $\Delta w_6 = lr \cdot \frac{\partial L}{\partial w_6} = 0.5 \times (-0.541068) = -0.270534$
2. 更新权重： $w_6^{new} = w_6 - \Delta w_6 = 0.15 - (-0.270534) = \mathbf{0.4205}$

3. 优化算法与正则化技术 (Optimization and Regularization)

3.1 Adam 与 SGD 的对比

- 随机梯度下降 (SGD): 依靠小批量数据的梯度进行更新。其更新路径包含噪声, 虽有助于跳出浅层局部极小值 (Escape shallow local minima), 但收敛较慢且易在峡谷区域震荡。
- Adam (Adaptive Moment Estimation): 目前深度学习中稳健的默认选择 (Robust default choice)。
 - 动量 (Momentum): 累积历史梯度以平滑更新路径, 抑制震荡。
 - 自适应学习率 (Adaptive LR): 针对各参数的历史梯度缩放学习率, 确保稀疏特征获得足够的更新。

3.2 批量归一化 (Batch Normalization, BN)

操作原理: BN 在 mini-batch 内部对神经元的激活值进行处理, 使其强制服从均值为 0、方差为 1 的分布。

3.3 技术优势与机制

- 稳定训练: 显著减少了内部协变量偏移 (Internal Covariate Shift), 使各层输入分布在训练过程中保持相对稳定。
- 加速收敛: 允许模型使用更高的学习率, 缓解了对初始化的极端敏感性。
- 训练与推理的差异: 训练时使用当前 batch 的统计量; 推理阶段则切换为使用训练期间累积的滚动平均 (Running Averages) 均值和方差, 以保证预测的确定性。

4. 卷积神经网络 (CNN) 机制与效率 (CNN Mechanisms and Efficiency)

4.1 输出尺寸计算

给定输入宽度 $W = 224$ 、卷积核大小 $K = 3$ 、填充 $P = 1$ 、步长 $S = 2$, 输出尺寸计算公式为:

$$W_{out} = \lfloor \frac{W - K + 2P}{S} \rfloor + 1$$
$$W_{out} = \lfloor \frac{224 - 3 + 2(1)}{2} \rfloor + 1 = \lfloor \frac{223}{2} \rfloor + 1 = 111 + 1 = \mathbf{112}$$

4.2 架构效率分析

CNN 相比全连接层 (MLP) 在图像处理上的卓越效率源于以下两大机制:

1. 参数共享 (Parameter Sharing): 在同一个特征图中, 相同的卷积核被复用于整个图像的不同位置。这不仅极大地减少了模型参数, 还赋予了模型平移等变性 (Translation Equivariance)——即无论目标在图像何处, 相同的卷积核都能捕捉到该特征。
2. 稀疏连接 (Sparse Connectivity): 输出层的每个神经元仅与输入层的局部感受野 (Local Receptive Field) 相连。这种设计利用了图像数据的空间局部性 (相邻像素相关性强), 显著降低了计算负担。

4.3 结论

CNN 通过上述机制在保持强大特征提取能力的同时，将参数量压缩至 MLP 的极小比例，使其成为计算机视觉任务的工业标准架构。