

作业集 2 参考答案：Transformer 架构与现代大语言模型前沿

1. 自注意力机制 (Self-Attention Mechanism) 深度解析

自注意力机制是 Transformer 架构的核心，它通过计算序列内各元素之间的相关性，实现了对上下文信息的动态捕捉。

核心公式：

$$\text{attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

核心组件阐述（网页搜索类比）：

- 查询 (Query, Q)**: 类似于你在搜索引擎中输入的“搜索词”。它代表当前单词为了更好地理解自身语义，需要寻找哪些上下文信息（“我要找什么？”）。
- 键 (Key, K)**: 类似于搜索结果中的“网页标题”。它代表序列中每个单词能提供的特征描述，用于与 Q 进行匹配（“我包含什么信息？”）。
- 值 (Value, V)**: 类似于网页的“实际内容”。一旦 Q 与某个 K 匹配成功，模型将提取该 K 对应的 V 信息进行聚合，形成最终的表示。

缩放因子 $\sqrt{d_k}$ 的数学直觉：在点积注意力中，当维度 d_k 较大时， Q 与 K 点积结果的数值量级会剧增。从概率统计角度看，假设 Q 和 K 的分量是均值为 0、方差为 1 的独立随机变量，则它们的点积 QK^T 的均值为 0，方差为 d_k 。若不进行缩放，过大的点积值经过 **softmax** 函数后会进入饱和区，导致梯度极小（梯度消失），模型难以收敛。除以 $\sqrt{d_k}$ 可以将方差重新归一化为 1，确保梯度在训练过程中的稳定性。

2. 架构范式对比：BERT 与 GPT

尽管 BERT 和 GPT 都基于 Transformer，但两者的设计目标决定了它们在下游任务中的不同表现。

技术对比表：

维度	BERT	GPT
架构类型	编码器 (Encoder) 堆叠	解码器 (Decoder) 堆叠
训练目标	MLM (掩码语言) + NSP (下句预测)	自回归 (Autoregressive) 下文预测
上下文方向性	双向 (Bidirectional)	单向 (Unidirectional/Causal)

下游任务优势：BERT 在命名实体识别 (NER)、阅读理解等任务中表现更优。由于其双向性特征，模型在编码每个 token 时能同时捕获左右两侧的上下文。配合 **Next Sentence Prediction (NSP)** 目标，BERT 具备极强的句子级别语义理解能力，能够精准识别词汇在特定语境下的角色。

生成能力：GPT 采用单向自回归特性，即基于历史 token 预测下一个 token。这种预测模式与人类自然语言生成的逻辑完全一致。虽然在理解任务中不如双向模型细腻，但其因果掩码设计使其在长文

本生成、创意写作及逻辑补全任务中具有原生优势。

3. 现代大语言模型 (LLM) 训练管线

现代 LLM 的开发遵循从通用知识获取到特定偏好对齐的严格流程。

三阶段训练流程：

- 预训练 (Pre-training)**：在海量互联网规模数据上学习。通过“预测下一个词”的任务，模型掌握了通用的语言模式、世界知识和基础逻辑。
- 指令微调 (SFT)**：使用高质量的“指令-回答”对（由人工编写或筛选）进行有监督微调。这一阶段赋予了模型理解人类指令并按要求完成任务的“指令遵循”能力。
- 人类偏好对齐 (RLHF/DPO)**：为确保模型输出安全、真实且符合人类价值观。
 - RLHF**：训练奖励模型并使用 PPO 算法优化策略，但计算复杂度高且不稳定。
 - DPO (直接偏好优化)**：作为现代主流替代方案，DPO 无需训练额外的奖励模型，直接在偏好数据上进行优化。其数学逻辑更简洁，训练更加稳定且计算效率更高。

关键概念区分：

- 缩放定律 (Scaling Laws)**：预测性提升。模型性能通常与计算量、参数量及数据规模呈幂律相关。
 - 涌现能力 (Emergent Abilities)**：非线性突破。指当模型规模跨越特定阈值时，突然表现出的复杂能力。典型例子包括：思维链 (Chain-of-thought) 推理、文本内学习 (In-context learning) 以及复杂的代码生成。
-

4. 计算机视觉的前沿：ViT 与 CNN

视觉 Transformer (ViT) 的出现证明了 Transformer 架构在非序列数据上的泛化能力。

机制对比：CNN 利用空间局部性，通过滑动卷积核提取特征。而 ViT 彻底打破卷积范式，将图像视为由一系列“视觉单词”组成的序列。

ViT 处理流程详解：

- 图像分块 (Patches)**：将图像划分为固定大小（如 16×16 ）的小块。
- 向量展平 (Flattening)**：将每个二维小块拉伸为一维向量。
- 线性投影 (Linear Projection)**：通过线性层将展平的向量映射到嵌入空间。
- 添加位置嵌入 (Positional Embeddings)**：补偿因序列化丢失的空间位置信息。
- Transformer 编码器处理**：包含一个特殊的 [CLS] token，其对应位置的输出通常被视为整个图像的全局表示，用于最终分类。

多模态前沿：CLIP CLIP 通过对比学习 (Contrastive Learning)，将图像和文本投影到同一个统一向量空间 (Unified Vector Space) 中。训练目标是最大化匹配对（如图片及其对应描述）的相似度，最小化不匹配对的相似度。这种方法赋予了模型强大的 零样本 (Zero-shot) 分类能力——模型不再需要针对特定标签微调，只需计算图像向量与文本标签向量的相似度即可识别物体。

5. 补充：Transformer 辅助特性 (Auxiliary Features)

这些技术细节共同保证了深层 Transformer 的训练稳定性和性能：

- **残差连接 (Residual Connections)**：通常称为 **Skip Connections**，允许梯度直接流向较浅的层，有效防止深层网络中的梯度消失问题。
- **层归一化 (Layer Normalization)**：现代架构（如 GPT-2/3）普遍采用 **Pre-norm** 模式（在子层之前进行归一化），这比原始的 Post-norm 更能稳定激活值的均值与方差，使模型能承受更高的学习率。
- **GELU 激活函数**：相比于传统的 ReLU，**GELU (Gaussian Error Linear Unit)** 在 0 附近更加平滑，能更好地处理负值，已成为现代 Transformer 的标准配置。
- **Dropout**：在训练阶段随机将部分神经元输出置零，通过引入噪声防止模型对训练数据的过度拟合。