

1 概率论

乘积规则

乘法法则: $\mathbb{P}[E_1 \cap E_2] = \mathbb{P}[E_1 | E_2] \mathbb{P}[E_2] = \mathbb{P}[E_2 | E_1] \mathbb{P}[E_1]$

贝叶斯计算后验


$$\underbrace{p(X = k | E)}_{\text{后验}} = \frac{\overbrace{p(E | X = k)}^{\text{似然}} \overbrace{p(X = k)}^{\text{先验}}}{\underbrace{p(E)}_{\text{边缘似然}}} = \frac{p(E | X = k)p(X = k)}{\sum_{k'=1}^K p(E | X = k')p(X = k')}$$

高斯分布

(3) 高斯分布

也称为正态分布。其概率密度函数 (PDF) 表示为:

$$\mathcal{N}(x | \mu, \sigma^2) \triangleq \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}$$



高斯分布的累积分布函数 (CDF) 定义为:

$$\Phi(x; \mu, \sigma^2) \triangleq \int_{-\infty}^x \mathcal{N}(z | \mu, \sigma^2) dz$$

如果 $\mu = 0$ 且 $\sigma = 1$ (标准正态分布), 我们简记为 $\Phi(x)$ 。



2 逻辑与推理

命题逻辑

- 命题逻辑 (proposition logic) 是应用一套形式化规则对以符号表示的描述性陈述进行推理的系统。
- 在命题逻辑中，一个或真或假的描述性陈述被称为原子命题，对原子命题的内部结构不做任何解析。
- 若干原子命题可通过逻辑运算符来构成复合命题。

谓词逻辑

谓词逻辑：函数与谓词的区别

海洋人工智能基础—谓词逻辑

- 函数中个体变元用个体常量（来自定义域）代入后结果仍是**个体（值域）**，如定义函数 $f(x)=x+10$ ，则 $f(2)=12$
- 谓词中个体变元用个体常量带入后就变成了**命题**，如 $car(x)$ (x 是车)这个谓词中 x 用吉普车代替，则 $car(\text{吉普车})$ 是命题。
- 函数是从定义域到值域的映射；谓词是从定义域到 $\{True, False\}$ 的映射

$P(x)$ 表示: $x < x^2$

- P 是谓词, x 是个体词, x 被称为变量。 x 的具体取值叫个体常项。比如, $P(0.1)$ 和 $P(0.02)$ 使得谓词为假。个体的取值范围为个体域。
- 一般用大写字母 P, Q, R 等来表示谓词。上述 $P(x)$ 描述了是否存在一个数, 这个数小于自身平方这种关系。
- 谓词中可以有若干个个体变量, 如 $\text{father}(x, y)$ 表示 x 是 y 父亲。
- $P(x)$ 是一元谓词 (包含一个个体), $P(x_1, x_2, \dots, x_n)$ 被称为 n 元谓词 (包含若干个个体)。

23

乘积分配规则

因果推理：因果图—链结构

海洋人工智能基础—因果推理

链(chain): 链是因果图的一种基本结构。它包含三个节点两条边, 其中一条边由第一个节点指向第二个节点, 另一条边由第二个节点指向第三个节点。

例 2.22 考虑如下的结构因果模型:

$$U = \{U_1, U_2, U_3\}, \quad V = \{X, Y, Z\}, \quad F = \{f_X, f_Y, f_Z\}$$

$$f_X: X = U_1$$

$$f_Z: Z = 3X + 10 + U_2$$

$$f_Y: Y = 5Z + U_3$$

$$\begin{aligned} P(X, Y | Z) &= \frac{P(X, Y, Z)}{P(Z)} = \frac{P(X)P(Z | X)P(Y | Z)}{P(Z)} \\ &= P(X | Z)P(Y | Z) \end{aligned}$$

即在链式图 $X \rightarrow Z \rightarrow Y$ 中, X 和 Y 在给定 Z 时条件独立。其中, 上式的第一步使用了条件概率的定义, 第二步使用了乘积分解规则, 最后一步使用了贝叶斯公式 $P(X)P(Z | X) = P(Z)P(X | Z) = P(X, Z)$ 。




图2.5 链式因果图

59

在分连结构中，给定 Z 时， X 和 Y 的联合概率：

$$\begin{aligned} P(X, Y | Z) &= \frac{P(X, Y, Z)}{P(Z)} = \frac{P(Z)P(X | Z)P(Y | Z)}{P(Z)} \\ &= P(X | Z)P(Y | Z) \end{aligned}$$

即在分连图 $X \leftarrow Z \rightarrow Y$ 中， X 和 Y 在给定 Z 时条件独立。上式的第一步使用了条件概率的定义，第二步使用了乘积分解规则。

在分连图 $X \leftarrow Z \rightarrow Y$ 中， X 和 Y 在给定 Z 时条件独立可以这样理解：若给定 Z ， Y 和 X 的取值不会变化，它们的值只会分别随 U_3 和 U_2 变化，因此给定 Z 时， Y 和 X 是条件独立的。




图2.6 分连因果图

63

在汇连结构中，给定 Z 时， X 和 Y 的联合概率： $U = \{U_1, U_2, U_3\}$, $V = \{X, Y, Z\}$,

$$\begin{aligned} P(X, Y | Z) &= \frac{P(X, Y, Z)}{P(Z)} = \frac{P(X)P(Y)P(Z | X, Y)}{P(Z)} \\ &\neq P(X | Z)P(Y | Z) \end{aligned}$$

$$\begin{aligned} F &= \{f_X, f_Y, f_Z\} \\ f_X &: X = U_1 \\ f_Y &: Y = U_2 \\ f_Z &: Z = X + Y + U_3 \end{aligned}$$

即在汇连图 $X \rightarrow Z \leftarrow Y$ 中， X 和 Y 在给定 Z 时条件相关。上式的第一步使用了条件概率的定义，第二步使用了乘积分解规则。

在汇连图 $X \rightarrow Z \leftarrow Y$ 中， X 和 Y 在给定 Z 时条件相关可以这样理解：给定 Z ，当 X 的取值发生变化时，为了保证 Z 的取值不变， Y 的取值也一定会发生变化，因而给定 Z 时， Y 和 X 是相关的。 $Z=10$ ， $U_3=1$ ，当 X 取值为3时， Y 的取值为6；当 X 的取值为4时， Y 的取值为5；当 X 取值为8时， Y 的取值为1。也就是说，给定 Z 时， Y 的取值会随 X 的取值变化而变化，因此，给定 Z 时， Y 和 X 是相关的。




图2.7 汇连因果图

66

D -分离(directional separation, d-separation), 可用于判断任意两个节点的相关性和独立性。若存在一条路径将这两个节点 (**直接**) 连通, 则称这两个节点是有向连接(d-connected)的, 即这两个节点是相关的; 若不存在这样的路径将这两个节点连通, 则称这两个节点不是有向连接的, 则称这两个节点是有向分离的(d-separated), 即这两个节点相互独立。

定义 2.18 D -分离: 路径 p 被限定集 Z 阻塞(block)当且仅当:

- (1) 路径 p 含有链结构 $A \rightarrow B \rightarrow C$ 或分连结构 $A \leftarrow B \rightarrow C$ 且中间节点 B 在 Z 中, **或**
- (2) 路径 p 含有汇连结构 $A \rightarrow B \leftarrow C$ 且汇连节点 B 及其后代都不在 Z 中。

若 Z 阻塞了节点 X 和节点 Y 之间的每一条路径, 则称给定 Z 时, X 和 Y 是 D -分离, 即给定 Z 时, X 和 Y 条件独立。

68

例 2.25 分析如下因果图中节点的关系

不妨考虑 X 和 T 的关系:

- (1) 若限定集为 $\emptyset$ 时, X 和 T 相互独立。因为 X 和 T 之间含有一个汇连结构 $X \rightarrow Z \leftarrow Y$, 且 Z 及其后代都不在限定集 $\emptyset$ 中, 此时 X 和 T 是有向分离, 即 X 和 T 相互独立;
- (2) 若限定集为 $\{W\}$ 时, X 和 T 是相关的。因为 X 和 T 之间含有一个链式结构 $Y \rightarrow S \rightarrow T$ (S 不在限定集中), 一个分连结构 $Z \leftarrow Y \rightarrow S$ (Y 不在限定集 $\{W\}$ 中), 一个汇连结构 $X \rightarrow Z \leftarrow Y$ (Z 的后代 W 在限定集 $\{W\}$ 中), 根据 D -分离的定义, 这些结构都无法阻塞 X 和 T 之间的路径, 因此 X 和 T 是有向连接的, 即 X 和 T 是相关的;
- (3) 若限定集为 $\{W, Y\}$ 时, X 和 T 条件独立。因为 X 和 T 之间只有一条路径, 且这条路径含有一个分连结构 $Z \leftarrow Y \rightarrow S$, 且 Y 在限定集 $\{W, Y\}$ 中, 因此 Y 阻塞了 X 和 T 之间的唯一路径, X 和 T 是有向分离, 即限定集为 $\{W, Y\}$ 时, X 和 T 条件独立。




图2.8 包含链、分连和汇连结构的因果图

69

3 搜索

搜索基本概念
(没什么好放的)

贪婪最佳优先搜索

二、贪婪最佳优先搜索与A*搜索算法

人工智能引论

贪婪最佳优先搜索：有信息（informed）搜索或启发式（heuristic）搜索

两个重要函数：评价函数与启发函数

辅助信息	所求解问题之外，与所求解问题相关的特定信息或知识。	
评价函数（evaluation function） $f(n)$	从当前节点 n 出发，根据评价函数来选择后续结点。	下一个结点是谁？
启发函数（heuristic function） $h(n)$	计算从结点 n 到目标结点之间所形成路径的最小代价值，这里将两点之间的直线距离作为启发函数。	完成任务还需要多少代价？

贪婪最佳优先搜索(Greedy best-first search)：评价函数 $f(n)$ =启发函数 $h(n)$




图 3.1 某地区的交通网络图

求取从城市A到城市K之间一条行驶时间最短路线

表 3.2 每个城市到目标城市的直线距离（启发函数取值）

节点	A	B	C	D	E	F	G	H	I	J	K	L
$h(n)$	13	10	6	12	7	8	5	3	6	3	0	6

每个城市到目标城市（即城市K）的直线距离（启发函数取值）

高等教育出版社

A*搜索算法（多了个路径代价函数）

二、贪婪最佳优先搜索与A*搜索算法

人工智能引论

A*搜索算法：评价函数和启发函数各司其职

把从起始结点到当前结点的路径代价在评价函数中予以考虑

$$f(n) = g(n) + h(n)$$

评价函数 (选择后续结点)	$g(n)$ 起始结点到结点 n 代价 (当前最小代价)	+	$h(n)$ 结点 n 到目标结点代价 (后续估计最小代价)
------------------	--------------------------------------	---	--

辅助信息	所求解问题之外，与所求解问题相关的特定信息或知识。	
评价函数（evaluation function） $f(n)$	从当前节点 n 出发，根据评价函数来选择后续结点。	下一个结点是谁？
启发函数（heuristic function） $h(n)$	计算从结点 n 到目标结点之间所形成路径的最小代价值，这里将两点之间的直线距离作为启发函数。	完成任务还需要多少代价？

定义从起始结点到结点 n 的路径代价函数 $g(n)$ ，在此基础上评价函数 $f(n)$ 被修改为： $f(n) = g(n) + h(n)$ ，即评价函数等于从起始结点到结点 n 的实际代价取值与结点 n 到目标结点估计代价取值之和。根据每个结点的评价函数之值不断选择后续结点的搜索算法被称为A*算法

高等教育出版社

表 3.3 本节中使用的若干符号

符号	含义
$h(n)$	结点 n 的启发函数取值
$g(n)$	从起始结点到结点 n 所对应路径的代价
$f(n)$	结点 n 的评价函数取值
$c(n, a, n')$	从结点 n 执行动作 a 到达结点 n' 的单步代价
$h^*(n)$	从结点 n 出发到达终止结点的最小代价

Minimax 搜索，alpha-beta 剪枝算法



三、Minimax搜索与alpha-beta剪枝算法

人工智能引论

alpha-beta剪枝算法示意图




图 3.14 一棵完整的最小最大搜索树




图 3.15 对图 3.14 中搜索树的 alpha-beta 剪枝

4 监督学习

监督学习与无监督学习、强化学习的区别与联系

机器学习：概念与分类

海洋人工智能基础—机器学习

- **监督学习(supervised learning)**
数据有标签、一般为回归或分类等任务
- **无监督学习(un-supervised learning)**
数据无标签、一般为聚类或若干降维任务
- **强化学习(reinforcement learning)**
序列数据决策学习，一般为与从环境交互中学习

半监督学习
(semi-supervised learning)
数

监督学习的基本概念
(没什么好放的)

判别模型和生成模型

- 监督学习方法又可以分为生成方法(Generative Approach)和判别方法(Discriminative Approach)。所学到的模型分别称为生成模型(Generative Model)和判别模型(Discriminative Model)。
- 判别方法直接学习判别函数 $f(\mathbf{X})$ 或者条件概率分布 $P(\mathbf{Y}|\mathbf{X})$ 作为预测的模型，即判别模型。
- 判别模型关心在给定输入数据下，预测该数据的输出是什么。
- 典型判别模型包括回归模型、神经网络、支持向量机和Ada boosting等。

$$f(\text{人脸}) \longrightarrow 0.99$$

$$P(\text{人脸} | \text{人脸}) = 0.99$$

15

16

- 生成模型从数据中学习联合概率分布 $P(X,Y)$ (通过似然概率 $P(X|Y)$ 和类概率 $P(Y)$ 的乘积来求取)

$$P(Y|X) = \frac{P(X,Y)}{P(X)} \quad \text{或者} \quad P(Y|X) = \frac{P(X|Y) \times P(Y)}{P(X)}$$

似然概率：计算导致样本 X 出现的模型参数值

- 典型方法为贝叶斯方法、隐马尔可夫链
- 联合分布概率 $P(X,Y)$ 或似然概率 $P(X|Y)$ 求取很困难

17

17

回归分析：一元线性回归模型参数求解

- 可以看出只要给出了训练样本 $(x_i, y_i) (i = 1, \dots, n)$ ，我们就可以从训练样本出发，建立一个线性回归方程，使得对训练样本数据而言，该线性回归方程预测的结果与样本标注结果之间的差值平方和最小。

这样，对于上面的案例，可以求得参数 a 和 b 分别为：

$$a = \frac{x_1 y_1 + x_2 y_2 + \dots + x_8 y_8 - 8 \bar{x} \bar{y}}{x_1^2 + x_2^2 + \dots + x_8^2 - 8 \bar{x}^2} = 1.428$$

$$b = \bar{y} - a \bar{x} = -7.09$$

- 即预测芒提兹尼欧地区火灾所影响森林面积与气温温度之间的一元线性回归模型为“火灾所影响的森林面积 = $1.428 \times \text{气温温度} - 7.09$ ”，即 $y = 1.428x - 7.09$




图5.5 Sigmoid函数

- 逻辑斯蒂回归(Logistic Regression)就是在回归模型中引入 Sigmoid函数的一种非线性回归模型。Logistic回归模型可如下表示：

$$y = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}}$$

这里 $\frac{1}{1+e^{-z}}$ 是sigmoid函数且 $0 < y < 1$ ， $\mathbf{x} \in \mathbb{R}^d$ 是输入数据， $\mathbf{w} \in \mathbb{R}^d$ 和 $b \in \mathbb{R}$ 是回归函数的参数。

- 投影后两个方差 s_1 和 s_2 分别为 $\mathbf{w}^T \Sigma_1 \mathbf{w}$ 和 $\mathbf{w}^T \Sigma_2 \mathbf{w}$ 。 s_1 和 s_2 可用来衡量同一类别数据样本之间“分散程度”。为了使得归属于同一类别的样本数据在投影后的空间中尽可能靠近，需要最小化 $s_1 + s_2$ 取值。
- 在投影之后的空间中，归属于两个类别的数据样本中心可分别如下计算：

$$m_1 = \mathbf{w}^T \mathbf{m}_1, \quad m_2 = \mathbf{w}^T \mathbf{m}_2$$

- 这样，就可以通过 $(m_2 - m_1)^2$ 来衡量不同类别之间的距离。为了使得归属于不同类别的样本数据在投影后空间中尽可能彼此远离，需要最大化过 $(m_2 - m_1)^2$ 取值。
- 同时考虑上面两点，就得到了需要最大化的目标 $J(\mathbf{w})$ ，定义如下：

$$J(\mathbf{w}) = \frac{(m_2 - m_1)^2}{s_1 + s_2}$$

支持向量机
(看不懂。)


5 无监督学习

无监督学习概念

无监督学习

- 无监督学习就是从无标注数据样本出发，学习数据样本中蕴含的模式，完成如聚类或降维等特定任务。无监督学习在人类学习中占据主导地位：通过观察客观事物洞察其内在秉性，而不是被逐一告知每个客观事物的概念名称。
- “皮之不存，毛将焉附”。在无监督学习中，虽然数据本身没有标注信息，但是由于数据是内容（如概念和语义等）的载体，因此刻画相同内容的数据载体必然具有相似的模式。从这个意义上而言，从无标注数据中挖掘其固有模式，透过数据看本质，就称为无监督学习要解决的主要问题。

无监督学习举例



- 虽然没有对数据进行标注，无监督学习算法根据颜色或形状来将未标注数据归属为两个集合，如把相同颜色数据或者相同形状的数据归属到同样集合中。

K 均值聚类

■ 第一步：初始化聚类质心

■ 第二步：将每个待聚类数据放入唯一一个聚类集合中

■ 第三步：根据聚类结果、更新聚类质心

■ 第四步：算法循环迭代，直到满足条件

■ 在新聚类质心基础上，根据欧氏距离大小，将每个待聚类数据放入唯一一个聚类集合中

■ 根据新的聚类结果、更新聚类质心

聚类迭代满足如下任意一个条件，则聚类停止：

- 已经达到了迭代次数上限
- 前后两次迭代中，聚类质心基本保持不变

K均值聚类算法的不足

- 需要事先确定聚类数目，很多时候我们并不知道数据应被聚类的数目
- 需要初始化聚类质心，初始化聚类中心对聚类结果有较大的影响
- 每个数据只可能属于一个聚簇，而不可能同时属于另一个聚簇，即“硬聚类”
- 算法是迭代执行，时间开销非常大
- 欧氏距离假设数据每个维度之间的重要性是一样的

主成分分析


(讲了方差协方差相关系数)

主成分分析: 算法动机

保证样本
投影后方差最大

- 在数理统计中，方差被经常用来度量数据和其数学期望（即均值）之间偏离程度，这个偏离程度反映了数据分布结构。
- 在许多实际问题中，研究数据和其均值之间的偏离程度有着很重要的意义。
- 在降维之中，需要尽可能将数据向方差最大方向进行投影，使得数据所蕴含信息没有丢失，彰显个性。如左下图所示，向y方向投影（使得二维数据映射为一维）就比向x方向投影结果在降维这个意义上而言要好；右下图则是向黑斜线方向投影要好。

图5.3 PCA降维示意图



特征人脸方法

特征人脸: 算法描述

2: 计算原始人脸样本数据的协方差矩阵: $\Sigma = \frac{1}{n-1} X^T X$

4: 取前 l 个最大特征根所对应特征向量 $w_1, w_2, \dots, w_l$ 组成映射矩阵 W

潜在语义分析


■ 第一步：计算单词-文档矩阵

表5.2 单词-文档 (term-document) 矩阵

[illegible]

第二步：奇异值分解

图5.8 单词-文档矩阵的奇异值分解示意



$$U = \begin{bmatrix} -0.09 & -0.38 & -0.14 & -0.04 & 0.71 & -0.02 & 0.12 & 0.33 & 0.45 & -0. \\ -0.1 & -0.47 & -0.2 & -0.06 & 0. & -0.06 & -0.76 & -0.38 & -0.01 & 0. \\ -0.18 & -0.53 & 0.41 & 0.51 & 0. & -0.14 & 0.16 & 0.09 & -0.42 & -0. \\ -0.28 & -0.08 & 0.57 & -0.23 & -0. & 0.32 & 0.17 & -0.5 & 0.38 & 0. \\ -0.07 & -0.35 & -0.4 & -0.46 & -0. & 0.22 & 0.46 & -0.19 & -0.45 & -0. \\ -0.09 & -0.38 & -0.14 & -0.04 & -0.71 & -0.02 & 0.12 & 0.33 & 0.45 & -0. \\ -0.52 & 0.13 & 0.16 & -0.47 & 0. & -0.65 & -0.04 & 0.16 & -0.11 & -0. \\ -0.45 & 0.16 & -0.32 & 0.34 & -0. & 0.01 & 0.11 & -0.19 & 0.08 & 0.71 \\ -0.45 & 0.16 & -0.32 & 0.34 & -0. & 0.01 & 0.11 & -0.19 & 0.08 & -0.71 \\ -0.42 & 0.1 & 0.09 & -0.11 & -0. & 0.63 & -0.32 & 0.49 & -0.22 & -0. \end{bmatrix}$$

对表5.2中的单词-文档矩阵进行奇异值分解，得到的结果展示。

$$V^T = \begin{bmatrix} -0.15 & -0.18 & -0.1 & -0.06 & -0.11 & -0.21 & -0.58 & -0.49 & -0.54 \\ -0.59 & -0.26 & -0.51 & -0.31 & -0.39 & 0.06 & 0.19 & 0.07 & 0.18 \\ 0.05 & 0.57 & -0.42 & -0.3 & 0.17 & 0.09 & -0.26 & 0.46 & -0.3 \\ 0.27 & 0.18 & -0.37 & -0.33 & 0.32 & -0.31 & 0.13 & -0.54 & 0.38 \\ 0.5 & 0. & -0.5 & 0.5 & -0.5 & 0. & 0. & 0. & -0. \\ -0.19 & 0.15 & 0.11 & 0.16 & -0.14 & -0.53 & -0.52 & 0.25 & 0.53 \\ -0.51 & 0.36 & -0.19 & 0.62 & 0.3 & -0.04 & 0.21 & -0.2 & -0.1 \\ 0.05 & -0.56 & -0.33 & 0.19 & 0.58 & 0.21 & -0.3 & 0.2 & 0.16 \\ 0.07 & -0.27 & -0.07 & 0. & 0.14 & -0.72 & 0.38 & 0.33 & -0.36 \end{bmatrix} D = \begin{bmatrix} 2.46 & 0. & 0. & 0. & 0. & 0. & 0. & 0. & 0. \\ 0. & 2.35 & 0. & 0. & 0. & 0. & 0. & 0. & 0. \\ 0. & 0. & 1.79 & 0. & 0. & 0. & 0. & 0. & 0. \\ 0. & 0. & 0. & 1.51 & 0. & 0. & 0. & 0. & 0. \\ 0. & 0. & 0. & 0. & 1.41 & 0. & 0. & 0. & 0. \\ 0. & 0. & 0. & 0. & 0. & 1.23 & 0. & 0. & 0. \\ 0. & 0. & 0. & 0. & 0. & 0. & 0.93 & 0. & 0. \\ 0. & 0. & 0. & 0. & 0. & 0. & 0. & 0.73 & 0. \\ 0. & 0. & 0. & 0. & 0. & 0. & 0. & 0. & 0.15 \end{bmatrix}$$

第三步：重建矩阵

当 $k=2$ ，即选取最大的前两个特征根及其对应的特征向量对矩阵 A 进行重建。下面给出了选取矩阵 U 、矩阵 D 和矩阵 V 的子部分重建所得矩阵 A_2 ：

$$A_2 = \begin{bmatrix} \text{nonconvex} & a1 & a2 & a3 & a4 & a5 & b1 & b2 & b3 & b4 \\ \text{regression} & 0.56 & 0.27 & 0.49 & 0.3 & 0.37 & -0.01 & -0.05 & 0.05 & -0.05 \\ \text{optimization} & 0.68 & 0.33 & 0.59 & 0.36 & 0.45 & -0.01 & -0.06 & 0.05 & -0.06 \\ \text{network} & 0.79 & 0.4 & 0.68 & 0.41 & 0.53 & 0.02 & 0.02 & 0.14 & 0.02 \\ \text{analysis} & 0.22 & 0.18 & 0.17 & 0.1 & 0.15 & 0.13 & 0.36 & 0.32 & 0.33 \\ \text{minimization} & 0.51 & 0.25 & 0.44 & 0.27 & 0.34 & -0.01 & -0.06 & 0.03 & -0.06 \\ \text{gene} & 0.56 & 0.27 & 0.49 & 0.3 & 0.37 & -0.01 & -0.05 & 0.05 & -0.05 \\ \text{syndrome} & 0.01 & 0.16 & -0.03 & -0.02 & 0.02 & 0.29 & 0.81 & 0.66 & 0.75 \\ \text{editing} & -0.05 & 0.11 & -0.07 & -0.05 & -0.02 & 0.26 & 0.72 & 0.58 & 0.67 \\ \text{human} & -0.05 & 0.11 & -0.07 & -0.05 & -0.02 & 0.26 & 0.72 & 0.58 & 0.67 \end{bmatrix}$$

■ 第四步：挖掘语义关系

- 基于单词-文档矩阵A，可以计算任意两个文档之间的皮尔逊相关系数，从而得到如下文档-文档相关系数矩阵：

$$\begin{pmatrix} a1 & a2 & a3 & a4 & a5 & b1 & b2 & b3 & b4 \\ a1 & 1. & 0.22 & 0.05 & 0.22 & 0.22 & -0.22 & -0.43 & -0.43 & -0.43 \\ a2 & 0.22 & 1. & -0.33 & -0.25 & 0.37 & -0.17 & -0.33 & 0.22 & -0.33 \\ a3 & 0.05 & -0.33 & 1. & 0.22 & 0.22 & -0.22 & -0.43 & -0.43 & -0.43 \\ a4 & 0.22 & -0.25 & 0.22 & 1. & -0.25 & -0.17 & -0.33 & -0.33 & -0.33 \\ a5 & 0.22 & 0.37 & 0.22 & -0.25 & 1. & -0.17 & -0.33 & -0.33 & -0.33 \\ b1 & -0.22 & -0.17 & -0.22 & -0.17 & -0.17 & 1. & 0.51 & 0.51 & -0.22 \\ b2 & -0.43 & -0.33 & -0.43 & -0.33 & -0.33 & 0.51 & 1. & 0.05 & 0.52 \\ b3 & -0.43 & 0.22 & -0.43 & -0.33 & -0.33 & 0.51 & 0.05 & 1. & 0.05 \\ b4 & -0.43 & -0.33 & -0.43 & -0.33 & -0.33 & -0.22 & 0.52 & 0.05 & 1. \end{pmatrix}$$

- 基于重建单词-文档矩阵A₂，可以计算任意两个文档之间的皮尔逊相关系数，从而得到如下文档-文档相关系数矩阵：

$$\begin{pmatrix} a1 & a2 & a3 & a4 & a5 & b1 & b2 & b3 & b4 \\ a1 & 1. & 0.97 & 1. & 1. & 1. & -0.95 & -0.95 & -0.93 & -0.95 \\ a2 & 0.97 & 1. & 0.97 & 0.97 & 0.98 & -0.85 & -0.86 & -0.83 & -0.86 \\ a3 & 1. & 0.97 & 1. & 1. & 1. & -0.95 & -0.96 & -0.94 & -0.96 \\ a4 & 1. & 0.97 & 1. & 1. & 1. & -0.95 & -0.96 & -0.94 & -0.96 \\ a5 & 1. & 0.98 & 1. & 1. & 1. & -0.94 & -0.95 & -0.93 & -0.95 \\ b1 & -0.95 & -0.85 & -0.95 & -0.95 & -0.94 & 1. & 1. & 1. & 1. \\ b2 & -0.95 & -0.86 & -0.96 & -0.96 & -0.95 & 1. & 1. & 1. & 1. \\ b3 & -0.93 & -0.83 & -0.94 & -0.94 & -0.93 & 1. & 1. & 1. & 1. \\ b4 & -0.95 & -0.86 & -0.96 & -0.96 & -0.95 & 1. & 1. & 1. & 1. \end{pmatrix}$$

maximization, EM) 算法^[7]来解决这个问题。

可以证明, E步骤和M步骤的迭代可不断优化模型参数, 使之更拟合数据。EM算法不能保证找到全局的最大值, 有可能找到一个鞍点 (saddle point) [20]。EM算法在统计中具有许多应用, 如机器学习、数据挖掘以及贝叶斯统计, 特别在混合模型的参数估计中应用广泛 [21, 22, 23]。在介绍EM算法的具体内容之前, 先看如下两个例子。

下面介绍两个硬币投掷的例子^[1]。假设有A和B两个硬币，进行5轮掷币实验：在每一轮实验中，先随机选择一个硬币，然后用所选择的硬币投掷10次，将投掷结果作为本轮实验观测结果，如表5.3所示。H代表硬币正面朝上，T代表硬币反面朝上。

1	H	T	T	T	H	H	T	H	T	H
2	H	H	H	H	T	H	H	H	H	H
3	H	T	H	H	H	H	H	T	H	H
4	H	T	H	T	T	T	H	H	T	T
5	T	H	H	H	T	H	H	H	T	H

195 of 359

数，所求取得到的 θ 值应该以最大概率（极大似然）“拟合”表5.3观测结果。

这里要注意的是，表5.3中所列观测结果是不完全数据，即从观测结果只能知道硬币正面或反面，但是并不知道这个正面或反面来自哪一个硬币，因此每一轮中所选择投掷的硬币是一个“隐变量”。由于这个问题中存在隐变量，因此下面采用EM算法来计算硬币A或硬币B被投掷为正面的概率。

1. 求取期望（E步骤，Expectation）

初始化每一轮中硬币A和硬币B投掷为正面的概率为 $\hat{\theta}_A^{(0)} = 0.60$ 和 $\hat{\theta}_B^{(0)} = 0.50$ 。下面根据这个初始化概率，结合5轮实验结果来更新硬币A和硬币B投掷为正面的概率。

在第一轮试验中，所观测得到的投掷结果为“HTTTHHTH”，这10次投掷结果由硬币A投掷所得概率为：

$$\begin{aligned} & P(\text{选择硬币A投掷} | \text{硬币投掷结果}, \theta) \\ &= \frac{P(\text{选择硬币A投掷}, \text{硬币投掷结果} | \theta)}{P(\text{选择硬币A投掷}, \text{硬币投掷结果} | \theta) + P(\text{选择硬币B投掷}, \text{硬币投掷结果} | \theta)} \\ &= \frac{(0.6)^5 \times (0.4)^5}{(0.6)^5 \times (0.4)^5 + (0.5)^{10}} = 0.45 \end{aligned}$$

这10次结果由硬币B投掷所得概率为：

$$\begin{aligned} & P(\text{选择硬币B投掷} | \text{硬币投掷结果}, \theta) \\ &= 1 - P(\text{选择硬币A投掷} | \text{硬币投掷结果}, \theta) \\ &= 0.55 \end{aligned}$$

一旦得到了在第一轮试验中选择硬币A或硬币B投掷的概率，则可以根据这个概率来计算第一轮中硬币A和硬币B投掷正面的期望次数。例如，硬币A为正面期望次数为 $N_{\text{正面总次数}} \times P_{\text{选硬币A概率}} = 5 \times 0.45 = 2.25$ ，其他项计算类似。

同理，可以计算得到其他4轮试验中硬币A和硬币B投掷正面的次数，以及5轮试验中硬币A或硬币B投掷为正面的总次数（见表5.4）。

2. 期望最大化（M步骤，Maximization）

在上面的计算中，通过初始化硬币A和硬币B投掷得到正面概率 $\hat{\theta}_A^{(0)}$ 和 $\hat{\theta}_B^{(0)}$ ，得到每一轮中选择硬币A和选择硬币B概率这一“隐变量”，进而可计算得到每一轮中硬币A和硬币B投掷正面次数。

表5.4 两个硬币在每一轮中被选择概率以及投掷正面/反面的次数

轮次	选硬币A概率	选硬币B概率	硬币A为正面期望次数	硬币A为反面期望次数	硬币B为正面期望次数	硬币B为反面期望次数
1	0.45	0.55	2.25	2.25	2.75	2.75
2	0.80	0.20	7.24	0.80	1.76	0.20
3	0.73	0.27	5.87	1.47	2.13	0.53
4	0.35	0.65	1.41	2.11	2.59	3.89
5	0.65	0.35	4.53	1.94	2.47	1.07
合计			21.30	8.57	11.70	8.43

在这些信息基础上，可更新得到硬币A和硬币B投掷为正面的概率，从而得到新的模型参数：

$$\hat{\theta}_A^{(1)} = \frac{21.30}{21.30 + 8.57} = 0.713 \quad \hat{\theta}_B^{(1)} = \frac{11.70}{11.70 + 8.43} = 0.581$$

接下来，可在新的概率值基础上继续计算每一轮投掷中选择硬币A或硬币B的概率，进而计算得到5轮中硬币A和硬币B投掷正面的总次数，从而得到硬币A和硬币B投掷为正面的更新概率值 $\hat{\theta}_A^{(2)}$ 和 $\hat{\theta}_B^{(2)}$ 。上述算法不断迭代，直至算法收敛，最终得到硬币A和硬币B投掷为正面的概率 $\theta = \{\theta_A, \theta_B\}$ 。

表5.5列出了10次迭代过程中硬币A和硬币B投掷为正面的概率。在第10次迭代时，算法收敛，得到 θ_A 和 θ_B 的值分别为0.797和0.520。

表5.5 两个硬币投掷结果为正面的概率迭代计算结果

迭代次数	硬币A为正面次数	硬币A为反面次数	硬币B为正面次数	硬币B为反面次数	硬币A投掷正面概率 θ_A	硬币B投掷正面概率 θ_B
1	21.30	8.57	11.70	8.43	$\hat{\theta}_A^{(1)} = 0.713$	$\hat{\theta}_B^{(1)} = 0.581$
2	19.21	6.56	13.79	10.44	$\hat{\theta}_A^{(2)} = 0.745$	$\hat{\theta}_B^{(2)} = 0.569$
3	19.41	5.86	13.59	11.14	$\hat{\theta}_A^{(3)} = 0.768$	$\hat{\theta}_B^{(3)} = 0.550$
4	19.75	5.47	13.25	11.53	$\hat{\theta}_A^{(4)} = 0.783$	$\hat{\theta}_B^{(4)} = 0.535$
5	19.98	5.28	13.02	11.72	$\hat{\theta}_A^{(5)} = 0.791$	$\hat{\theta}_B^{(5)} = 0.526$
6	20.09	5.19	12.91	11.81	$\hat{\theta}_A^{(6)} = 0.795$	$\hat{\theta}_B^{(6)} = 0.522$
7	20.14	5.16	12.86	11.84	$\hat{\theta}_A^{(7)} = 0.796$	$\hat{\theta}_B^{(7)} = 0.521$
8	20.16	5.15	12.84	11.85	$\hat{\theta}_A^{(8)} = 0.796$	$\hat{\theta}_B^{(8)} = 0.520$
9	20.17	5.15	12.83	11.85	$\hat{\theta}_A^{(9)} = 0.797$	$\hat{\theta}_B^{(9)} = 0.520$
10	20.18	5.15	12.82	11.85	$\hat{\theta}_A^{(10)} = 0.797$	$\hat{\theta}_B^{(10)} = 0.520$

在上面这个过程中，每一轮选择硬币A还是选择硬币B来完成10次投掷是一个隐变量，硬币A和硬币B投掷结果为正面的概率 $\theta = \{\theta_A, \theta_B\}$ 称为模型参数。

EM算法使用迭代方法来求解模型参数 $\theta = \{\theta_A, \theta_B\}$ ：先初始化模型参数，然后计算得到隐变量（EM算法的E步骤），接着基于观测投掷结果和当前隐变量值一起来最大化似然函数（即使得模型参数能够更好拟合观测结果），更新模型参数（EM算法的M步骤）。基于当前得到的模型参数，继续更新隐变量（EM算法的E步骤），然后继续最大化似然函数，更新模型参数（EM算法的M步骤）。以此类推，不断迭代下去，直到模型参数基本无变化，算法收敛。

5.5.2 三硬币投掷例子

假设有三枚质地材料不均匀的硬币（即每枚硬币投掷出现正反两面的概率不一定相等），这三枚硬币分别标记为0, 1, 2。约定出现正面记为H（head，头），出现反面记为T（tail，尾），一次试验的过程如下：首先掷硬币0，如果硬币0投掷结果为H，则选择硬币1投掷三次，如果硬币0投掷结果为T，则选择硬币2投掷三次。观测结果中仅记录硬币1和硬币2的投掷结果，不出现硬币0的投掷结果。因为硬币0的投掷结果没有被记录，所以是未观测到的数据（隐变量）。

未观测数据取值集合记为 $C_z = \{H, T\}$ ，观测数据取值集合记为 $C_x = \{HHH, TTT, HTT, THH, HHT, TTH, HTH, THT\}$ ，模型参数集合（三枚硬币分别出现正面的概率）为 $\theta = \{\lambda, p_1, p_2\}$ 。在 n 次试验中，未观测到的数据序列记为 z ，观测到的数据序列记为 x ，观测到的数据序列中有 h 次为正面朝上， t 次为反面朝上。易知有下面的式子成立：

$$P(x, z | \theta) = P(z | \theta) P(x | z, \theta)$$

其中

$$P(z | \theta) = \begin{cases} \lambda & \text{当 } z = H \\ 1 - \lambda & \text{当 } z = T \end{cases}$$


$$P(x | z, \theta) = \begin{cases} p_1^h (1 - p_1)^t & \text{当 } z = H \\ p_2^h (1 - p_2)^t & \text{当 } z = T \end{cases}$$

在硬币0掷出正面后，选择硬币1投掷三次所得“反正反”这一结果的概率如下计算：

6 深度学习基础

全是概念，太多了，不如着重看这两题

梯度下降案例



$f(x) = x^2$ 起点 $P(8,64)$, 学习率 $=0.1$,

x_i	8.	6.4	5.12	4.096	3.277	2.622	2.098	1.679	1.343
∇f_i	16.	12.8	10.24	8.192	6.554	5.244	4.196	3.358	...
$x_i - \eta \nabla f_i$	6.4	5.12	4.096	3.277	2.622	2.098	1.679	1.343	...

练一练: 学习率 $=0.2$ 时, 上述曲线梯度下降算法的过程, 并画图 (手工计算)

练一练: 用python实现一个梯度下降算法的函数, 参数为终止条件、学习率、起点

梯度下降案例



【例 7-4】对曲面 $f(x, y) = 3x^2 + 2y^2$ 进行梯度下降法求局部低点, 起点 $P(3, 5)$, 学习率 $\eta = 0.3$, 终止条件 $\|\nabla\| < 0.002$.

解: $\frac{\partial f}{\partial x} = 6x$, $\frac{\partial f}{\partial y} = 4y$.

依次计算, 直到符合条件, 如表 7-5 所示。

表 7-5 例 7-4 中的计算过程


轮次	x	y	$\frac{\partial f}{\partial x}$	$\frac{\partial f}{\partial y}$	$x - \eta \frac{\partial f}{\partial x}$	$y - \eta \frac{\partial f}{\partial y}$	$\ \nabla\ $
1	3	5	18	20	-2.4	-1	724
2	-2.4	-1	-14.4	-4	1.92	0.2	223.4
3	1.92	0.2	11.52	0.8	-1.54	-0.04	133.4
4	-1.54	-0.04	-9.22	-0.16	1.23	8×10^{-3}	85.0
5	1.23	8×10^{-3}	7.37	0.03	-0.98	-1.6×10^{-3}	54.4
6	-0.98	-1.6×10^{-3}	-5.91	-6.4×10^{-3}	0.79	3.2×10^{-4}	34.8
7	0.79	3.2×10^{-4}	4.72	-1.28×10^{-3}	-0.63	-6.4×10^{-5}	22.3

除了上述的标准梯度下降法, 还有一些变体梯度下降法, 如批量梯度下降 (Batch Gradient Descent), 随机梯度下降 (Stochastic Gradient Descent, SGD), 小批量梯度下降 (Mini-batch Gradient Descent)。

思考: 为什么损失函数、激活函数必须是连续可导的?

❖ 梯度下降法问题与限制

- 1、固定学习率, 过犹不及或遥遥无期
- 2、陷入局部最优
- 3、每次都要计算全部样本误差
- 4、损失函数必须连续可导 (不然求不了)





7 多层感知机 (MLP)

多层感知机 (MLP)



多层感知机 (MLP)

- 多层感知机是罗森布拉特标准感知机的扩展。如果以神经元来计算层数，一个多层感知器至少包含三层：一个输入层，一个隐藏层和一个输出层。
- 数据通过输入层进入网络，乘以连接的权重后输入到隐藏层节点。隐藏层节点将这些加权后的输入求和并经过一个非线性变换（称为激活函数）后送往输出层。



- We can it to composite a more complicated function:
$$f(x) = \sigma(W_3\sigma(W_2\sigma(W_1x + b_1) + b_2) + b_3)$$



只有一个隐含层的叫浅层学习网络，隐含层大于一层的叫深度学习网络（深度学习一词的起源）

多层感知机 (MLP)



罗森布拉特
康奈尔大学的实验心理学家
1957年提出感知机模型

- 多层感知器是罗森布拉特标准感知器的扩展。如果以神经元来计算层数，一个多层感知器至少包含三层：一个输入层，一个隐藏层和一个输出层。
- 数据通过输入层进入网络，乘以连接的权重后输入到隐藏层节点。隐藏层节点将这些加权后的输入求和并经过一个非线性变换（称为激活函数）后送往输出层。



- We can it to composite a more complicated function:
$$f(x) = \sigma(W_3\sigma(W_2\sigma(W_1x + b_1) + b_2) + b_3)$$

只有一个隐含层的叫浅层学习网络，隐含层大于一层的叫深度学习网络（深度学习一词的起源）

8 卷积神经网络 (CNN)

图像卷积运算

浙江大学 CS1241G 人工智能基础 (A) (理工农医)

卷积在图像上的具体运算

补0

Image Matrix

Kernel Matrix

Output Matrix

$$\begin{aligned} &0 * 0 + 0 * 0 + -1 * 0 + 0 * 0 \\ &+ 0 * -1 + 105 * 5 + 102 * -1 \\ &+ 0 * 0 + 103 * -1 + 99 * 0 = 320 \end{aligned}$$

13

浙江大学 CS1241G 人工智能基础 (A) (理工农医)

小结 卷积运算运算中的三个主要参数

1 卷积核形状:

3 × 3 5 × 5 7 × 7

2 步长: 决定运算的速度


步长=1 步长=2

3 卷积核数量: 决定每一层能提取的特征数

步长=1 步长=2

15

卷积神经网络概念



18

浙江大學 CS1241G 人工智能基础 (A) (理工农医)

池化

池化 (pooling)：池化也称下采样，其作用就是缩小特征图的尺寸，减少计算量。池化的原理是用某一图像区域子块的统计信息包含了该子块全局信息。池化操作主要有最大池化、平均池化、随机池化、L2范数池化、K-max池化和全局平均池化等。CNN常用 2×2 区域进行池化。

例9-2：对如下特征图进行平均池化计算，池化窗口 2×2 。

最大池化	池化结果	随机池化	池化结果
$\begin{bmatrix} 125 & 115 \\ 137 & 120 \end{bmatrix}$	137	$\begin{bmatrix} 12 & 11 \\ 17 & 10 \end{bmatrix}$	Radom(12,11,17,10)
平均池化	池化结果	L2范数池化	池化结果
$\begin{bmatrix} 33 & 46 \\ 57 & 40 \end{bmatrix}$	44	$\begin{bmatrix} 19 & 15 \\ 26 & 23 \end{bmatrix}$	$\sqrt{19^2 + 15^2 + 26^2 + 23^2}$


23	34	55	32	66	43
15	43	27	30	39	54
33	67	47	28	56	49
56	89	90	35	77	65
54	32	37	48	65	32
63	67	38	43	29	54

$A1 = (23+34+15+43)/4 = 28.75$	$A2 = (55+32+27+30)/4 = 36$	$A3 = (66+43+39+54)/4 = 50.5$
$A4 = (33+67+56+89)/4 = 61.25$	$A5 = (47+28+90+35)/4 = 50$	$A6 = (36+49+77+65)/4 = 56.75$
$A7 = (54+32+63+67)/4 = 54$	$A8 = (37+48+38+43)/4 = 41.5$	$A9 = (65+32+29+54)/4 = 45$

19

为什么要池化：
让特征矩阵变小，并且数据变的更容易处理

展平与独热码



1	2	3
4	5	6
7	8	9



1 2 3 4 5 6 7 8 9

展平：用于将多维的数据降为一维，构建MLP，完成最后的分类任务。

独热码 (One-Hot code)：在分类问题中，我们不能将不同的分类用1,2,3,这种有序的数字来表示，只能通过**独热码**这样的向量矩阵来进行编码，供计算机识别计算，并用所在索引位置的概率值来预测最终的分类结果

	猫	狗	猪	牛	羊		猫	狗	猪	牛	羊	求和
猫	1	0	0	0	0		0.76	0.18	0.03	0.02	0.01	1
狗	0	1	0	0	0		0.05	0.92	0.01	0.01	0.01	1

独热码-编码

前馈网络运算结果

9 循环神经网络 (RNN)

神经网络的分类


三种神经网络

前馈神经网络




多层感知机 MLP
卷积神经网络 CNN

反馈神经网络



循环神经网络 RNN
长短期记忆网络 LSTM
Hopfield网络
波尔兹曼机

图网络




知识图谱
社交网络
城市交通

循环神经网络概念

CS1241G 人工智能基础 (A) (理工农医)

RNN的结构

- 循环神经网络 (**Recurrent Neural Network, RNN**) : 是一种特殊类型的反馈神经网络, 专门用于处理序列数据。
- 核心思想: 循环结构, 网络能捕捉和利用序列中的顺序依赖性信息。



- RNN的基本单元是一个具有循环连接的神经网络层——允许网络在处理每个时间步的数据时, 能利用之前时间步信息。
- 具体地, RNN在每个时间步都会接收一个输入, 并产生一个输出, 同时其内部状态 (隐藏状态) 会被更新并传递到下一个时间步。

表示法一

循环神经网络求解

CS1241G 人工智能基础 (A) (理工农医)

例题

例10-1: 已知拓扑结构为同步多对多RNN (基本结构见图 RNN基本逻辑结构), 输入层、隐含层 (一层)、输出层的神经元均为一个, 激活函数均为 ReLU, $W = [0.5, 0.1, 0.2]$, $H = [1]$, $V = [3]$, $S_0 = 0$, $\alpha = 0$, $\beta = 0$, 对 $X = [1, 1, 1]$, $[2, 2, 2]$, $[3, 3, 3]$ 的输入序列, 计算其输出序列 Y 。

解: $X_1 = [1, 1, 1]$ $X_2 = [2, 2, 2]$ $X_3 = [3, 3, 3]$

$$S_1 = f(W \bullet X_1^T + H \bullet S_0) = f(0.8) = 0.8$$

$$Y_1 = h(V \bullet S_1) = h(2.4) = 2.4$$


$$S_2 = f(W \bullet X_2^T + H \bullet S_1) = f(1.6 + 0.8) = 2.4$$

$$Y_2 = h(V \bullet S_2) = h(7.2) = 7.2$$

$$S_3 = f(W \bullet X_3^T + H \bullet S_2) = f(2.4 + 2.4) = 4.8$$

$$Y_3 = h(V \bullet S_3) = h(14.4) = 14.4$$

$\therefore Y = [2.4, 7.2, 14.4]$



$$Y_t = h(V \bullet S_t + \alpha)$$


$$S_t = f(W \bullet X_t + H \bullet S_{t-1} + \beta)$$

10 博弈论

博弈论诞生

博弈论的诞生：现代博弈论的建立

- 博弈论 (game theory)，又称对策论。
- 博弈行为：带有相互竞争性质的主体，为了达到各自目标和利益，采取的带有对抗性质的行为。
- 博弈论主要研究博弈行为中最优的对抗策略及其稳定局势，协助人们在一定规则范围内寻求最合理的行为方式。
- 1944年冯·诺伊曼与奥斯卡·摩根斯特恩合著《博弈论与经济行为》，以数学形式来阐述博弈论及其应用，标志着现代系统博弈理论的初步形成，冯·诺伊曼被称为现代博弈论之父。



John von Neumann(1903-1957), Oskar Morgenstern(1902-1977), *Theory of Games and Economic Behavior*, Princeton University Press, 1944

博弈论概念

博弈论的相关概念：博弈的要素

- 参与者或玩家 (player)：参与博弈的决策主体
- 策略 (strategy)：参与者可以采取的行动方案，是一整套在采取行动之前就已经准备好的完整方案。
 - 某个参与者可采纳策略的全体组合形成了策略集 (strategy set)
 - 所有参与者各自采取行动后形成的状态被称为局势 (outcome)
 - 如果参与者可以通过一定概率分布来选择若干个不同的策略，这样的策略称为混合策略 (mixed strategy)。若参与者每次行动都选择某个确定的策略，这样的策略称为纯策略 (pure strategy)
- 收益 (payoff)：各个参与者在不同局势下得到的利益
 - 混合策略意义下的收益应为期望收益 (expected payoff)
- 规则 (rule)：对参与者行动的先后顺序、参与者获得信息多少等内容的规定

囚徒困境

博弈论的相关概念：囚徒困境 (prisoner's dilemma)

- 1950年，兰德公司的梅里尔·弗勒德和梅尔文·德雷希尔拟定了相关困境理论，后来美国普林斯顿大学数学家阿尔伯特·塔克以“囚徒方式”阐述：
 - 警方逮捕了共同犯罪的甲、乙两人，由于警方没有掌握充分的证据，所以将两人分开审讯：
 - 若一人认罪并指证对方，而另一方保持沉默，则此人会被当即释放，沉默者会被判监禁10年
 - 若两人都保持沉默，则根据已有的犯罪事实（无充分证据）两人各判半年
 - 若两人都认罪并相互指证，则两人各判5年

	乙沉默（合作）	乙认罪（背叛）
甲沉默（合作）	二人各服刑半年	乙被释放，甲服刑10年
甲认罪（背叛）	甲被释放，乙服刑10年	二人各服刑5年

- 参与者：甲、乙
- 规则：甲、乙两人分别决策，无法得知对方的选择
- 策略集：认罪、沉默（纯策略）
- 局势及对应收益（年）
 - 甲认罪：0 乙沉默：-10
 - 甲认罪：-5 乙认罪：-5
 - 甲沉默：-10 乙认罪：0
 - 甲沉默：-0.5 乙沉默：-0.5
- 在囚徒困境中，最优解为两人同时沉默，但是两人实际倾向于选择同时认罪（均衡解）

纳什均衡

- 博弈的稳定局势即为纳什均衡 (Nash equilibrium)：指的是参与者所作出的这样一种策略组合，在该策略组合上，任何参与者单独改变策略都不会得到好处。换句话说，如果在一个策略组合上，当所有其他人都不会改变策略时，没有人会改变自己的策略，则该策略组合就是一个纳什均衡。
- Nash定理：若参与者有限，每位参与者的策略集有限，收益函数为实值函数，则博弈必存在混合策略意义下的纳什均衡。

遗憾最小化算法（剪刀石头布的例子）

< □ □ + □
🔍 📁 🖋️ 👁️ 📄 ⋮ ▼

↶ ↷
✎ ✏️ 🖍️ 🖌️ 🗑️ 🔄 🖼️ 📏 📐

306

略 σ_i 的概率 $P(\sigma_i^{T+1})$ 为:

$$P(\sigma_i^{T+1}) = \begin{cases} \frac{\text{Regret}_i^{T,+}(\sigma_i)}{\sum_{\sigma'_i \in \Sigma_i} \text{Regret}_i^{T,+}(\sigma'_i)} & \text{当 } \sum_{\sigma'_i \in \Sigma_i} \text{Regret}_i^{T,+}(\sigma'_i) > 0 \\ \frac{1}{|\Sigma_i|} & \text{其他} \end{cases} \quad (\text{式8.3})$$

$|\Sigma_i|$ 表示玩家 i 所有策略的总数。显然，如果在过往 T 轮中策略 σ_i 所带来的遗憾值大、其他策略 σ'_i 所带来的遗憾值小，则在第 $T+1$ 轮选择策略 σ_i 的概率值 $P(\sigma_i^{T+1})$ 就大。也就是说，带来越大遗憾值的策略具有更高的价值，因此其在后续被选择的概率就应该越大。如果没有一个能够提升前 T 轮收益的策略，则在后续轮次中随机选择一种策略。依照一定的概率选择行动是为了防止对手发现自己所采取的策略（如采取遗憾值最大的策略）。

这种遗憾匹配的方式既能启发式地提升接下来博弈中的预期收益，又能利用概率采样的随机性避免被对手猜到自己的策略。

接下来通过石头-布-剪刀（rock-paper-scissors, RPS）的游戏来具体介绍遗憾值最小化算法过程。石头-剪刀-布游戏有两名玩家参加，在博弈时两人同时决策，表8.6给出了这个游戏可能出现的不同局势及收益。

表8.6 石头-剪刀-布游戏的局势及收益 (u_A, u_B)

		玩家B		
		石头(R)	剪刀(S)	布(P)
玩家A	石头(R)	(0, 0)	(1, -1)	(-1, 1)
	剪刀(S)	(-1, 1)	(0, 0)	(1, -1)
	布(P)	(1, -1)	(-1, 1)	(0, 0)

假设第一局时，玩家A出“石头(R)”、玩家B出“布(P)”。从表8.6可见，第一局中玩家A的收益 $u_A(R, P) = -1$ ，玩家B的收益为 $u_B(P, R) = 1$ 。从表8.6所给信息可计算得到玩家A在第一局中没有选择“布”这一策略的遗憾值 $\text{Regret}_A^1(P) = u_A(P, P) - u_A(R, P) = 0 - (-1) = 1$ ，玩家A在第一局中没有选择“剪刀”这一策略的遗憾值 $\text{Regret}_A^1(S) = u_A(S, P) - u_A(R, P) = 1 - (-1) = 2$ 。注意因为玩家A实际选择出石头(R)，所以没有选择出“石头”的遗憾值 $\text{Regret}_A^1(R) = 0$ 。根据遗憾匹配算法，在第一局结束后，玩家A在第二局选择“石头”“剪刀”和“布”

319 of 359

这三个策略的概率分别为 0 、 $\frac{2}{3}$ 、 $\frac{1}{3}$ 。

同时,从表8.6所给信息可计算得到玩家B在第一局中没有选择“石头”这一策略的遗憾值 $Regret_B^1(R) = u_B(R, R) - u_B(R, P) = 0 - 1 = -1$, 玩家B在第一局中没有选择“剪刀”这一策略的遗憾值 $Regret_B^1(S) = u_B(R, S) - u_B(R, P) = -1 - 1 = -2$ 。对玩家B而言, $\sum_{\sigma'_i \in \Sigma_i} Regret_i^{t,*}(\sigma'_i) = -3 < 0$, 因此下一轮中以 $\frac{1}{|\Sigma_i|} = \frac{1}{3}$ 的概率从“石头”“剪刀”和“布”中选择一个策略。

假设玩家A在第二局按照遗憾值最大的策略选择“剪刀”, 玩家B随机选择“石头”, 根据公式 $Regret_A^2(\sigma_i) = \sum_{t=1}^2 (u_A(\sigma_i, \sigma'_t) - u_A(\sigma'_t))$ 可计算得到玩家A的累加遗憾值(如表8.7所示)。

表8.7 玩家A在两轮后所得到的遗憾值

遗憾值/策略	石头	剪刀	布
第一轮	0	2	1
第二轮	1	0	2
$Regret_A^2$	1	2	3

从上表可知, 前二局结束后, 在第三局时, 玩家A选择“石头”“剪刀”和“布”的概率分别为 $\frac{1}{6}$ 、 $\frac{2}{6}(\frac{1}{3})$ 、 $\frac{3}{6}(\frac{1}{2})$ 。需要注意的是, 玩家A既可以按照遗憾值最小在第三轮来选择“布”这一策略, 又可以随机选择“石头”或“剪刀”以防止自己的策略被对手察觉。

遗憾最小化算法在实际使用中需要反复模拟博弈多次, 才能拟合到近似的最优反应策略。当然, 并不是所有的博弈都像石头-剪刀-布游戏这样一次决策就可以得出胜负, 对于围棋和扑克等需要多次决策才能判断胜负的博弈问题, 那么应该怎么办呢?

为了解决这个问题, 需要计算状态转移序列中每个状态的“虚拟遗憾值”, 这就是虚拟遗憾值最小化算法(counterfactual regret minimization)^[7]。

对于任何序贯决策的博弈对抗, 可将博弈过程表示成一棵博弈树, 博弈树中的每一个中间结点都是一个信息集 I , 信息集中包含了博弈中当前的状态。给定博弈树的每一个结点, 玩家都可以从一系列的动作中选择一个, 然后状态发生转换, 如此周而复始, 直到终局(博弈树的叶子

11 强化学习

马尔可夫过程

(参考朱江样题文档问题 17)