

《海洋人工智能基础》期末复习资料

0. 复习总说明

今年课程考试范围需要按照老师最新说明和 2026 版复习大纲来复习。

老师原话重点可以整理为：

1. 今年由李伟昌老师代替张帆老师讲深度学习。
2. 张帆老师样题中的梯度下降内容参考性不大。
3. 其他两部分由朱江老师和韩业辉老师出题。
4. 去年考过强化学习，但今年没有强化学习考试内容。
5. 今年复习应重点围绕：
 - 朱江老师部分：概率论、逻辑与推理、监督学习、智能体。
 - 韩业辉老师部分：搜索、无监督学习、博弈论。
 - 李伟昌老师部分：深度学习。

1. 总体学习路径

1.1 最推荐学习顺序

对于一个从 0 开始、但马上考试的同学，不建议按教材原顺序从头到尾慢慢看，而应该按照“考试最可能出题、最容易形成解题模板、最容易拿分”的顺序学习。

推荐顺序如下：

- 1 概率论与贝叶斯
- 2 → 高斯分布与高斯后验
- 3 → 逻辑与推理
- 4 → 搜索算法
- 5 → 无监督学习
- 6 → 博弈论
- 7 → 监督学习
- 8 → 深度学习
- 9 → 智能体

理由如下：

1. 概率论和高斯分布是朱江老师部分的核心，分值高，题型稳定。
2. 逻辑证明题套路明显，掌握公式和推理规则后容易拿分。
3. 搜索算法、K-means、PCA、EM、博弈论都是韩老师样题重点。
4. 监督学习概念较多，但考试通常围绕公式和概念辨析。
5. 深度学习今年换老师，不能完全押张帆样题，但 CNN/RNN/MLP 等基础必须掌握。
6. 智能体更偏概念题，适合考前背诵。

1.2 模块优先级

优先级	模块	学习重点
S	贝叶斯、高斯后验、联合高斯	大题高频，公式固定
S	贪婪搜索、A*、Minimax、alpha-beta	韩老师样题重点
S	K-means、PCA、EM	韩老师样题重点
A	命题逻辑、谓词逻辑	证明题模板明显
A	线性回归、Logistic 回归、SVM	大纲明确要求
A	CNN 输出尺寸、RNN 递推	深度学习基础计算
B	特征人脸、LSA、智能体	偏概念理解
C	强化学习、d 分离、因果推理	今年不作为主线复习

2. 概率论

概率论是整门课最重要的数学基础之一。考试中常见问题包括：

1. 根据证据计算后验概率。
2. 判断条件独立。
3. 计算随机变量线性变换后的均值和协方差。
4. 推导方差、协方差公式。
5. 计算高斯先验和高斯观测下的后验。
6. 根据高斯分布构造分类器。

2.1 随机变量

随机变量不是“随机的变量名”，而是把随机事件的结果映射成数字的函数。

例如抛硬币：

1	正面 → 1
2	反面 → 0

可以定义随机变量：

$$X = \begin{cases} 1, & \text{正面} \\ 0, & \text{反面} \end{cases}$$

再如掷骰子：

$$X \in \{1, 2, 3, 4, 5, 6\}$$

其中：

$$P(X = 1) = \frac{1}{6}$$

$$P(X = 2) = \frac{1}{6}$$

2.2 概率基本性质

概率满足：

$$0 \leq P(A) \leq 1$$

$$P(\Omega) = 1$$

如果事件 A 和 B 互斥：

$$A \cap B = \emptyset$$

则：

$$P(A \cup B) = P(A) + P(B)$$

如果事件不互斥：

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

其中：

- $A \cup B$ 表示 A 或 B 发生。
- $A \cap B$ 表示 A 和 B 同时发生。

2.3 条件概率

条件概率表示：

在某个事件已经发生的前提下，另一个事件发生的概率。

定义：

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

其中：

$$P(B) > 0$$

例如：

- A ：今天堵车。
- B ：今天下雨。

那么：

$$P(A|B)$$

表示“已知今天下雨的情况下，今天堵车的概率”。

2.4 乘积规则

由条件概率定义：

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

两边乘以 $P(B)$ ：

$$P(A \cap B) = P(A|B)P(B)$$

同理：

$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$

所以：

$$P(A \cap B) = P(B|A)P(A)$$

因此乘积规则为：

$$P(A \cap B) = P(A)P(B|A) = P(B)P(A|B)$$

这个公式非常重要，因为贝叶斯公式就是从这里推出来的。

2.5 贝叶斯公式

由乘积规则：

$$P(A \cap B) = P(A)P(B|A)$$

又有：

$$P(A \cap B) = P(B)P(A|B)$$

所以：

$$P(A)P(B|A) = P(B)P(A|B)$$

得到：

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

这就是贝叶斯公式。

2.6 贝叶斯公式中的四个概念

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

符号	名称	含义
$P(A)$	先验 prior	看到证据 B 之前，对 A 的相信程度

符号	名称	含义
$P(B A)$	似然 likelihood	如果 A 为真, 观察到 B 的概率
$P(B)$	证据 evidence	观察到 B 的总概率
$P(A B)$	后验 posterior	看到 B 之后, 对 A 的相信程度

考试记忆:

$$\text{后验} \propto \text{似然} \times \text{先验}$$

也就是:

$$P(A|B) \propto P(B|A)P(A)$$

2.7 离散随机变量的后验向量

假设:

$$H \in \{1, 2, \dots, K\}$$

我们观察到两个证据:

$$e_1, e_2$$

需要计算:

$$P(H|e_1, e_2) = (P(H = 1|e_1, e_2), P(H = 2|e_1, e_2), \dots, P(H = K|e_1, e_2))$$

根据贝叶斯公式:

$$P(H = k|e_1, e_2) = \frac{P(e_1, e_2|H = k)P(H = k)}{P(e_1, e_2)}$$

其中:

$$P(e_1, e_2) = \sum_{j=1}^K P(e_1, e_2|H = j)P(H = j)$$

所以:

$$P(H = k|e_1, e_2) = \frac{P(e_1, e_2|H = k)P(H = k)}{\sum_{j=1}^K P(e_1, e_2|H = j)P(H = j)}$$

这是离散贝叶斯后验计算的标准模板。

2.8 条件独立

如果给定 H 时, E_1 和 E_2 条件独立, 则:

$$P(E_1, E_2|H) = P(E_1|H)P(E_2|H)$$

直观理解:

一旦知道了 H , E_1 和 E_2 之间就不再互相提供额外信息。

于是后验公式可以简化为：

$$P(H = k|e_1, e_2) = \frac{P(e_1|H = k)P(e_2|H = k)P(H = k)}{\sum_{j=1}^K P(e_1|H = j)P(e_2|H = j)P(H = j)}$$

这类题的关键就是判断题目是否给了条件独立。

2.9 独立与条件独立的区别

普通独立：

$$P(X, Y) = P(X)P(Y)$$

条件独立：

$$P(X, Y|Z) = P(X|Z)P(Y|Z)$$

两者不是一回事。

普通独立表示 X 和 Y 本身没有关系。

条件独立表示：在不知道 Z 的时候 X 和 Y 可能相关；但知道 Z 之后，它们就不再相关。

例如：

- Z ：下雨。
- X ：地面湿。
- Y ：有人打伞。

不知道是否下雨时，地面湿和有人打伞相关。

但如果已经知道下雨，则二者之间的额外关系可能变弱。

2.10 期望

离散随机变量的期望：

$$E[X] = \sum_x xP(X = x)$$

连续随机变量的期望：

$$E[X] = \int_{-\infty}^{+\infty} xp(x) dx$$

期望可以理解为长期平均值。

例如掷骰子：

$$\begin{aligned} E[X] &= 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} \\ E[X] &= \frac{1 + 2 + 3 + 4 + 5 + 6}{6} = 3.5 \end{aligned}$$

注意：期望不一定是随机变量能实际取到的值。骰子点数不会等于 3.5，但长期平均是 3.5。

2.11 方差

方差衡量随机变量围绕均值波动的程度。

定义：

$$\text{Var}(X) = E[(X - E[X])^2]$$

也可以写成：

$$\text{Var}(X) = E[X^2] - (E[X])^2$$

如果方差大，说明数据分散。

如果方差小，说明数据集中。

2.12 协方差

协方差衡量两个变量一起变化的趋势。

定义：

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$$

如果：

$$\text{Cov}(X, Y) > 0$$

说明 X 大时， Y 往往也大，二者正相关。

如果：

$$\text{Cov}(X, Y) < 0$$

说明 X 大时， Y 往往小，二者负相关。

如果：

$$\text{Cov}(X, Y) = 0$$

说明二者线性不相关。

注意：

协方差为 0 不一定代表独立。

但如果 X, Y 服从联合高斯分布，则协方差为 0 可以推出独立。

2.13 方差和协方差公式推导

考试常考：

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

推导如下：

$$\text{Var}(X + Y) = E[(X + Y - E[X + Y])^2]$$

因为：

$$E[X + Y] = E[X] + E[Y]$$

所以：

$$Var(X + Y) = E[((X - E[X]) + (Y - E[Y]))^2]$$

展开平方：

$$= E[(X - E[X])^2 + (Y - E[Y])^2 + 2(X - E[X])(Y - E[Y])]$$

利用期望线性：

$$= E[(X - E[X])^2] + E[(Y - E[Y])^2] + 2E[(X - E[X])(Y - E[Y])]$$

所以：

$$Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y)$$

2.14 随机向量线性变换

设：

$$E[x] = \mu$$

$$Cov[x] = \Sigma$$

定义：

$$y = Ax + b$$

则：

$$E[y] = A\mu + b$$

$$Cov[y] = A\Sigma A^T$$

推导：

$$E[y] = E[Ax + b] = AE[x] + b = A\mu + b$$

协方差：

$$Cov[y] = E[(y - E[y])(y - E[y])^T]$$

因为：

$$y - E[y] = Ax + b - (A\mu + b) = A(x - \mu)$$

所以：

$$Cov[y] = E[A(x - \mu)(x - \mu)^T A^T]$$

$$Cov[y] = AE[(x - \mu)(x - \mu)^T]A^T$$

$$Cov[y] = A\Sigma A^T$$

记忆：

均值跟着线性变换走。

协方差左乘 A ，右乘 A^T ，不受平移 b 影响。

2.15 高斯分布

一维高斯分布写作：

$$X \sim N(\mu, \sigma^2)$$

概率密度函数：

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

其中：

- μ ：均值，决定中心位置。
- σ^2 ：方差，决定分布宽窄。
- σ ：标准差。

标准正态分布：

$$N(0, 1)$$

2.16 多维高斯分布

多维高斯写作：

$$x \sim N(\mu, \Sigma)$$

其中：

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$

$$\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_d \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} \text{Var}(x_1) & \text{Cov}(x_1, x_2) & \cdots & \text{Cov}(x_1, x_d) \\ \text{Cov}(x_2, x_1) & \text{Var}(x_2) & \cdots & \text{Cov}(x_2, x_d) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(x_d, x_1) & \text{Cov}(x_d, x_2) & \cdots & \text{Var}(x_d) \end{bmatrix}$$

多维高斯密度：

$$p(x) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left[-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)\right]$$

2.17 二维联合高斯

若：

$$\begin{bmatrix} X \\ Y \end{bmatrix} \sim N \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{bmatrix} \right)$$

其中：

$$\text{Cov}(X, Y) = \rho\sigma_X\sigma_Y$$

如果：

$$\rho = 0$$

则 X, Y 不相关。

对于联合高斯来说，不相关可以推出独立。

2.18 高斯边缘分布

如果：

$$\begin{bmatrix} X \\ Y \end{bmatrix} \sim N \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix} \right)$$

那么边缘分布为：

$$X \sim N(\mu_X, \Sigma_{XX})$$

$$Y \sim N(\mu_Y, \Sigma_{YY})$$

意思是：联合高斯中只看其中一部分变量，它仍然是高斯分布。

2.19 高斯条件分布

设：

$$\begin{bmatrix} X \\ Y \end{bmatrix} \sim N \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix} \right)$$

则：

$$X|Y = y \sim N(\mu_{X|Y}, \Sigma_{X|Y})$$

其中：

$$\mu_{X|Y} = \mu_X + \Sigma_{XY}\Sigma_{YY}^{-1}(y - \mu_Y)$$

$$\Sigma_{X|Y} = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}$$

直观理解：

- 观察到 $Y = y$ 后，可以利用 X 和 Y 的相关性修正对 X 的估计。
- 后验协方差通常变小，因为观测带来了新信息。

2.20 高斯先验 + 高斯噪声观测

这是考试非常重要的题型。

设：

$$x \sim N(\mu, \sigma^2)$$

测量模型：

$$y = x + w$$

其中噪声：

$$w \sim N(0, \sigma_w^2)$$

则似然为：

$$p(y|x) = N(y; x, \sigma_w^2)$$

也就是：

$$p(y|x) = \frac{1}{\sqrt{2\pi\sigma_w^2}} \exp \left[-\frac{(y-x)^2}{2\sigma_w^2} \right]$$

后验：

$$p(x|y) \propto p(y|x)p(x)$$

因为先验和似然都是高斯，所以后验仍是高斯：

$$p(x|y) = N(\mu_{post}, \sigma_{post}^2)$$

后验方差：

$$\frac{1}{\sigma_{post}^2} = \frac{1}{\sigma^2} + \frac{1}{\sigma_w^2}$$

所以：

$$\sigma_{post}^2 = \frac{\sigma^2 \sigma_w^2}{\sigma^2 + \sigma_w^2}$$

后验均值：

$$\mu_{post} = \sigma_{post}^2 \left(\frac{\mu}{\sigma^2} + \frac{y}{\sigma_w^2} \right)$$

化简：

$$\mu_{post} = \frac{\sigma_w^2 \mu + \sigma^2 y}{\sigma^2 + \sigma_w^2}$$

2.21 高斯后验的直观理解

后验均值：

$$\mu_{post} = \frac{\sigma_w^2 \mu + \sigma^2 y}{\sigma^2 + \sigma_w^2}$$

如果测量噪声很小：

$$\sigma_w^2 \rightarrow 0$$

则：

$$\mu_{post} \rightarrow y$$

说明测量非常可靠，所以更相信测量值。

如果先验方差很小：

$$\sigma^2 \rightarrow 0$$

则：

$$\mu_{post} \rightarrow \mu$$

说明先验非常可靠，所以更相信先验均值。

后验方差：

$$\sigma_{post}^2 = \frac{\sigma^2 \sigma_w^2}{\sigma^2 + \sigma_w^2}$$

满足：

$$\sigma_{post}^2 \leq \sigma^2$$

$$\sigma_{post}^2 \leq \sigma_w^2$$

说明融合观测后，不确定性变小。

2.22 次序统计量：最左侧点期望

题目：

 X, Y 从 $[0, 1]$ 中独立均匀抽取，最左侧点的期望位置是多少？

设：

$$M = \min(X, Y)$$

则：

$$P(M > m) = P(X > m, Y > m)$$

由于 X, Y 独立：

$$P(M > m) = P(X > m)P(Y > m)$$

又因为 $X, Y \sim U(0, 1)$ ：

$$P(X > m) = 1 - m$$

$$P(Y > m) = 1 - m$$

所以：

$$P(M > m) = (1 - m)^2$$

于是：

$$F_M(m) = P(M \leq m) = 1 - (1 - m)^2$$

求导：

$$f_M(m) = 2(1 - m)$$

期望：

$$E[M] = \int_0^1 m f_M(m) dm$$

$$E[M] = \int_0^1 2m(1 - m) dm$$

$$E[M] = 2 \int_0^1 (m - m^2) dm$$

$$E[M] = 2 \left(\frac{1}{2} - \frac{1}{3} \right)$$

$$E[M] = \frac{1}{3}$$

所以最左侧点的期望位置为：

$$\boxed{\frac{1}{3}}$$

3. 逻辑与推理

今年逻辑与推理重点是：

1. 命题逻辑。
2. 谓词逻辑。
3. 逻辑等价变形。
4. 简单证明题。

不做主线复习：

1. 因果推理。
2. d 分离。

3.1 命题逻辑

命题是能够判断真假的陈述句。

例如：

- “今天下雨”是命题。
- “2 是偶数”是命题。
- “请关门”不是命题。
- “这个数很大”通常不是严格命题，因为真假不明确。

命题常用字母表示：

$$P, Q, R$$

例如：

$$P = \text{今天下雨}$$

$$Q = \text{我带伞}$$

3.2 命题联结词

名称	符号	含义
非	$\neg P$	P 不成立
与	$P \wedge Q$	P 和 Q 都成立
或	$P \vee Q$	P 或 Q 至少一个成立
蕴含	$P \rightarrow Q$	如果 P, 则 Q
双向蕴含	$P \leftrightarrow Q$	P 当且仅当 Q

3.3 蕴含的真值表

P	Q	$P \rightarrow Q$
T	T	T
T	F	F
F	T	T
F	F	T

注意：

$$F \rightarrow T = T$$

$$F \rightarrow F = T$$

蕴含命题只在“前件真、后件假”时为假。

3.4 常用逻辑等价式

3.4.1 蕴含消去

$$P \rightarrow Q \equiv \neg P \vee Q$$

这是最重要的等价式。

3.4.2 逆否命题

$$P \rightarrow Q \equiv \neg Q \rightarrow \neg P$$

3.4.3 德摩根律

$$\neg(P \wedge Q) \equiv \neg P \vee \neg Q$$

$$\neg(P \vee Q) \equiv \neg P \wedge \neg Q$$

记忆：

非进去，与变或，或变与。

3.4.4 双重否定

$$\neg(\neg P) \equiv P$$

3.4.5 分配律

$$P \wedge (Q \vee R) \equiv (P \wedge Q) \vee (P \wedge R)$$

$$P \vee (Q \wedge R) \equiv (P \vee Q) \wedge (P \vee R)$$

3.5 谓词逻辑

命题逻辑只能处理整个句子，而谓词逻辑可以处理对象和对象的性质。

例如：

$$Student(x)$$

表示：

x 是学生。

$$Likes(x, y)$$

表示：

x 喜欢 y 。

3.6 全称量词与存在量词

全称量词：

$$\forall x P(x)$$

表示：

对所有 x , $P(x)$ 都成立。

存在量词：

$$\exists x P(x)$$

表示：

存在至少一个 x ，使得 $P(x)$ 成立。

例如：

$$\forall x (Student(x) \rightarrow Study(x))$$

表示：

所有学生都会学习。

$$\exists x (Student(x) \wedge LikesAI(x))$$

表示：

存在一个学生喜欢人工智能。

3.7 量词否定

最重要的量词变形：

$$\neg \forall x P(x) \equiv \exists x \neg P(x)$$

$$\neg \exists x P(x) \equiv \forall x \neg P(x)$$

记忆：

否定穿过量词时，全称变存在，存在变全称，里面取反。

3.8 谓词逻辑证明模板

假设：

$$\forall x (F(x) \rightarrow (G(x) \vee H(x)))$$

以及：

$$\neg \forall x (F(x) \rightarrow G(x))$$

证明：

$$\exists x (F(x) \wedge H(x))$$

第一步：处理第二个条件

$$\neg \forall x (F(x) \rightarrow G(x))$$

量词否定：

$$\exists x \neg (F(x) \rightarrow G(x))$$

蕴含消去：

$$F(x) \rightarrow G(x) \equiv \neg F(x) \vee G(x)$$

所以：

$$\neg(F(x) \rightarrow G(x)) = \neg(\neg F(x) \vee G(x))$$

根据德摩根律：

$$= F(x) \wedge \neg G(x)$$

所以存在某个 a ，使得：

$$F(a) \wedge \neg G(a)$$

因此：

$$F(a)$$

且：

$$\neg G(a)$$

第二步：使用第一个条件

由：

$$\forall x(F(x) \rightarrow (G(x) \vee H(x)))$$

得到：

$$F(a) \rightarrow (G(a) \vee H(a))$$

因为：

$$F(a)$$

所以：

$$G(a) \vee H(a)$$

又因为：

$$\neg G(a)$$

所以：

$$H(a)$$

第三步：得到结论

已有：

$$F(a)$$

和：

$$H(a)$$

所以：

$$F(a) \wedge H(a)$$

因此：

$$\exists x(F(x) \wedge H(x))$$

4. 搜索算法

搜索算法是韩业辉老师样题重点。

核心内容：

- 1. 搜索问题的组成。
- 2. 搜索树。
- 3. 完备性、最优性、时间复杂度、空间复杂度。
- 4. 贪婪最佳优先搜索。
- 5. A* 搜索。
- 6. Minimax 搜索。
- 7. alpha-beta 剪枝。
- 8. 蒙特卡洛树搜索。

4.1 搜索问题的组成

一个搜索问题通常由以下部分组成：

组成	含义
初始状态	从哪里开始
动作集合	每一步可以做什么
状态转移	执行动作后到哪里
目标测试	判断是否到达目标
路径代价	一条路径的总花费


例如地图导航：

- 初始状态：杭州。
- 目标状态：上海。
- 动作：从一个城市开车到另一个城市。
- 路径代价：距离或时间。
- 目标测试：是否到达上海。

4.2 搜索树

搜索树把所有可能的行动展开成树形结构。

例如：



其中：

- 根节点是初始状态。
- 边表示动作。
- 子节点表示执行动作后的新状态。
- 从根到某个节点的一条路径表示一个行动序列。

4.3 搜索算法评价指标

4.3.1 完备性

完备性表示：

如果问题有解，算法是否一定能找到解？

例如：

- BFS 在有限分支、有限深度下是完备的。
- DFS 在无限深度空间中可能不完备。

4.3.2 最优性

最优性表示：

算法找到的解是否一定是代价最小的解？

例如：

- BFS 在每步代价相同时可以找到最短路径。
- 贪婪搜索通常不保证最优。
- A* 在启发函数满足条件时可以保证最优。

4.3.3 时间复杂度

时间复杂度表示算法需要扩展多少节点。

如果分支因子为 b ，目标深度为 d ，搜索复杂度常写作：

$$O(b^d)$$

4.3.4 空间复杂度

空间复杂度表示算法需要存储多少节点。

BFS 通常空间复杂度较高，因为它要保存整层节点。

DFS 通常空间复杂度较低，因为它只需要保存当前路径。

4.4 启发函数

启发函数记为：

$$h(n)$$

表示：

从当前节点 n 到目标节点的估计代价。

例如地图中可以用直线距离作为启发函数。

启发函数不是准确值，而是估计值。

4.5 路径代价函数

路径代价记为：

$$g(n)$$

表示：

从起点到当前节点 n 已经花费的真实代价。

4.6 贪婪最佳优先搜索

贪婪搜索只看启发函数：

$$f(n) = h(n)$$

它每次选择看起来离目标最近的节点。

优点：

1. 速度可能很快。
2. 实现简单。

缺点：

1. 不保证最优。
 2. 容易被错误启发函数误导。
 3. 可能陷入局部最优。
-

4.7 A* 搜索

A* 搜索使用：

$$f(n) = g(n) + h(n)$$

其中：

- $g(n)$ ：从起点到当前节点的真实代价。
- $h(n)$ ：从当前节点到目标的估计代价。
- $f(n)$ ：从起点经过当前节点到目标的估计总代价。

A* 的思想：

既考虑已经花了多少，也考虑未来可能还要花多少。

4.8 贪婪搜索与 A* 的区别

对比	贪婪最佳优先搜索	A* 搜索
评价函数	$f(n) = h(n)$	$f(n) = g(n) + h(n)$
是否考虑已走代价	不考虑	考虑
是否考虑未来估计代价	考虑	考虑
是否保证最优	通常不保证	在条件满足时保证
特点	贪快	更稳健

一句话记忆：

贪婪搜索只看离终点近不近，A* 同时看已经走了多少和还要走多少。

4.9 可采纳启发函数

如果：

$$h(n) \leq h^*(n)$$

则称 $h(n)$ 是可采纳的。

其中：

- $h(n)$ 是估计代价。
- $h^*(n)$ 是真实最优代价。

可采纳的意思是：

启发函数永远不高估真实代价。

如果启发函数可采纳，A* 树搜索可以保证最优。

4.10 一致启发函数

一致性条件：

$$h(n) \leq c(n, a, n') + h(n')$$

其中：

- $c(n, a, n')$ 是从 n 到 n' 的单步代价。
- $h(n)$ 是当前节点到目标的估计。
- $h(n')$ 是后继节点到目标的估计。

一致性比可采纳性更强。

如果启发函数一致，则图搜索 A* 也能保证最优。

4.11 Minimax 搜索

Minimax 用于双人零和博弈。

设有两个玩家：

- MAX：希望分数最大。
- MIN：希望 MAX 的分数最小。

规则：

1. MAX 层取子节点最大值。
2. MIN 层取子节点最小值。
3. 从叶节点向上回传。

例如：

某个 MIN 节点的子节点为：

3, 5, 2

则该 MIN 节点值为：

$$\min(3, 5, 2) = 2$$

某个 MAX 节点的子节点为：

2, 7, 4

则该 MAX 节点值为：

$$\max(2, 7, 4) = 7$$

4.12 alpha-beta 剪枝

alpha-beta 剪枝是 Minimax 的优化。

它不会改变最终结果，只减少搜索节点。

定义：

α = MAX 当前能保证的最好值

β = MIN 当前能保证的最好值

剪枝条件：

$\alpha \geq \beta$

含义：

如果继续搜索已经不可能影响最终选择，就停止展开该分支。

4.13 alpha-beta 记忆规则

层	操作	更新
MAX 层	取最大值	更新 α
MIN 层	取最小值	更新 β
任意层	若 $\alpha \geq \beta$	剪枝

4.14 蒙特卡洛树搜索 MCTS

- MCTS 包括四步：
- 1. 选择 Selection。
 - 2. 扩展 Expansion。
 - 3. 模拟 Simulation。
 - 4. 反向传播 Backpropagation。

4.14.1 选择

从根节点开始，根据 UCB/UCT 选择最值得探索的子节点。

常见公式：

$$UCT_i = \bar{X}_i + C \sqrt{\frac{\ln N}{n_i}}$$

- 其中：
- $\bar{X}_i$ ：节点 i 的平均收益。
 - N ：父节点访问次数。
 - n_i ：子节点访问次数。
 - C ：探索系数。

第一项是利用，第二项是探索。

4.14.2 扩展

如果当前节点还没有完全展开，则扩展一个新的子节点。

4.14.3 模拟

从新节点开始，随机模拟到终局，得到输赢或收益。

4.14.4 反向传播

将模拟结果沿路径向上传递，更新每个节点的：

1. 访问次数。
2. 累计收益。
3. 平均收益。

5. 监督学习

监督学习使用带标签的数据。

训练数据为：

$$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

其中：

- x_i 是输入。
- y_i 是标签。
- 模型学习映射：

$$f : x \rightarrow y$$

5.1 分类与回归

任务	输出	例子
回归	连续值	预测温度、价格、速度
分类	离散类别	判断是否故障、识别类别

5.2 损失函数

损失函数衡量预测错误程度。

单个样本损失：

$$L(f(x_i), y_i)$$

训练集平均损失：

$$R_{emp}(f) = \frac{1}{n} \sum_{i=1}^n L(f(x_i), y_i)$$

这叫经验风险。

训练目标：

$$\min_f R_{emp}(f)$$

5.3 期望风险与经验风险

期望风险：

$$R(f) = E[L(f(X), Y)]$$

它代表模型在真实数据分布上的平均错误。

但真实分布通常未知，所以使用训练集上的平均损失近似：

$$R_{emp}(f) = \frac{1}{n} \sum_{i=1}^n L(f(x_i), y_i)$$

5.4 泛化能力

泛化能力指模型在未见过的数据上的表现。

如果训练集表现很好，测试集表现很差，叫过拟合。

如果训练集和测试集表现都不好，叫欠拟合。

5.5 正则化

正则化用于防止模型过拟合。

一般形式：

$$J(w) = L(w) + \lambda \Omega(w)$$

其中：

- $L(w)$ ：原始损失。
- $\Omega(w)$ ：正则项。
- λ ：正则化强度。

L2 正则：

$$\Omega(w) = w^T w$$

所以：

$$J(w) = L(w) + \lambda w^T w$$

5.6 线性回归

线性回归模型：

$$\hat{y} = w^T x + b$$

如果将偏置并入参数，可以写成：

$$\hat{y} = w^T x$$

最小二乘损失：

$$L(w) = \sum_{i=1}^n (y_i - w^T x_i)^2$$

矩阵形式：

$$L(w) = (y - Xw)^T (y - Xw)$$

5.7 带 L2 正则的线性回归

目标函数：

$$J(w) = (y - Xw)^T (y - Xw) + \lambda w^T w$$

对 w 求导：

$$\frac{\partial J}{\partial w} = -2X^T(y - Xw) + 2\lambda w$$

令导数为 0：

$$-2X^T y + 2X^T Xw + 2\lambda w = 0$$

整理：

$$(X^T X + \lambda I)w = X^T y$$

所以：

$$w = (X^T X + \lambda I)^{-1} X^T y$$

这就是岭回归。

5.8 Logistic 回归

Logistic 回归用于二分类。

模型：

$$P(y = 1|x) = \sigma(w^T x + b)$$

其中：

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

因为 sigmoid 函数输出范围是 $(0, 1)$ ，所以可以解释为概率。

分类规则：

$$P(y = 1|x) > 0.5$$

则判为 1，否则判为 0。

5.9 Logistic 回归的对数几率

定义几率：

$$\frac{P(y = 1|x)}{P(y = 0|x)}$$

Logistic 回归满足：

$$\log \frac{P(y = 1|x)}{P(y = 0|x)} = w^T x + b$$

所以它本质上是让对数几率成为输入特征的线性函数。

5.10 生成方法与判别方法

生成方法

生成方法学习联合分布：

$$P(X, Y)$$

通常分解为：

$$P(X, Y) = P(X|Y)P(Y)$$

分类时使用贝叶斯公式：

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

代表模型：

- 朴素贝叶斯。
- 高斯判别分析。
- 隐马尔可夫模型。

生成方法关心：

数据是怎么生成的？

判别方法

判别方法直接学习：

$$P(Y|X)$$

或者直接学习决策边界。

代表模型：

- Logistic 回归。
- SVM。
- 神经网络。

判别方法关心：

怎么把类别分开？

5.11 LDA 线性判别分析

LDA 的目标是找到一个投影方向，使得：

1. 同类样本尽可能聚集。
2. 不同类样本尽可能分离。

目标函数：

$$J(w) = \frac{w^T S_B w}{w^T S_W w}$$

其中：

- S_B ：类间散度矩阵。
- S_W ：类内散度矩阵。

LDA 适合类别近似高斯且共享协方差矩阵的情况。

5.12 高斯判别分析

假设每一类条件分布为高斯：

$$p(x|y = k) = N(\mu_k, \Sigma_k)$$

根据贝叶斯公式：

$$P(y = k|x) \propto p(x|y = k)P(y = k)$$

取对数：

$$\log P(y = k|x) = \log p(x|y = k) + \log P(y = k) + C$$

如果所有类别协方差不同：

$$\Sigma_k \text{ 不同}$$

则得到 QDA，即二次判别分析。

如果所有类别共享协方差：

$$\Sigma_k = \Sigma$$

则得到 LDA，即线性判别分析。

5.13 支持向量机 SVM

SVM 的目标是找到分类超平面：

$$w^T x + b = 0$$

使分类间隔最大。

二分类标签：

$$y_i \in \{-1, +1\}$$

约束：

$$y_i(w^T x_i + b) \geq 1$$

最大化间隔等价于最小化：

$$\frac{1}{2} \|w\|^2$$

所以硬间隔 SVM 的优化问题为：

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

约束：

$$y_i(w^T x_i + b) \geq 1$$

5.14 软间隔 SVM

现实数据可能不能完全线性分开，因此引入松弛变量：

$$\xi_i \geq 0$$

约束变成：

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$

目标函数：

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_i \xi_i$$

其中 C 控制错误惩罚强度。

5.15 核函数

当数据线性不可分时，可以用核函数映射到高维空间。

常见核函数：

线性核：

$$K(x, z) = x^T z$$

多项式核：

$$K(x, z) = (x^T z + c)^d$$

高斯 RBF 核：

$$K(x, z) = \exp\left(-\frac{\|x - z\|^2}{2\sigma^2}\right)$$

核函数的核心作用：

6. 无监督学习

无监督学习处理没有标签的数据。

训练数据只有：

$$x_1, x_2, \dots, x_n$$

没有：

$$y_i$$

目标是发现数据内部结构。

常见任务：

任务	目标
聚类	把相似样本分组
降维	用低维表示保留主要信息
密度估计	估计数据分布
表示学习	学习更好的特征

6.1 方差、协方差、皮尔逊相关系数

方差：

$$Var(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

协方差：

$$Cov(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

皮尔逊相关系数：

$$\rho_{XY} = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

范围：

$$-1 \leq \rho_{XY} \leq 1$$

解释：

相关系数	含义
$\rho > 0$	正相关

相关系数	含义
$\rho < 0$	负相关
$\rho = 0$	线性不相关
$\rho = 1$	完全正线性相关
$\rho = -1$	完全负线性相关

6.2 K-means 聚类

K-means 是经典聚类算法。

目标是把数据分成 K 个簇：

$$C_1, C_2, \dots, C_K$$

每个簇有一个质心：

$$\mu_k$$

目标函数：

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} ||x_i - \mu_k||^2$$

含义：

让每个样本尽可能靠近自己所属簇的中心。

6.3 K-means 算法步骤

1. 选择 K 个初始质心。
2. 计算每个样本到每个质心的距离。
3. 将样本分配给最近质心对应的簇。
4. 更新每个簇的质心：

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

5. 重复步骤 2 到 4，直到质心不再变化。

6.4 为什么 K-means 最小化类内方差？

聚类的目标是：

1. 同一类内部尽可能相似。
2. 不同类之间尽可能不同。

类内方差越小，说明同一簇内部越紧密。

所以 K-means 要最小化：

$$\sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

6.5 K-means 的缺点

K-means 有以下缺点：

1. 需要提前指定 K 。
2. 对初始质心敏感。
3. 对异常点敏感。
4. 更适合球形簇。
5. 不适合复杂形状的数据分布。

6.6 PCA 主成分分析

PCA 是降维方法。

目标：

找到一些方向，让数据投影到这些方向后保留尽可能多的信息。

PCA 的核心是：

最大化投影方差

如果数据投影到某个方向后方差大，说明数据在这个方向上差异明显，信息丰富。

6.7 PCA 数学步骤

给定数据矩阵：

$$X \in R^{n \times d}$$

其中：

- n 是样本数。
- d 是特征维度。

第一步：中心化

$$\tilde{X} = X - \bar{X}$$

第二步：计算协方差矩阵

$$\Sigma = \frac{1}{n} \tilde{X}^T \tilde{X}$$

第三步：特征值分解

$$\Sigma v_i = \lambda_i v_i$$

其中：

- v_i 是特征向量。
- λ_i 是特征值。

第四步：选择最大特征值对应的方向

如果降到 k 维，取前 k 个最大特征值对应的特征向量：

$$W = [v_1, v_2, \dots, v_k]$$

第五步：投影

$$Z = XW$$

6.8 PCA 与 K-means 的区别

方法	类型	目标
K-means	聚类	最小化类内方差
PCA	降维	最大化投影方差

记忆：

K-means 让同一簇内部更紧。
PCA 让降维后保留更多信息。

6.9 SVD 奇异值分解

对矩阵 A ，SVD 分解为：

$$A = U \Sigma V^T$$

其中：

- U ：左奇异向量。
- Σ ：奇异值矩阵。
- V ：右奇异向量。

奇异值越大，对应方向信息越重要。

低秩近似：

$$A_k = U_k \Sigma_k V_k^T$$

表示只保留最大的 k 个奇异值，用更简单的矩阵近似原矩阵。

6.10 特征人脸 Eigenface

特征人脸是 PCA/SVD 在人脸识别中的应用。

步骤：

1. 收集很多人脸图像。
2. 将每张人脸图像拉平成向量。
3. 计算平均脸。
4. 每张脸减去平均脸。
5. 对人脸矩阵做 PCA/SVD。
6. 得到若干个特征脸。
7. 将新人脸投影到特征脸空间中。
8. 使用低维表示进行识别。

直观理解：

一张人脸有很多像素，但真正区分人脸的关键信息只集中在少数方向上。PCA 找到的这些方向就是特征脸。

6.11 潜在语义分析 LSA

LSA 用于文本分析。

基本思想：

通过词语在文档中的共现关系，发现隐藏语义结构。

步骤：

1. 构造词-文档矩阵：

$$A \in R^{M \times N}$$

其中 M 是词数， N 是文档数。

2. 对矩阵做 SVD：

$$A = U \Sigma V^T$$

3. 保留前 k 个奇异值：

$$A_k = U_k \Sigma_k V_k^T$$

4. 得到低维语义空间。

在低维空间中，语义相近的词或文档距离更近。

6.12 EM 算法

EM 是期望最大化算法，用于含有隐变量的参数估计问题。

EM 包括两步：

1. E 步：Expectation，估计隐变量的后验概率。

2. M 步：Maximization，用 E 步结果更新参数。

6.13 什么是隐变量？

隐变量是：

影响观测结果，但我们看不到的变量。

例如硬币问题：

有两枚硬币 A 和 B。

每轮随机选一枚硬币投 10 次。

我们只能看到每轮投掷结果，但不知道这一轮用的是 A 还是 B。

“这一轮用了哪枚硬币”就是隐变量。

6.14 EM 硬币问题

设初始参数：

$$\theta_A = 0.6$$

$$\theta_B = 0.5$$

对于某一轮结果 R_i ，计算：

$$P(A|R_i) = \frac{P(R_i|A)P(A)}{P(R_i|A)P(A) + P(R_i|B)P(B)}$$

如果默认：

$$P(A) = P(B) = 0.5$$

则：

$$P(A|R_i) = \frac{P(R_i|A)}{P(R_i|A) + P(R_i|B)}$$

E 步计算每轮来自 A/B 的概率。

M 步更新：

$$\theta_A = \frac{A \text{ 的期望正面次数}}{A \text{ 的期望总次数}}$$

$$\theta_B = \frac{B \text{ 的期望正面次数}}{B \text{ 的期望总次数}}$$

7. 博弈论与遗憾最小化

7.1 博弈论基本概念

概念	含义
玩家	参与决策的主体
策略	玩家可以采取的行动方案
策略集	一个玩家所有可选策略的集合
收益	玩家采取策略后得到的结果
局势	所有玩家策略组合形成的状态
信息	玩家掌握的博弈相关知识

7.2 纯策略

纯策略是确定选择某一个行动。

例如石头剪刀布：

- 一直出石头。
- 一直出剪刀。
- 一直出布。

这些都是纯策略。

7.3 混合策略

混合策略是按照概率随机选择行动。

例如：

$$P(\text{石头}) = \frac{1}{3}$$

$$P(\text{剪刀}) = \frac{1}{3}$$

$$P(\text{布}) = \frac{1}{3}$$

这就是一个混合策略。

7.4 纳什均衡

纳什均衡是一个策略组合，在这个组合下：

任何一个玩家单独改变自己的策略，都不能获得更高收益。

数学表达：

设策略组合为：

$$s^* = (s_1^*, s_2^*, \dots, s_n^*)$$

如果对任意玩家 i ：

$$u_i(s_i^*, s_{-i}^*) \geq u_i(s_i, s_{-i}^*)$$

则 s^* 是纳什均衡。

7.5 囚徒困境

典型收益矩阵：

	B 沉默	B 背叛
A 沉默	(-1,-1)	(-10,0)
A 背叛	(0,-10)	(-5,-5)

对 A 来说：

- 如果 B 沉默，A 背叛更好。
- 如果 B 背叛，A 背叛也更好。

对 B 同理。

所以：

(背叛, 背叛)

是纳什均衡。

但它不是整体最优，因为：

(沉默, 沉默)

对两人整体更好。

7.6 如何找纳什均衡？

矩阵博弈中可以用最佳反应法。

步骤：

1. 固定 B 的策略，看 A 哪个选择收益最高。
2. 固定 A 的策略，看 B 哪个选择收益最高。
3. 如果某个格子同时是双方最佳反应，就是纳什均衡。

7.7 遗憾值

遗憾表示：

如果当初选另一个策略，本来可以多赚多少。

设实际选择策略 a , 得到收益 $u(a)$ 。

如果当时选择策略 b , 可以得到收益 $u(b)$ 。

则对策略 b 的遗憾为:

$$R_b = u(b) - u(a)$$

如果:

$$R_b > 0$$

说明后悔没选 b 。

如果:

$$R_b < 0$$

说明幸好没选 b 。

通常只保留正遗憾:

$$R_b^+ = \max(R_b, 0)$$

7.8 累计遗憾

多轮博弈中, 累计遗憾为:

$$R_i^T = \sum_{t=1}^T r_i^t$$

其中:

- r_i^t 是第 t 轮对策略 i 的即时遗憾。
- R_i^T 是到第 T 轮的累计遗憾。

7.9 遗憾匹配

遗憾匹配的核心:

下一轮选择某策略的概率, 与它过去的正遗憾成正比。

公式:

$$p_i = \frac{R_i^+}{\sum_j R_j^+}$$

如果所有正遗憾都是 0, 则平均随机选择:

$$p_i = \frac{1}{n}$$

8. 深度学习

今年深度学习由李伟昌老师负责。张帆老师样题中的梯度下降参考性不大，但 CNN、RNN、MLP 等基础内容仍然必须掌握。

8.1 神经网络基本结构

神经网络是由很多层组成的函数。

基本结构：

1 | 输入层 → 隐藏层 → 输出层

单个神经元：

$$z = w^T x + b$$

$$a = \phi(z)$$

其中：

- x ：输入。
- w ：权重。
- b ：偏置。
- ϕ ：激活函数。
- a ：输出。

8.2 为什么需要激活函数？

如果没有激活函数，多层神经网络只是线性变换的叠加。

例如：

$$h = W_1 x$$

$$y = W_2 h$$

则：

$$y = W_2 W_1 x$$

仍然是线性变换。

所以没有激活函数，再多层也无法表达复杂非线性关系。

8.3 常见激活函数

Sigmoid

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

特点：

- 输出范围 $(0, 1)$ 。
 - 可以解释为概率。
 - 容易梯度消失。
-

Tanh

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

特点：

- 输出范围 $(-1, 1)$ 。
 - 零中心化。
 - 也可能梯度消失。
-

ReLU

$$ReLU(x) = \max(0, x)$$

特点：

- 计算简单。
 - 缓解梯度消失。
 - 负半轴输出为 0。
-

Softmax

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

特点：

- 每项大于 0。
 - 所有项加起来等于 1。
 - 可表示多分类概率。
-

8.4 损失函数

MSE

用于回归：

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

交叉熵

用于分类。

二分类：

$$L = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$$

多分类：

$$L = - \sum_{k=1}^K y_k \log \hat{y}_k$$

8.5 梯度下降

基本公式：

$$x_{t+1} = x_t - \alpha f'(x_t)$$

其中：

- α ：学习率。
- $f'(x_t)$ ：当前位置梯度。
- 负号表示沿下降方向更新。

例子：

$$f(x) = (x - 3)^2$$

$$f'(x) = 2(x - 3)$$

如果：

$$x_0 = 8, \quad \alpha = 0.2$$

第一次：

$$x_1 = 8 - 0.2 \cdot 2(8 - 3) = 6$$

第二次：

$$x_2 = 6 - 0.2 \cdot 2(6 - 3) = 4.8$$

8.6 前向传播

前向传播就是从输入算到输出。

两层神经网络：

$$h = \phi(W_1x + b_1)$$
$$\hat{y} = softmax(W_2h + b_2)$$

8.7 反向传播

反向传播使用链式法则计算梯度。

如果：

$$L = L(\hat{y}, y)$$

且：

$$\hat{y} = f(w)$$

则：

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial w}$$

反向传播的本质：

从损失函数开始，把误差一层层往前传，计算每个参数应该怎么调整。

8.8 MLP 多层感知机

MLP 是全连接神经网络。

一层全连接：

$$h = \phi(Wx + b)$$

如果输入维度为 d ，输出维度为 m ：

$$W \in R^{m \times d}$$

$$b \in R^m$$

参数数量：

$$md + m$$

8.9 CNN 卷积神经网络

CNN 常用于图像数据。

核心特点：

1. 局部连接。
2. 参数共享。
3. 保留空间结构。
4. 提取局部特征。

卷积输出尺寸公式：

$$O = \left\lfloor \frac{N - F + 2P}{S} \right\rfloor + 1$$

其中：

符号	含义
N	输入尺寸
F	卷积核尺寸
P	padding
S	stride
O	输出尺寸

例子：

输入：

$$32 \times 32$$

卷积核：

$$5 \times 5$$

padding：

$$P = 0$$

stride：

$$S = 1$$

输出尺寸：

$$O = \left\lfloor \frac{32 - 5 + 2 \cdot 0}{1} \right\rfloor + 1$$
$$O = 28$$

所以输出为：

$$28 \times 28$$

8.10 Padding

Padding 是在输入边缘补零。

作用：

- 1. 控制输出尺寸。
- 2. 保留边缘信息。
- 3. 避免特征图过快变小。

如果希望 stride 为 1 时输出尺寸不变，常用：

$$P = \frac{F - 1}{2}$$

8.11 Stride

Stride 是卷积核每次移动的步长。

- $S = 1$ ：每次移动 1 格。
- $S = 2$ ：每次移动 2 格，输出变小。

Stride 越大，输出尺寸越小。

8.12 Pooling 池化

池化用于降低特征图尺寸。

最大池化：

max pooling

取局部窗口最大值。

平均池化：

average pooling

取局部窗口平均值。

作用：

1. 降低计算量。
2. 增强局部平移不变性。
3. 减少过拟合。

8.13 RNN 循环神经网络

RNN 用于序列数据。

例如：

- 文本。
- 时间序列。
- 语音。
- 船舶轨迹。
- 海洋传感器数据。

RNN 递推公式：

$$h_t = \tanh(Wx_t + Uh_{t-1} + b)$$

其中：

- x_t : 当前输入。
- h_{t-1} : 上一时刻隐藏状态。
- h_t : 当前隐藏状态。
- W : 输入权重。
- U : 隐藏状态权重。

例子:

设:

$$W = 1, \quad U = 1, \quad b = 0$$

$$h_0 = 0$$

$$x = [1, 2]$$

则:

$$h_1 = \tanh(1 \cdot 1 + 1 \cdot 0) = \tanh(1) \approx 0.7616$$

$$h_2 = \tanh(1 \cdot 2 + 1 \cdot 0.7616) = \tanh(2.7616) \approx 0.9920$$

8.14 RNN 的问题

普通 RNN 容易出现:

1. 梯度消失。
2. 梯度爆炸。
3. 难以捕捉长程依赖。

例如一句话:

我昨天买了一本书，虽然封面很旧，内容却很精彩，所以我很喜欢它。

“它”指代“书”，中间隔了很多词。普通 RNN 可能难以记住这么远的信息。

8.15 LSTM

LSTM 是长短时记忆网络，用门控机制缓解长程依赖问题。

核心结构:

1. 遗忘门。
2. 输入门。
3. 输出门。
4. 细胞状态。

遗忘门:

$$f_t = \sigma(W_f[x_t, h_{t-1}] + b_f)$$

输入门:

$$i_t = \sigma(W_i[x_t, h_{t-1}] + b_i)$$

候选状态：

$$\tilde{C}_t = \tanh(W_C[x_t, h_{t-1}] + b_C)$$

细胞状态：

$$C_t = f_t C_{t-1} + i_t \tilde{C}_t$$

输出门：

$$o_t = \sigma(W_o[x_t, h_{t-1}] + b_o)$$

隐藏状态：

$$h_t = o_t \tanh(C_t)$$

考试重点不是死背公式，而是理解：

LSTM 用门控制信息保留、写入和输出，用来解决普通 RNN 的长程依赖问题。

8.16 GRU

GRU 是 LSTM 的简化版本。

主要有两个门：

1. 更新门。
2. 重置门。

特点：

- 参数比 LSTM 少。
- 训练更快。
- 也能缓解长程依赖问题。

8.17 BatchNorm、Dropout、梯度裁剪

BatchNorm

作用：

1. 稳定中间层分布。
2. 加快训练。
3. 允许使用更大学习率。

Dropout

训练时随机丢弃部分神经元。

作用：

1. 防止神经元之间过度依赖。
2. 减少过拟合。

梯度裁剪

如果梯度太大，就限制梯度范数。

作用：

- 1. 防止梯度爆炸。
- 2. 常用于 RNN、LSTM、GRU。

9. 智能体

智能体是能够感知环境、进行决策并采取行动的系统。

基本循环：

1 | 环境 → 感知 → 决策 → 行动 → 环境变化

形式化表示：

$$Agent : Percepts \rightarrow Actions$$

也就是说，智能体根据感知序列选择行动。

9.1 智能体基本组成

组成	作用
传感器	感知环境
执行器	对环境采取行动
状态表示	存储环境或内部状态
决策模块	判断下一步做什么
学习模块	根据经验改进
目标/效用函数	衡量行动好坏

9.2 无人船智能体例子

以无人船为例：

组成	例子
传感器	GPS、雷达、声呐、摄像头
执行器	推进器、舵机
状态	位置、速度、航向、障碍物信息
决策	路径规划、避障

组成	例子
学习	根据历史航行数据优化策略

9.3 理性智能体

理性智能体是指：

在已有感知和知识条件下，选择期望性能最好的行动。

理性不等于全知。

如果信息不足，理性智能体也可能做错，但只要它在当时信息下做了最合理选择，就仍然是理性的。

9.4 PEAS 描述

PEAS 用于描述智能体任务环境。

字母	含义
P	Performance measure，性能指标
E	Environment，环境
A	Actuators，执行器
S	Sensors，传感器

例如自动驾驶船：

项目	内容
P	安全、快速、省能、避碰
E	海面、港口、其他船舶、天气
A	推进器、舵机
S	GPS、雷达、声呐、摄像头

9.5 智能体类型

9.5.1 简单反射智能体

只根据当前感知行动。

规则形式：

1	if 条件 then 动作
---	---------------

例如：

缺点：没有记忆，不能处理部分可观测环境。

9.5.2 基于模型的反射智能体

维护内部状态。

适合当前感知不完整的环境。

例如无人船暂时看不到某个障碍物，但可以根据之前观测记住它的位置。

9.5.3 目标型智能体

根据目标选择行动。

例如：

目标是到达某个坐标点。

它会规划路径。

9.5.4 效用型智能体

不仅考虑是否达到目标，还比较不同结果的好坏。

例如两条路线都能到达目标：

- 路线 A 快但危险。
- 路线 B 慢但安全。

效用型智能体会综合安全、时间、能耗做选择。

9.5.5 学习型智能体

能从经验中改进。

例如无人船通过多次航行学习：

- 哪些海况下需要降低速度。
- 哪些区域容易出现障碍物。
- 哪些路径更省能。

10. 最终考试公式清单

10.1 贝叶斯后验

$$P(H = k | e_1, e_2) = \frac{P(e_1, e_2 | H = k)P(H = k)}{\sum_j P(e_1, e_2 | H = j)P(H = j)}$$

条件独立时：

$$P(H = k|e_1, e_2) = \frac{P(e_1|H = k)P(e_2|H = k)P(H = k)}{\sum_j P(e_1|H = j)P(e_2|H = j)P(H = j)}$$

10.2 线性变换

$$E[Ax + b] = A\mu + b$$

$$Cov[Ax + b] = A\Sigma A^T$$

10.3 方差和协方差

$$Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y)$$

10.4 高斯后验

$$\sigma_{post}^2 = \frac{\sigma^2 \sigma_w^2}{\sigma^2 + \sigma_w^2}$$

$$\mu_{post} = \frac{\sigma_w^2 \mu + \sigma^2 y}{\sigma^2 + \sigma_w^2}$$

10.5 A* 搜索

$$f(n) = g(n) + h(n)$$

10.6 K-means

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} ||x_i - \mu_k||^2$$

10.7 PCA

$$\Sigma v = \lambda v$$

10.8 Logistic 回归

$$P(y = 1|x) = \frac{1}{1 + e^{-(w^T x + b)}}$$

10.9 SVM

$$\min_{w, b} \frac{1}{2} ||w||^2$$

$$y_i(w^T x_i + b) \geq 1$$

10.10 CNN 输出尺寸

$$O = \left\lfloor \frac{N - F + 2P}{S} \right\rfloor + 1$$

10.11 RNN

$$h_t = \tanh(Wx_t + Uh_{t-1} + b)$$

11. 考前背诵版

1. 贝叶斯公式：后验正比于似然乘先验。
2. 条件独立：给定 H 后，联合似然可以拆成两个似然相乘。
3. 高斯后验：先验和测量融合后仍是高斯，后验方差更小。
4. 线性变换：均值 $A\mu + b$ ，协方差 $A\Sigma A^T$ 。
5. 方差公式： $Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y)$ 。
6. 逻辑证明：先消蕴含，再用量词否定和德摩根律。
7. 贪婪搜索： $f = h$ 。
8. A* 搜索： $f = g + h$ 。
9. A* 最优依赖可采纳或一致启发函数。
10. Minimax：MAX 取大，MIN 取小。
11. alpha-beta： $\alpha \geq \beta$ 就剪枝。
12. MCTS：选择、扩展、模拟、反向传播。
13. K-means：最小化类内方差。
14. PCA：最大化投影方差。
15. EM：E 步估计隐变量，M 步更新参数。
16. 纳什均衡：任何人单独改变策略都不会变好。
17. 遗憾最小化：正遗憾越大，下轮选它概率越高。
18. 监督学习有标签，无监督学习无标签。
19. 生成模型学 $P(X, Y)$ ，判别模型学 $P(Y|X)$ 或决策边界。
20. 线性回归做连续预测，Logistic 回归做分类概率。
21. SVM 找最大间隔超平面。
22. CNN 输出尺寸公式是 $\lfloor (N - F + 2P)/S \rfloor + 1$ 。
23. RNN 用隐藏状态记忆序列。
24. LSTM/GRU 用门控解决长程依赖。
25. 智能体是感知环境、做决策、采取行动的系統。