



浙江大学
Zhejiang University



海洋信息学：通与观（夏） 4-子空间与特征分析处理 (Eigenanalysis Methods)

王德麟

delinwang@zju.edu.cn

海洋电子与智能系统研究所
海洋学院，浙江大学

三、特征空间分析方法

特征分析方法在很多专业应用（例如匹配滤波、线性系统的傅里叶分析、带通滤波器等等）中被广泛使用。

特征分析能基于给定的数据而判断其“自然”坐标系。

在抽象数学中，**特征分析等同于谱分析**：

- 例如线性算子的**谱被定义为其特征值**
- 其“自然”的**基即为其特征向量**

在一般的工程应用中，通常谱分析指代傅里叶分析（实时上远不止于此）。

本节我们讨论利用这种思想进行阵列信号处理。

3.1 数学基础 – 符号与定义

1. 符号

我们常用字母加低杆表示矢量和矩阵，并且用小写字母表示矢量，大写字母表示矩阵

$$\underline{a} = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} \quad \underline{B} = \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix}$$

2. 线性空间

关于线性空间和希尔伯特空间的严格定义，读者可以参阅有关线性代数的教科书，这里仅给出其使用概念和结论

3.1 数学基础 – 符号与定义

所谓线性空间是指满足线性变换关系的矢量集合，这里“满足线性变换关系”是指

$\forall \underline{\alpha}, \underline{\beta} \in \Omega$ 和 $\forall a, b \in C$ (a, b 为复常数) 有:

$$a(\underline{\alpha} + \underline{\beta}) = a\underline{\alpha} + a\underline{\beta}$$

$$(a + b)\underline{\alpha} = a\underline{\alpha} + b\underline{\alpha}$$

$$a(b\underline{\alpha}) = (ab)\underline{\alpha}$$

严格定义： 线性空间首先应满足“加法”和“数乘”的封闭性。

3.1 数学基础 – 符号与定义

3. 希尔伯特空间

希尔伯特空间是指定义了内积的完备线性空间。

设矢量 $\underline{\alpha}$, $\underline{\beta}$ 为:

$$\underline{\alpha} = [x_1, x_2, \dots, x_N]^T$$

$$\underline{\beta} = [y_1, y_2, \dots, y_N]^T$$

我们定义两个矢量的内积为:

$$(\underline{\alpha}, \underline{\beta}) = \underline{\alpha}^H \underline{\beta} = \sum_{i=1}^N x_i^* y_i$$

式中 “ $\{ \}^H$ ” 表示共轭转置, “ $*$ ” 表示取复共轭

3.1 数学基础 – 独立性、正交性、子空间分解

1. 线性无关

在N维线性空间中，若 $\sum_{i=1}^n a_i \underline{\alpha}_i = 0 \Leftrightarrow a_1 = \cdots = a_n = 0$ ，那么，矢量组 $\{\underline{\alpha}_1, \underline{\alpha}_2, \cdots, \underline{\alpha}_n\}$ 是线性无关的，否则，若 $\underline{\alpha}_1, \underline{\alpha}_2, \cdots, \underline{\alpha}_n$ 的非平凡组合为零，则称 $\{\underline{\alpha}_1, \underline{\alpha}_2, \cdots, \underline{\alpha}_n\}$ 是线性相关的。

2. 子空间

线性空间 Ω 的一个子集V，若V对加法和数乘封闭，即对任意 $\{\underline{\alpha}, \underline{\beta}\} \in V$ 和 $a \in \mathcal{C}$ ，有 $\underline{\alpha} + \underline{\beta} \in V$ ， $a \cdot \underline{\alpha} \in V$ ，则称V是 Ω 的一个子空间。

3.1 数学基础 – 独立性、正交性、子空间分解

设 $\{\underline{\alpha}_1, \underline{\alpha}_2, \dots, \underline{\alpha}_n\}$ 是 Ω 上的一组矢量，则由 $\underline{\alpha}_1, \underline{\alpha}_2, \dots, \underline{\alpha}_n$ 的所有线性组合构成的集合是 Ω 的一个子空间，常称为 $\{\underline{\alpha}_1, \underline{\alpha}_2, \dots, \underline{\alpha}_n\}$ 张成的**子空间**，记为：

$$\text{span}\{\underline{\alpha}_1, \underline{\alpha}_2, \dots, \underline{\alpha}_n\} = \left\{ \sum_{i=1}^n a_i \underline{\alpha}_i \mid a_1, a_2, \dots, a_n \in C \right\}$$

若 $\{\underline{\alpha}_1, \underline{\alpha}_2, \dots, \underline{\alpha}_n\}$ 是线性无关的，且 $\underline{\beta} \in \text{span}\{\underline{\alpha}_1, \underline{\alpha}_2, \dots, \underline{\alpha}_n\}$ ，那么 $\underline{\beta}$ 可由 $\underline{\alpha}_1, \underline{\alpha}_2, \dots, \underline{\alpha}_n$ 唯一地线性表示。

3.1 数学基础 – 独立性、正交性、子空间分解

如果 $\{\underline{\alpha}_{i1}, \underline{\alpha}_{i2}, \dots, \underline{\alpha}_{ik}\}$ 是线性无关，并且不是 $\{\underline{\alpha}_1, \underline{\alpha}_2, \dots, \underline{\alpha}_n\}$ 的任一线性无关组的真子集，那么这个子集 $\{\underline{\alpha}_{i1}, \underline{\alpha}_{i2}, \dots, \underline{\alpha}_{ik}\}$ 就是 $\{\underline{\alpha}_1, \underline{\alpha}_2, \dots, \underline{\alpha}_n\}$ 的一个**最大线性无关组**。

如果是最大线性无关组，那么，

$$1) \quad \text{span}\{\underline{\alpha}_1, \underline{\alpha}_2, \dots, \underline{\alpha}_n\} = \text{span}\{\underline{\alpha}_{i1}, \underline{\alpha}_{i2}, \dots, \underline{\alpha}_{ik}\}$$

$$2) \quad \dim \text{span}\{\underline{\alpha}_1, \underline{\alpha}_2, \dots, \underline{\alpha}_n\} = k$$

3) 称 $\{\underline{\alpha}_{i1}, \underline{\alpha}_{i2}, \dots, \underline{\alpha}_{ik}\}$ 是 $\text{span}\{\underline{\alpha}_{i1}, \underline{\alpha}_{i2}, \dots, \underline{\alpha}_{ik}\}$ 的一个基。

3.1 数学基础 – 矩阵的值域与零空间

给定一组向量，由这组向量张成的子空间容易由以上给出的定义写出。另一种求子空间的方法是给定子空间中矢量的约束条件。如与矩阵有关的**子空间值域**与**零空间**。

设 $\underline{A} \in R^{m \times n}$ ，则 $\underline{A}$ 的值域（或列空间）为

$$\begin{aligned} R(\underline{A}) &= \left\{ \underline{y} \in R^m \mid \underline{y} = \underline{A}\underline{x}, \underline{x} \in R^n \right\} \\ &= \text{span} \{ \underline{a}_1, \underline{a}_2, \dots, \underline{a}_n \}, \underline{A} = (\underline{a}_1, \underline{a}_2, \dots, \underline{a}_n) \end{aligned}$$

$\underline{A}$ 的零空间(核) 为: $N(\underline{A}) = \{ \underline{x} \in R^n \mid \underline{A}\underline{x} = 0 \}$

矩阵 $\underline{A}$ 的秩定义为:

$$\text{rank}(\underline{A}) = \dim[R(\underline{A})]$$

3.1 数学基础 – 矩阵的值域与零空间

可以证明 $\text{rank}(\underline{A}) = \text{rank}(\underline{A}^T)$ ，即矩阵的秩等于最大无关行数或最大无关列数。

$\text{rank}(\underline{A}) + \dim[N(\underline{A})] = n$ ，如果 $m = n$ ，则有如下关系：

- 1) $\underline{A}$ 是非奇异的。
- 2) $N(\underline{A}) = \{0\}$
- 3) $\text{rank}(\underline{A}) = n$ (满秩)

3. 正交性

设 $\underline{\alpha}, \underline{\beta} \in R^n$ ，则这两个矢量的夹角余弦定义为：

$$\cos \gamma = \frac{(\underline{\alpha}, \underline{\beta})}{\sqrt{(\underline{\alpha}, \underline{\alpha})(\underline{\beta}, \underline{\beta})}} \quad (\underline{\alpha}, \underline{\beta} \neq 0)$$

3.1 数学基础 – 矩阵的值域与零空间

- 1) 矢量 $\underline{\alpha}, \underline{\beta}$ 正交是指其夹角余弦等于零, 即 $(\underline{\alpha}, \underline{\beta}) = 0$
- 2) 矢量组 $\{\underline{\alpha}_1, \underline{\alpha}_2, \dots, \underline{\alpha}_n\}$ 是正交的, 如果对所有 $i \neq j$, 有 $\underline{\alpha}_i$ 与 $\underline{\alpha}_j$ 正交。如果满足 $(\underline{\alpha}_i, \underline{\alpha}_j) = \delta_{ij}$, 则称之为标准正交的。
- 3) 子空间 $S_1, \dots, S_p$ 称为互相正交的, 如果

$$\forall \underline{\alpha} \in S_i \text{ 和 } \underline{\beta} \in S_j, \text{ 当 } i \neq j \text{ 时有 } (\underline{\alpha}, \underline{\beta}) = 0$$

4. 子空间分解:

如果 $S_1, \dots, S_k$ 是线性空间 Ω 的子空间, 那么它们的和 $S = \{\underline{\alpha}_1 + \underline{\alpha}_2 + \dots + \underline{\alpha}_k \mid \underline{\alpha}_i \in S_i, i = 1, 2, \dots, k\}$ 也是一个子空间。若每一个 $\underline{v} \in S$ 有唯一的表达式 $\underline{v} = \underline{\alpha}_1 + \underline{\alpha}_2 + \dots + \underline{\alpha}_k, \underline{\alpha}_i \in S_i$ 则 S 被称为一个直和, 并写为: $S = S_1 \oplus S_2 \oplus \dots \oplus S_k$

3.1 数学基础 – 矩阵的值域与零空间

子空间的交集也是一个子空间，如 $S = S_1 \cap S_2$ 。如果 $S_i \cap S_j = \{0\}, i \neq j$ ，则 $S = S_1 + \cdots + S_k$ 为直和。

一个重要特例：**正交分解**

一个子空间 $S \in R^m$ 的正交补为 $S^\perp = \left\{ \underline{y} \in R^m \mid \underline{y}^T \underline{x} = 0, \underline{x} \in S \right\}$

如果矢量 $\underline{v}_1, \cdots, \underline{v}_k$ 是标准正交的并且张成子空间 $S \in R^m$ ，则称矢量组 $\underline{v}_1, \cdots, \underline{v}_k$ 构成子空间 S 的一个标准正交基。它总可以扩充为 R^m 的一组完全的标准正交基 $\{\underline{v}_1, \cdots, \underline{v}_m\}$ ，此时：

$$S^\perp = \text{span}\{\underline{v}_{k+1}, \cdots, \underline{v}_m\}$$

3.1 数学基础 – 线性变换与投影算子

1. 线性变换

线性空间 R^m 上的一个变换 λ 称为线性变换，如果它满足：

$$1) \forall \underline{\alpha}, \underline{\beta} \in R^m, \lambda(\underline{\alpha} + \underline{\beta}) = \lambda \underline{\alpha} + \lambda \underline{\beta}$$

$$2) \forall \underline{\alpha} \in R^m, \text{和数 } a \in R^1, \lambda(a \underline{\alpha}) = a \lambda \underline{\alpha}$$

在一定基的意义上，一个线性变换 λ 可用一矩阵 $\underline{A}$ 表示。

用一组基表示它在线性变换 λ 下的象，其坐标所排成的矩阵就称为 λ 在这组基下的矩阵。线性变换与矩阵一一对应。

3.1 数学基础 – 线性变换与投影算子

2. 正交投影算子

一种重要的线性变换是投影算子，而且正交情形是最重要的。

正交投影算子的定义：

设子空间 $S \in R^m$ ，线性变换 P 称为正交投影，如果，


$$1) \forall \underline{x} \in R^m, P\underline{x} \in S \text{ 且 } \forall \underline{x} \in S, P\underline{x} = \underline{x},$$

$$2) \forall \underline{x} \in R^m, \forall \underline{y} \in S, (\underline{x} - P\underline{x}, \underline{y}) = 0$$

3.1 数学基础 – 线性变换与投影算子

几何意义：已知 m 维线性空间中的一个点 $\underline{b}$ 和子空间 S ，求点 $\underline{p}$ ，使 $\underline{b}$ 到 $\underline{p}$ 点的距离不超过 $\underline{b}$ 到 S 上各点的距离。如图所示。

向量 $\underline{b}$ 表示由一系列的实验和调查所给出的数据，由于这些实验或调查包含不少的误差，以致在给定的子空间中不可能找到这组数据，即，我们不可能把 $\underline{b}$ 表示成子空间 S 中的一个向量，因为我们所遇到的方程组是不相容的，因此，是无解的，这样一来，最小二乘解法就是选择点 $\underline{p}$ 作为最佳选择。



3.1 数学基础 – 线性变换与投影算子

1) 若子空间 S 由标准正交基 $\underline{a}_1, \underline{a}_2, \dots, \underline{a}_n$ 张成, 则任一矢量 $\underline{b} \in R^m$ 在子空间 S 上的正交投影矢量 $\underline{p}$ 可表示为:

$$\begin{aligned}\underline{p} &= \sum_{i=1}^n (\underline{b}, \underline{a}_i) \underline{a}_i = (\underline{a}_1, \dots, \underline{a}_n) \begin{pmatrix} \underline{a}_1^H \\ \vdots \\ \underline{a}_n^H \end{pmatrix} \underline{b} \\ &= \underline{P} \underline{b}\end{aligned}$$

此公式可用直角坐标系来解释。

式中 $m \times m$ 阶方阵

常称为**投影矩阵**。

$$\begin{aligned}\underline{P} &= (\underline{a}_1, \dots, \underline{a}_n) \begin{pmatrix} \underline{a}_1^H \\ \vdots \\ \underline{a}_n^H \end{pmatrix} \dots\dots\dots (1) \\ &= \underline{A} \underline{A}^H \quad \underline{A} = (\underline{a}_1, \dots, \underline{a}_n)\end{aligned}$$

3.1 数学基础 – 线性变换与投影算子

可见，由标准正交基来求正交投影算子是很方便的。

2) 若子空间 S 由一组基 $a_1, a_2, \dots, a_n$ (未必正交) 张成，求由 $a_1, a_2, \dots, a_n$ 表示的空间 S 上的正交投影算子。

由正交投影的定义, $\underline{b}$ 到 S 的投影矢量 $\underline{p} = \underline{A}\underline{x}$, 即 $\underline{p}$ 由 $a_1, a_2, \dots, a_n$ 线性表示, 且 $\underline{b} - \underline{p}$ 与 $a_1, a_2, \dots, a_n$ 正交, 即 $\underline{A}^H (\underline{b} - \underline{A}\underline{x}) = 0$, 则 $\underline{x} = (\underline{A}^H \underline{A})^{-1} \underline{A}^H \underline{b}$, 得投影矢量

$$\underline{p} = \underline{A}(\underline{A}^H \underline{A})^{-1} \underline{A}^H \underline{b} \dots \dots \dots (2)$$

由(2.12)式可知, S 上的正交投影矩阵为:

$$\underline{P} = \underline{A}(\underline{A}^H \underline{A})^{-1} \underline{A}^H \dots \dots \dots (3)$$

3.1 数学基础 – 线性变换与投影算子

上式给出了到矩阵的列空间上的正交投影矩阵，当基矢量是标准正交基时，（3）式可简化为（1）式形式。（3）式也称为的伪逆。

3. 正交变换与正交矩阵

线性变换是正交变换，如果对线性空间中的任意矢量 $\underline{\alpha}, \underline{\beta}$ ，有内积关系： $(\underline{\lambda}\underline{\alpha}, \underline{\lambda}\underline{\beta}) = (\underline{\alpha}, \underline{\beta})$ 。有时又称为保角变换、酉变换。相应于正交变换 $\underline{\lambda}$ 的矩阵 $\underline{A}$ 为正交矩阵或酉矩阵，如果满足关系：

$$\underline{A}^H \underline{A} = \underline{A} \underline{A}^H = I$$

3.1 数学基础 – 矩阵的分解

1. 特征值分解

对任一 N 维Hermite矩阵 ($\underline{A} = \underline{A}^H$)，其特征矢量构成 N 维空间的一组标准正交基。因此，存在一正交矩阵 $\underline{T}$ 使得 $\underline{A}$ 与一对角阵相似，即：

$$\underline{T}^{-1} \underline{A} \underline{T} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_N)$$

式中 $\lambda_i (i=1, 2, \dots, N)$ 为 $\underline{A}$ 的特征值。

正定（半正定）性：若Hermite阵 $\underline{A}$ 对任一非零矢量，有：
 $\underline{X}^H \underline{A} \underline{X} > 0 (\geq 0)$ ，则称 $\underline{A}$ 为正定（半正定）的。

- 正定的Hermite矩阵 $\underline{A}$ 的所有特征值为正数，即：

$$\underline{A} = \underline{T} \text{diag}(\lambda_1, \dots, \lambda_N) \underline{T}^H = \sum_{i=1}^N \lambda_i \underline{v}_i \underline{v}_i^H \dots \dots \dots (4)$$

特征值
特征矢量

3.1 数学基础 – 矩阵的分解

2. 奇异值分解 (SVD)

对 $\forall \underline{A} \in C^{n \times m}$, 存在正交矩阵 $\underline{U} = (\underline{u}_1, \dots, \underline{u}_n) \in C^{n \times n}$ 和 $\underline{V} = (\underline{v}_1, \dots, \underline{v}_m) \in C^{m \times m}$, 使得

$$\underline{A} = \sum_{i=1}^r \sigma_i \underline{u}_i \underline{v}_i^H = \underline{U} \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots, 0) \underline{V}^H$$

式中 $r = \text{rank}(\underline{A})$, $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq \sigma_{r+1} = \dots = 0$, σ_i 是 $\underline{A}$ 的奇异值。

容易验证:

- 1) $\underline{A} \underline{v}_i = \sigma_i \underline{u}_i$
- 2) $\underline{A}^H \underline{u}_i = \sigma_i \underline{v}_i, (i = 1, 2, \dots, p)$
- 3) $N(\underline{A}) = \text{span}\{\underline{v}_{r+1}, \dots, \underline{v}_m\}$
 $R(\underline{A}) = \text{span}\{\underline{u}_1, \dots, \underline{u}_r\}$

3.1 数学基础 – 矩阵的分解

2.矩阵QR分解

任一矩阵 $\underline{A} \in C^{n \times m}$ ，总可以化为 $\underline{A} = \underline{Q}\underline{R} \cdots \cdots \cdots (5)$

其中 $\underline{Q}$ 是正交矩阵， $\underline{R}$ 是上三角矩阵，（5）式称为 $\underline{A}$ 的QR分解。

3.1 数学基础 – 复变量实函数求导数

研究实函数： $f(W, W^*) = g(x, y)$ ，其中 $W = x + jy$
 $W^* = x - jy$

根据求导法则：

$$\frac{\partial g}{\partial x} = \frac{\partial f}{\partial W} \frac{\partial W}{\partial x} + \frac{\partial f}{\partial W^*} \frac{\partial W^*}{\partial x} = \frac{\partial f}{\partial W} + \frac{\partial f}{\partial W^*}$$

$$\frac{\partial g}{\partial y} = \frac{\partial f}{\partial W} \frac{\partial W}{\partial y} + \frac{\partial f}{\partial W^*} \frac{\partial W^*}{\partial y} = j \frac{\partial f}{\partial W} - j \frac{\partial f}{\partial W^*}$$

$$\therefore \frac{\partial f}{\partial W} = \frac{1}{2} \left(\frac{\partial g}{\partial x} - j \frac{\partial g}{\partial y} \right)$$

$$\frac{\partial g}{\partial W^*} = \frac{1}{2} \left(\frac{\partial g}{\partial x} + j \frac{\partial g}{\partial y} \right)$$

3.1 数学基础 – 复变量实函数求导数

1. 矩阵对标量求微分

若矩阵 $\underline{A} = (a_{ij})_{m \times n}$ 的元素是某个自变量 t (标量) 的函数, 当每一个 $a_{ij}(t)$ 均为可微函数时, 可构成一个与 $\underline{A}$ 同阶的矩阵:

$$\frac{d \underline{A}}{dt} = \left[\frac{da_{ij}}{dt} \right]_{m \times n}$$

, 称作矩阵 $\underline{A}$ 对自变量 t 的导数或微分。

矩阵的微分满足的基本运算规则为:

$$\begin{aligned} 1) \frac{d(\underline{A} + \underline{B})}{dt} &= \frac{d \underline{A}}{dt} + \frac{d \underline{B}}{dt} \\ 2) \frac{d(\underline{A} \underline{B})}{dt} &= \frac{d \underline{A}}{dt} \underline{B} + \underline{A} \frac{d \underline{B}}{dt} \end{aligned}$$

3.1 数学基础 – 复变量实函数求导数

2. 矩阵对矢量求微分

设 $\underline{A} = (a_{ij})_{m \times n}$ 的元素是某一矢量 $\underline{x}_{p \times 1}$ 的可微函数，则矩阵 $\underline{A}$ 对矢量 $\underline{x}$ 的微分：

$$\frac{d \underline{A}}{d \underline{x}} = \begin{bmatrix} \frac{d \underline{A}}{dx_1} \\ \vdots \\ \frac{d \underline{A}}{dx_p} \end{bmatrix} \neq \frac{d \underline{A}}{d \underline{x}^H} = \begin{bmatrix} \frac{d \underline{A}}{dx_1} & \dots & \frac{d \underline{A}}{dx_p} \end{bmatrix}$$

3. 矩阵对矩阵求微分

$$\underline{A} = (a_{ij})_{p \times q}, \text{ 则 } \frac{d \underline{A}}{d \underline{B}} = \left[\left(\frac{d(a_{ij})}{db_{kl}} \right)_{p \times q} \right]_{sp \times tq}$$
$$\underline{B} = (b_{kl})_{s \times t}$$

右边矩阵共有 st 个块，每分块矩阵为 $\underline{A}$ 矩阵对矩阵 $\underline{B}$ 的元素 b_{kl} 求导，所有分块矩阵按 $\underline{B}$ 阵排列方式排列

3.2 特征分析与傅里叶分析

考虑一个线性算子: $L[a_1x_1 + a_2x_2] = a_1L[x_1] + a_2L[x_2]$


特征向量 $\boldsymbol{v}$: $L[\boldsymbol{v}] = \lambda\boldsymbol{v}, \quad \boldsymbol{v} \neq 0$

可见, 线性算子 L 作用在特征向量 $\boldsymbol{v}$ 上, 相当于将向量**线性放大 (或缩小)**, 其**放大 (或缩小) 系数即为特征值** (类比滤波器增益)

- 特征向量乘以一个常数仍为特征向量, 通常取归一化的 $\boldsymbol{v}$ 作为基, 即令 $\|\boldsymbol{v}\|=1$
- 特征向量的数量即为矩阵定义的**线性空间的维度**。

我们可以把线性算子 L 的特征值 λ 看做它的谱。 特征值 特征向量

考虑一个LTI系统的例子:
$$L[e^{j\omega n}] = \sum_{k=-\infty}^{\infty} h(n-k)e^{j\omega k} = H(e^{j\omega})e^{j\omega n}$$



不难看出, 线性滤波器的谱即为它的频谱。

3.2 特征分析与傅里叶分析

还可以进一步利用特征向量的正交性和完备性，把任意一个向量写为特征向量的和的形式。等效于利用特征向量定义了坐标系。

$$x = \sum_i a_i v_i \quad \text{with} \quad a_i = \langle x, v_i \rangle$$

$$L[x] = \sum_i \lambda_i a_i v_i$$

类比傅里叶变换：

$$x(n) = \sum_{i=1}^{\infty} X(\omega_i) \exp(j\omega_i n)$$

$$X(\omega_i) = \langle x(n), \exp(j\omega_i n) \rangle = \frac{1}{N} \sum_{n=0}^N x(n) \exp(-j\omega_i n)$$

一旦确定了线性算子 L 的一组相互正交的特征向量 $\{v_i\}$ ，我们就可以用它定义一套“自然”的坐标系。

- 需要注意的是，线性算子 L 的特征向量不一定是正交的，但是对于厄米矩阵，其特征值都为实数，且特征向量彼此正交。

3.2 特征分析与傅里叶分析

对于阵列信号处理问题，我们通常主要讨论阵列的空间相关矩阵 $\mathbf{R}$ 。

空间相关矩阵具有厄米对称性（ $\mathbf{R}^t = \mathbf{R}$ ），并且通常都是正定的（ $\mathbf{x}^t \mathbf{R} \mathbf{x} > 0, \forall \mathbf{x} \neq \mathbf{0}$ ）。

这种情况下，矩阵的特征值为正数，且特征向量正交。

$$\mathbf{v}_i^t \mathbf{R} \mathbf{v}_j = \lambda_i \delta_{ij} \quad \mathbf{v}_i^t \mathbf{v}_j = \delta_{ij}$$

这样一来，我们就得到了一组正交基 $\{\mathbf{v}_i\}$

$$\mathbf{R} = \sum_{i=1}^M \lambda_i \mathbf{v}_i \mathbf{v}_i^t \quad \text{and} \quad \mathbf{R}^{-1} = \sum_{i=1}^M \lambda_i^{-1} \mathbf{v}_i \mathbf{v}_i^t$$

存在使特征值取最大值（最小值）的特征向量

$$\mathbf{x}^t \mathbf{R} \mathbf{x} = \sum \lambda_i a_i^2$$

$$\min_{\mathbf{x}} \frac{\mathbf{x}^t \mathbf{R} \mathbf{x}}{\mathbf{x}^t \mathbf{x}} = \lambda_M, \quad \mathbf{x} = \mathbf{v}_M$$
$$\max_{\mathbf{x}} \frac{\mathbf{x}^t \mathbf{R} \mathbf{x}}{\mathbf{x}^t \mathbf{x}} = \lambda_1, \quad \mathbf{x} = \mathbf{v}_1$$

3.3 信号子空间与噪声子空间

信号模型：等距 m 元阵接收 p 个信源



$$\mathbf{a}(\theta_i) = \left[1, e^{-j\omega_i}, \dots, e^{-j(m-1)\omega_i} \right]^T, \quad \omega_i = 2\pi \frac{d}{\lambda} \sin \theta_i$$

$$= \left[a_1(\omega_i), \dots, a_m(\omega_i) \right]^T$$

$$x_k(n) = \sum_{i=1}^p s_i(n) a_k(\omega_i) + e_k(n), \quad k = 1, 2, \dots, m$$

阵列采样数据为： $\mathbf{x}(n) = \sum_{i=1}^p s_i(n) \mathbf{a}(\omega_i) + \mathbf{e}(n) = \mathbf{A}(\omega) \mathbf{s}(n) + \mathbf{e}(n)$

$$\mathbf{a}(\omega) = \left[\mathbf{a}(\omega_1), \dots, \mathbf{a}(\omega_p) \right]$$

$$= \begin{bmatrix} 1 & 1 & \dots & 1 \\ e^{-j\omega_1} & e^{-j\omega_2} & \dots & e^{-j\omega_p} \\ \vdots & \vdots & \vdots & \vdots \\ e^{-j(m-1)\omega_1} & e^{-j(m-1)\omega_2} & \dots & e^{-j(m-1)\omega_p} \end{bmatrix}$$

3.3 信号子空间与噪声子空间

做如下假设：

1. 对于不同的 ω_i ，向量 $\mathbf{a}(\omega_i)$ 相互线性独立
2. 加性噪声向量 $\mathbf{e}(n)$ 的每个元素都是独立全同的零均值复白噪声，方差 σ^2 。
3. 矩阵 $\mathbf{P} = E\{\mathbf{s}(n)\mathbf{s}^t(n)\}$ 非奇异，即 $\text{rank}(\mathbf{P}) = p$

条件1：对于ULA， $\mathbf{a}(\omega) = [\mathbf{a}(\omega_1), \dots, \mathbf{a}(\omega_p)] = \begin{bmatrix} 1 & 1 & \dots & 1 \\ e^{-j\omega_1} & e^{-j\omega_2} & \dots & e^{-j\omega_p} \\ \vdots & \vdots & \ddots & \vdots \\ e^{-j(m-1)\omega_1} & e^{-j(m-1)\omega_2} & \dots & e^{-j(m-1)\omega_p} \end{bmatrix}$

对于矩阵 $\underline{\mathbf{M}} = \begin{bmatrix} 1 & 1 & \dots & 1 \\ x_1 & x_2 & \dots & x_N \\ x_1^2 & x_2^2 & \dots & x_N^2 \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{N-1} & x_2^{N-1} & \dots & x_N^{N-1} \end{bmatrix}$ ，列向量相互独立（满列秩）的充要条件为当 $i \neq j$ 时， $x_i \neq x_j$

$$e^{j\frac{2\pi d}{\lambda}\sin\theta_1} \neq e^{j\frac{2\pi d}{\lambda}\sin\theta_2}$$
$$d < \lambda / 2$$

3.3 信号子空间与噪声子空间

做如下假设：

1. 对于不同的 ω_i ，向量 $\mathbf{a}(\omega_i)$ 相互线性独立
2. 加性噪声向量 $\mathbf{e}(n)$ 的每个元素都是独立全同的零均值复白噪声,方差 σ^2 。
3. 矩阵 $\mathbf{P} = E\{\mathbf{s}(n)\mathbf{s}^t(n)\}$ 非奇异，即 $\text{rank}(\mathbf{P}) = p$

条件1：对于ULA，该条件天然满足。

条件2： $E\{\mathbf{e}(n)\} = 0$, $E\{\mathbf{e}(n)\mathbf{e}^t(n)\} = \sigma^2\mathbf{I}$, $E\{\mathbf{e}_i(n)\mathbf{e}_j^t(n)\} = 0$

条件3：要求信号源相互独立。

3.3 信号子空间与噪声子空间

3个条件满足的情况下， $\mathbf{x}(n)$ 的空间相关矩阵为：

$$\begin{aligned}\mathbf{R}_{xx} &= E\{\mathbf{x}(n)\mathbf{x}^t(n)\} = \mathbf{A}(\omega)E\{\mathbf{s}(n)\mathbf{s}^t(n)\}\mathbf{A}^t(\omega) + \sigma^2\mathbf{I} \\ &= \mathbf{A}\mathbf{P}\mathbf{A}^t + \sigma^2\mathbf{I}\end{aligned}$$

可见 $\mathbf{R}_{xx}$ 是厄米矩阵，可进行特征值分解：

$$\begin{aligned}\mathbf{R}_{xx} &= \mathbf{U}\Sigma\mathbf{U}^t \\ \Sigma &= \text{diag}(\alpha_1^2, \dots, \alpha_m^2)\end{aligned}$$

条件1 保证了 $\mathbf{A}$ 满列秩。

$$\begin{aligned}\text{rank}(\mathbf{A}\mathbf{P}\mathbf{A}^t) &= \text{rank}(\mathbf{P}) = p \\ \mathbf{U}^t\mathbf{A}\mathbf{P}\mathbf{A}^t\mathbf{U} &= \text{diag}(\alpha_1^2, \dots, \alpha_p^2, 0, \dots, 0)\end{aligned}$$

3.3 信号子空间与噪声子空间

$$\text{rank}(\mathbf{A}\mathbf{P}\mathbf{A}^t) = \text{rank}(\mathbf{P}) = p$$

$$\mathbf{U}^t \mathbf{A}\mathbf{P}\mathbf{A}^t \mathbf{U} = \text{diag}(\alpha_1^2, \dots, \alpha_p^2, 0, \dots, 0)$$

式子中 $\alpha_1^2, \dots, \alpha_p^2$ 是没有噪声时观测信号 $A(\omega)s(n)$ 的自相关矩阵 $\mathbf{A}\mathbf{P}\mathbf{A}$ 的特征值。

在同时用 $\mathbf{U}^t$ 左乘， $\mathbf{U}$ 右乘 $\mathbf{R}_{xx}$ ：

$$\mathbf{U}^t \mathbf{R}_{xx} \mathbf{U} = \mathbf{U}^t \mathbf{A}\mathbf{P}\mathbf{A}^t \mathbf{U} + \sigma^2 \mathbf{U}^t \mathbf{U} = \text{diag}(\alpha_1^2, \dots, \alpha_p^2, 0, \dots, 0) + \sigma^2 \mathbf{I}$$

可以发现，自相关矩阵 $\mathbf{R}_{xx}$ 的特征值为：

$$\lambda_i = \sigma_i^2 = \begin{cases} \alpha_i^2 + \sigma^2, & i = 1, \dots, p \\ \sigma^2, & i = p+1, \dots, m \end{cases}$$

3.3 信号子空间与噪声子空间

进一步，我们还可以根据两种特征值，将特征矩阵 U 也分为两部分 $U = [S|G]$ ，即分别由信号的特征向量和噪声的特征向量构成。

$$S = [s_1, \dots, s_p] = [u_1, \dots, u_p]$$

$$G = [g_1, \dots, g_{m-p}] = [u_{p+1}, \dots, u_m]$$

通常，将信号特征向量张成的 $\text{span}\{s_1, \dots, s_p\}$ 称为信号子空间，将噪声特征向量张成的 $\text{span}\{g_1, \dots, g_{m-p}\}$ 称为噪声子空间。

由于子空间的构造方法（特征向量彼此正交），因此信号子空间与噪声子空间正交

$$\text{span}\{s_1, \dots, s_p\} \perp \text{span}\{g_1, \dots, g_{m-p}\}$$

3.3 信号子空间与噪声子空间

前面提到，我们一般选择归一化的特征向量。此处我们认为特征矩阵 U 为酉矩阵，满足

$$UU^t = [S \mid G] \begin{bmatrix} S^t \\ G^t \end{bmatrix} = SS^t + GG^t = I$$

即有：

$$GG^t = I - SS^t$$

定义信号子空间上的投影矩阵

$$P_s = S \langle S, S \rangle^{-1} S^t = SS^t$$

其中：

$$\langle S, S \rangle = S^t S = I$$

$P_s x$ 可视为向量 x 在信号子空间上的投影。同理得噪声子空间上的投影矩阵：

$$P_n = G \langle G, G \rangle^{-1} G^t = GG^t = I - SS^t = I - P_s$$

3.3 信号子空间与噪声子空间

当信号子空间 S_m^p 已知，进行方向估计的方法：

用 $a(\theta_i)$ 为搜索矢量，向信号子空间 S_m^p 上做投影，或向噪声子空间 N_m^{m-p} 做投影。

定理： $a(\theta)$ 在 N_m^{m-p} 上投影矢量长度等于零， $a(\theta)$ 在 S_m^p 上投影矢量为自己本身的充要条件为

$$\theta \in \{\theta_1, \theta_2, \dots, \theta_p\}$$

可以以此正交性特征，进行信号到达方向估计。

3.4 多重信号分类法 (Multiple Signal Classification)

基本思想：将任意阵列输出数据的协方差矩阵进行特征分解，从而得到与信号分量相对应的信号子空间和与信号分量正交的噪声子空间，然后利用这两个子空间的正交性来估计信号的参数。

窄带远场的信号模型： $X(t) = A(\theta)s(t) + N(t)$

$$R = E[XX^H] = AE[SS^H]A^H + \sigma^2 I = AR_s A^H + \sigma^2 I$$

由于信号和噪声相互独立，数据的协方差矩阵可以分解为与信号和噪声相关的两部分，大特征值对应的特征矢量张成的空间称为信号子空间，理想条件下，信号子空间和噪声子空间是相互正交的。

3.4 多重信号分类法 (Multiple Signal Classification)

MUSIC方法步骤:

1. 由阵列数据 $\mathbf{x}(n)$ 估计相关矩阵 $\hat{\mathbf{R}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}(n) \mathbf{x}^H(n)$
2. 对 $\mathbf{R}$ 作特征分解
3. 用 p 个大特征值对应的特征矢量构成信号子空间 $\mathbf{S}_m^p$, 或用 $m - p$ 个小特征值对应的特征矢量构成噪声子空间 $\mathbf{N}_m^{m-p}$
4. 用搜索矢量 $\mathbf{a}(\theta)$ 向 $\mathbf{N}_m^{m-p}$ 做投影。

$$\mathbf{P}_n \mathbf{a}(\theta) = \left[\sum_{i=p+1}^m \underline{\mathbf{v}}_i \underline{\mathbf{v}}_i^H \right] \mathbf{a}(\theta)$$

5. 计算谱峰:

$$S(\theta) = \frac{1}{\|\mathbf{P}_n \mathbf{a}(\theta)\|} = \frac{1}{\sum_{i=p+1}^N \left| \underline{\mathbf{a}}^H(\theta) \underline{\mathbf{v}}_i \right|^2}$$

谱峰与信号强度无关, 只反映 $\mathbf{a}(\theta)$ 与 $\mathbf{N}_m^{m-p}$ 的正交性。

3.4 多重信号分类法 (Multiple Signal Classification)

值得注意的是:

1. 非理想情况下得到的协方差矩阵的特征值满足:

$$\lambda_1 > \lambda_2 > \cdots > \lambda_N > \lambda_{N+1} > \cdots > \lambda_M$$

2. 而不满足 $\lambda_1 > \lambda_2 > \cdots > \lambda_N > \lambda_{N+1} = \cdots = \lambda_M = \sigma^2$

3. 由于 $\mathbf{U}\mathbf{U}^t = \mathbf{S}\mathbf{S}^t + \mathbf{G}\mathbf{G}^t = \mathbf{I}$, 表明利用噪声子空间进行信号参数估计与利用信号子空间进行估计是一致的。

4. 当 $a(\theta)$ 属于信号子空间时, $a^H(\theta)\hat{\mathbf{U}}_n \rightarrow 0$, 此时空间谱会在信号源方向出现“谱峰”。

5. Music算法实质是基于一维搜索的噪声子空间算法


3.4 多重信号分类法 (Multiple Signal Classification)

基于解相干的Music算法:


Music算法在理想条件下具有良好的性能，但在信号源相干时算法变得很坏。

极端地，当信号完全相干时，阵列接收数据的协方差矩阵的秩降为1，显然这会导致信号子空间的维数小于信号源数，也就是说信号子空间“扩散”到噪声子空间，这会导致某些相干源的导向矢量与噪声子空间不完全正交，从而无法正确估计信号源方向。

此时，核心问题就是解相干或去相干，主要方法有：




3.4 多重信号分类法 (Multiple Signal Classification)



来波方向为: $25^\circ, 30^\circ, 60^\circ$

3.4 多重信号分类法 (Multiple Signal Classification)



3.4 多重信号分类法 (Multiple Signal Classification)

MUSIC vs. 最小方差波束形成:

常规波束形成方法: $\hat{\theta} = \arg \max_{\theta} S(\theta) = \mathbf{a}^H(\theta) \mathbf{R} \mathbf{a}(\theta)$

最优波束形成方法:
$$\begin{cases} \min_{\mathbf{W}} \mathbf{W}^H \mathbf{R} \mathbf{W} \\ \mathbf{W}^H \mathbf{a}(\theta) = 1 \end{cases} \Rightarrow \mathbf{W}_{opt} = \frac{\mathbf{R}^{-1} \mathbf{a}(\theta)}{\mathbf{a}^H(\theta) \mathbf{R}^{-1} \mathbf{a}(\theta)}$$

$$\hat{\theta} = \arg \max_{\theta} S_C(\theta)$$

$$S_C(\theta) = \mathbf{W}_{opt}^H \mathbf{R} \mathbf{W}_{opt} = \frac{1}{\mathbf{a}^H(\theta) \mathbf{R}^{-1} \mathbf{a}(\theta)}$$

MVDR分辨率明显高于普通波束扫描。基理可由最优波束形成的原理来理解。但波束扫描无论是普通波束形成还是最优波束形成，其分辨率或多或少是受限于阵列孔径。

3.4 多重信号分类法 (Multiple Signal Classification)

MUSIC vs. 最小方差波束形成:

相关矩阵: $\mathbf{R} = \sum_{i=1}^P \lambda_i \mathbf{v}_i \mathbf{v}_i^H + \sigma_n^2 \sum_{i=P+1}^N \mathbf{v}_i \mathbf{v}_i^H$

$$\begin{aligned}\mathbf{R}^{-1} &= \sum_{i=1}^P \lambda_i^{-1} \mathbf{v}_i \mathbf{v}_i^H + \frac{1}{\sigma_n^2} \left(\mathbf{I} - \sum_{i=1}^P \mathbf{v}_i \mathbf{v}_i^H \right) \\ &= \frac{1}{\sigma_n^2} \left(\mathbf{I} - \sum_{i=1}^P \frac{\lambda_i - \sigma_n^2}{\lambda_i} \mathbf{v}_i \mathbf{v}_i^H \right)\end{aligned}$$

当SNR很大, $\lambda_i \gg \sigma_n^2$

$$\mathbf{R}^{-1} \approx \frac{1}{\sigma_n^2} \left(\mathbf{I} - \sum_{i=1}^P \mathbf{v}_i \mathbf{v}_i^H \right) = \frac{1}{\sigma_n^2} \sum_{i=P+1}^N \mathbf{v}_i \mathbf{v}_i^H$$

MUSIC谱:

$$S_{music}(\theta) = \frac{1}{\sum_{i=P+1}^N |\mathbf{a}^H(\theta) \mathbf{v}_i|^2}$$

MVDR (Capon) 谱:

$$S_C(\theta) = \frac{1}{\mathbf{a}^H(\theta) \mathbf{R}^{-1} \mathbf{a}(\theta)} \stackrel{SNR \rightarrow \infty}{\approx} \frac{\sigma_n^2}{\sum_{i=P+1}^N |\mathbf{a}^H(\theta) \mathbf{v}_i|^2} \approx S_{music}(\theta)$$

3.4 多重信号分类法 (Multiple Signal Classification)

MUSIC vs. 最小方差波束形成分辨率:

Capon法基于信号与干扰加噪声之比最大来求最优波束形成。
Music法则只关心信号与干扰之比最大来求最优波束形成，不关心噪声。

在相关矩阵 R 精确已知（要求无穷多次快拍数据）情况下，白噪声功率（或信噪比）不影响MUSIC方法

在 R 精度足够的情况下，一般MUSIC法优于MVDR。

关于谱峰强度:

Music谱峰只是反映了阵列流形矢量 $a(\theta)$ 与噪声子空间的正交性，而与信噪比无关。

而Capon谱峰是真正的输出功率，与信噪比有关。

一般而言，MVDR稳健性较MUSIC好，分辨力劣于MUSIC